Caracterização de Padrões de Depreciação Automotiva sob a Transição Energética: Uma Abordagem Baseada em Transformação Bidimensional de Séries Temporais

Gabriel Martins Brum
Departamento de Ciência da Computação e Estatística
Universidade Estadual Paulista (UNESP)
São José do Rio Preto, Brasil
g.brum@unesp.br

***Resumo*—A transição para a mobilidade elétrica introduz incertezas na precificação de veículos seminovos em razão da perda de capacidade de baterias, rápida obsolescência técnica e guerras comerciais de preços. Este artigo investiga a desvalorização veicular a partir de microdados da base fipeX. A investigação analisa se veículos elétricos apresentam desvalorização acelerada em relação a modelos convencionais de mesma faixa de preço de lançamento, bem como se a codificação de séries temporais em matrizes bidimensionais via *Gramian Angular Fields* e *Markov Transition Fields* aprimora o agrupamento não supervisionado frente a abordagens clássicas. A metodologia emprega a Taxa de Retenção de Valor em uma janela temporal de 32 meses com 4.457 séries, redução de dimensionalidade por PCA e modelagem por K-Means e DBSCAN. A validação das partições foi realizada por métricas intrínsecas e análise de variância bidirecional.**

***Index Terms*—Mineração de Séries Temporais, Veículos Elétricos, *Reshaping*, Agrupamento, Depreciação Automotiva.**

I. Introdução

O mercado automotivo global e brasileiro atravessa um processo de reorganização tecnológica impulsionado pela introdução e expansão de veículos elétricos (EVs) e híbridos [1]. A especulação em torno da depreciação desses veículos cria uma barreira para potenciais compradores, gerando receio quanto à revenda e elevando a incerteza sobre a taxa de desvalorização dos ativos [2]. Automóveis equipados com motores a combustão apresentam trajetória de desvalorização consolidada e linearizada em função da idade do bem [3]. Em contrapartida, os veículos eletrificados enfrentam incertezas operacionais singulares, destacando-se a perda de capacidade de armazenamento das baterias de íons de lítio e a rápida substituição técnica por modelos de maior autonomia [4]. A avaliação empírica conduzida sobre cinco mercados desenvolvidos apurou depreciação média anual de 13,9% para veículos elétricos (1,16% ao mês), superando a taxa de 10,4% ao ano observada em modelos convencionais a gasolina [5]. A literatura sobre o comportamento de depreciação veicular e políticas tarifárias tem se concentrado prioritariamente em economias desenvolvidas e na China, subsistindo uma lacuna empírica quanto à dinâmica do mercado brasileiro sob a transição energética [6], [7].

Para além da dinâmica setorial de mercado, a análise e a descoberta de padrões comportamentais em séries temporais têm incorporado técnicas de codificação matricial bidimensional (*reshaping*) [8], [9]. Abordagens convencionais representam o histórico de preços como vetores unidimensionais em $\mathbb{R}^T$, empregando distâncias Euclidianas sensíveis a desvios de escala e ruídos pontuais. O algoritmo Dynamic Time Warping (DTW) flexibiliza o alinhamento de sequências desfasadas, mas distensões no eixo temporal tendem a suprimir a sincronia de choques macroeconômicos exógenos, além de introduzir elevado custo computacional quadrático sobre bases volumosas [10]. Em contraposição, a conversão de séries temporais em matrizes bidimensionais atua como um agregador de atributos intrínsecos sobre a sequência original sem demandar variáveis externas. As transformações Gramian Angular Summation Field (GASF), Gramian Angular Difference Field (GADF) e Markov Transition Field (MTF) proporcionam reduções de 12% a 48% no erro de classificação frente a vetores brutos ao preservar relações angulares e matrizes de transição, promovendo adicionalmente maior estabilidade e ganho de silhueta no agrupamento financeiro [9], [11]. Esse panorama delimita duas lacunas centrais investigadas neste artigo: a carência de estudos empíricos sobre a Taxa de Retenção de Valor (VRR) de veículos elétricos e híbridos em comparação a modelos a combustão no mercado brasileiro e a inexistência de investigações que empreguem técnicas de *reshaping* para a descoberta de padrões de desvalorização veicular.

A. Objetivos, Questões de Pesquisa e Contribuições

O objetivo deste estudo consiste em analisar a dinâmica temporal de desvalorização veicular sob a transição energética no Brasil por meio de agrupamento não supervisionado, contrastando espaços vetoriais unidimensionais com representações matriciais bidimensionais combinadas à redução dimensional. A investigação é guiada por duas questões centrais de pesquisa: (1) a entrada de veículos elétricos induz desvalorização

relativa mais acelerada em comparação a veículos convencionais pareados no mesmo estrato econômico de lançamento, ou o padrão observado reflete prioritariamente a faixa de preço do ativo? (2) a codificação de séries temporais em matrizes bidimensionais projetadas via PCA produz agrupamentos com maior coesão e separabilidade intrínseca em relação às métricas vetoriais clássicas Euclidianas e DTW?

A partir dessa formulação, o trabalho apresenta três contribuições principais: (1) a caracterização quantitativa da retenção de valor de automóveis elétricos, híbridos e a combustão no mercado brasileiro ao longo de 32 meses de acompanhamento com microdados da base fipeX; (2) a comprovação estatística do papel preponderante da matriz energética sobre a depreciação por meio de pareamento econômico intra-estrato e análise de variância bidirecional; (3) a validação da codificação matricial GASF associada ao PCA como alternativa computacionalmente eficiente e com qualidade de separabilidade superior ao alinhamento elástico clássico.

II. Materiais e Métodos

O procedimento metodológico foi dividido em quatro etapas executadas sequencialmente: preparação da base de dados, pré-processamento das séries temporais de retenção de valor, codificação matricial bidimensional com redução dimensional e modelagem de agrupamento com validação das partições.

A. Base de Dados FipeX

Os dados foram obtidos do repositório público fipeX, que reúne o histórico de preços médios mensais de veículos automotores comercializados no Brasil apurados pela Fundação Instituto de Pesquisas Econômicas (FIPE) entre maio de 2005 e janeiro de 2026 [12]. A base original continha 9.276.121 registros cadastrais com atributos de identificação do modelo, montadora, ano de modelo, tipo de veículo, matriz energética e preço médio de mercado cotado em Reais ($P_{i,t}$).

B. Pré-Processamento e Análise Exploratória

O procedimento de limpeza e preparação foi conduzido para eliminar inconsistências e isolar a evolução dos preços em relação à idade cronológica dos veículos. Foram descartadas 83 instâncias duplicadas e 22 registros com valor monetário nulo. A base foi restrita a automóveis de passeio, o que resultou na exclusão de 3.565.306 registros referentes a motocicletas, caminhões e utilitários de grande porte. Modelos antigos cadastrados com atraso na FIPE foram eliminados por meio da restrição temporal $(ano_lancamento - ano_modelo) \leq 1$, descartando 1.942.304 registros para assegurar que a idade zero corresponda ao período de estreia comercial do ativo. Foram removidos 52.721 registros de combustíveis com volume residual (etanol e gás natural) e 24.996 registros de montadoras com baixa participação de mercado. Esse processo totalizou a exclusão de 5.585.432 registros, correspondendo a uma redução de 60,2% da base inicial.

A base remanescente de 3.690.689 registros pertencentes a 63 montadoras foi submetida ao cálculo da Taxa de Retenção de Valor (VRR), definida pela relação entre o preço no mês de avaliação t e o preço de lançamento no mês inicial:

$$VRR_{i,t} = \frac{P_{i,t}}{P_{i,0}}, \quad t \in \{0, 1, \ldots, T-1\}. \tag{1}$$

O cálculo da Equação 1 remove a magnitude nominal dos preços em Reais e permite a comparação direta entre veículos de diferentes faixas de mercado. Para viabilizar a modelagem, a amostra foi restrita a veículos lançados a partir de 2019 com acompanhamento contínuo por uma janela de $T = 32$ meses (2,6 anos), tolerando até 10% de interpolação linear para meses ausentes. Esse corte consolidou uma matriz balanceada de 4.457 séries temporais completas. A amostra resultante é composta por 1.756 veículos Flex (39,4%), 1.258 a Gasolina (28,2%), 871 a Diesel (19,5%), 382 Híbridos (8,6%) e 190 Elétricos (4,3%).

A categorização econômica foi estabelecida a partir dos quartis gerais dos preços de lançamento, apurando Q_1 igual a R$ 82.998,00, mediana de R$ 155.043,00 e Q_3 de R$ 325.283,00. Os veículos foram classificados nos estratos de Entrada ($P_{i,0} \leq Q_1$), Intermediário ($Q_1 < P_{i,0} \leq Q_3$) e Luxo ($P_{i,0} > Q_3$).

C. Codificação Bidimensional de Séries Temporais

As trajetórias temporais de retenção de valor foram convertidas em matrizes quadradas de dimensão 32×32 sem redimensionamento prévio, conforme o método proposto por Wang e Oates [9]. A série normalizada no intervalo $[-1, 1]$ foi inicialmente projetada em coordenadas polares com ângulo $\phi_t = \arccos(\widetilde{VRR}_t)$ e raio $r_t = t/T$. A matriz Gramian Angular Summation Field (GASF) foi gerada a partir da soma cosseno entre os pontos temporais:

$$G_{(i,j)} = \cos(\phi_i + \phi_j) = \widetilde{x}_i \widetilde{x}_j - \sqrt{1 - \widetilde{x}_i^2}\sqrt{1 - \widetilde{x}_j^2}. \tag{2}$$

A transformação descrita na Equação 2 preserva a correlação temporal e os valores médios de retenção do ativo. A matriz Gramian Angular Difference Field (GADF) foi calculada por meio da diferença seno:

$$D_{(i,j)} = \sin(\phi_i - \phi_j) = \widetilde{x}_j \sqrt{1 - \widetilde{x}_i^2} - \widetilde{x}_i \sqrt{1 - \widetilde{x}_j^2}, \tag{3}$$

agregando informação relativa às taxas locais de variação e à velocidade de perda de valor ao longo da série. A técnica Markov Transition Field (MTF) foi construída discretizando as trajetórias em cinco quantis de amplitude e computando as probabilidades de transição estocástica de primeira ordem entre os passos temporais i e j. Como o vetor achatado de cada imagem contém 1.024 atributos por canal e 3.072 atributos na fusão dos três canais, a técnica de Análise de Componentes Principais (PCA) foi aplicada retendo 95% da variância explicada acumulada [8]. Essa projeção reduziu os dados para 2 componentes no GASF e 5 componentes no GADF, eliminando ruídos colineares.

D. Modelagem de Agrupamento e Protocolo de Validação

O algoritmo K-Means foi avaliado com inicialização K-Means++ variando K de 2 a 7 sobre o espaço 1D VRR Euclidiano, sobre o espaço 1D com alinhamento temporal e sobre os espaços latentes gerados pelas imagens 2D via PCA [10], [13]. O algoritmo baseado em densidade DBSCAN também foi investigado, adotando o raio ε determinado pelo ponto de inflexão das curvas de k-distâncias para $MinPts = 5$ [8], [14].

A avaliação das partições foi conduzida por critérios intrínsecos e testes extrínsecos. Na validação intrínseca, foram calculados o coeficiente de Silhueta médio e o índice Davies-Bouldin, acompanhados da análise do decaimento da soma dos erros quadráticos [15], [16]. Na validação extrínseca com os rótulos de combustível e faixa de preço, foram computados o índice Rand ajustado (ARI), a informação mútua normalizada (NMI), a homogeneidade, a completude e o coeficiente V de Cramér. A contribuição de cada fator sobre a variação líquida aos 32 meses ($\Delta VRR = VRR_{32m} - VRR_{0m}$) foi quantificada por análise de variância (ANOVA) bidirecional (2×5).

III. Resultados e Discussão

A. Análise Exploratória e Pareamento de Segmentos

A amostra de 4.457 trajetórias de retenção expõe o comportamento singular do mercado brasileiro entre 2019 e 2026. Em contraste com o padrão histórico de depreciação linear, automóveis a combustão registraram valorização nominal atípica motivada por choques na cadeia global de suprimentos, atingindo retenção média superior a 115% em modelos Flex e Diesel aos 12 e 24 meses. Em contrapartida, veículos elétricos exibiram desvalorização contínua. Como 93,2% dos elétricos pertencem aos estratos Intermediário e de Luxo (mediana de R$ 322.000,00) e 75,5% dos modelos Flex integram o estrato de Entrada (mediana de R$ 77.000,00), a avaliação comparativa demanda pareamento intra-estrato para isolar a tecnologia de propulsão da magnitude nominal do preço inicial.

B. Eficácia Comparativa das Representações 1D e 2D

A qualidade do agrupamento pelo algoritmo K-Means foi avaliada para partições de $K = 2$ a $K = 7$ sobre os espaços vetoriais 1D e os espaços latentes das transformações bidimensionais reduzidas por PCA. Para a partição com quatro grupos ($K = 4$), a projeção matricial GASF alcançou a maior coesão e separabilidade intrínseca ($s = 0,410$, $DB = 0,784$, tempo de 0,05 s), superando expressivamente o vetor 1D Euclidiano ($s = 0,311$, $DB = 1,028$, 0,06 s) e o alinhamento DTW com DBA ($s = 0,243$, $DB = 1,212$, 71,62 s). A transformação GADF produziu separabilidade semelhante ($s = 0,424$, $DB = 0,967$, 0,05 s), enquanto a codificação MTF obteve desempenho insatisfatório ($s = 0,064$, $DB = 3,116$, 0,80 s) pela supressão do gradiente contínuo na discretização em quantis. A fusão multicanal registrou $s = 0,200$, $DB = 1,502$ e 0,24 s, denotando dispersão de atributos. O processamento sobre os dois componentes do GASF consumiu apenas 0,05 segundos, estabelecendo uma aceleração superior a 1.400 vezes frente ao cálculo elástico do DTW.

C. Arquétipos de Depreciação e Validação Extrínseca

O particionamento no espaço GASF com $K = 4$ identificou quatro arquétipos temporais de retenção: Valorização Moderada (C_1, média de $+23,3\%$ aos 32 meses, 1.005 veículos), Depreciação Acelerada (C_2, média de $-13,6\%$, 1.624 veículos), Super-Valorização (C_3, média de $+39,6\%$, 338 veículos) e Estabilidade (C_4, média de $+5,7\%$, 1.490 veículos). O arquétipo C_2 reuniu 65,8% de todos os veículos elétricos da base (125 unidades) e 48,4% dos modelos híbridos, ao passo que C_3 não conteve nenhum modelo elétrico.

Os testes de validação extrínseca registraram $ARI = 0,012$, $NMI = 0,022$ e $V = 0,140$ para combustível, e $ARI = 0,012$, $NMI = 0,024$ e $V = 0,159$ para faixa de preço. Esses escores próximos de zero confirmam que o agrupamento não supervisionado não reproduz categorias cadastrais prévias, mas organiza os veículos pela dinâmica temporal de suas trajetórias.

A análise de variância bidirecional (2×5) sobre a variação líquida aos 32 meses indicou que o tipo de combustível responde por quase o dobro da variabilidade explicada frente ao estrato econômico ($SS = 142.704$ contra $SS = 73.614$, ambos com $p < 10^{-39}$). No estrato de Luxo, com veículos pareados no mesmo patamar de entrada, modelos elétricos registraram perda mediana de $-23,8\%$, enquanto modelos a gasolina obtiveram ganho de $+1,2\%$ e a diesel alcançaram $+12,1\%$. Essa diferença de 25 pontos percentuais confirma que a taxa de desvalorização decorre da tecnologia de propulsão e não do patamar de preço.

IV. Conclusão

Este estudo investigou a retenção de valor veicular durante a transição energética no Brasil por mineração de séries temporais. Em resposta à primeira questão de pesquisa, a desvalorização acelerada em veículos elétricos decorre da tecnologia de propulsão e não apenas do estrato de preço. Mais de 65% dos modelos elétricos concentram-se no grupo de desvalorização contínua, e o teste ANOVA comprovou a primazia do combustível sobre o estrato de mercado ($SS = 142.704$ contra $SS = 73.614$), registrando defasagem de 25 pontos percentuais frente a veículos a gasolina de mesmo valor inicial.

Em resposta à segunda questão de pesquisa, a transformação bidimensional GASF com PCA reduziu a dispersão dos dados e elevou o coeficiente de Silhueta de 0,311 para 0,410, viabilizando o agrupamento com rapidez computacional três ordens de grandeza superior ao método DTW. Como limitação metodológica, o corte temporal de 32 meses exclui modelos lançados muito recentemente. Trabalhos futuros devem estender o monitoramento para avaliar a consolidação das redes de reciclagem e substituição de baterias.

REFERÊNCIAS

[1] F. H. B. Alvarez, "Modelagem da aceitação de veículos elétricos considerando políticas de incentivo, consciência ambiental, inovação pessoal e auto-eficácia financeira: uma extensão ao utaut 2," Tese de Doutorado, Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio), 2024. [Online]. Available: https://www.maxwell.vrac.puc-rio.br/67544/67544.PDF

[2] L. Rush, Y. Zhou, and D. Gohlke, "Vehicle residual value analysis by powertrain type and impacts on total cost of ownership," Argonne National Laboratory, Tech. Rep. ANL/ESD-22/2 Rev. 1, 2022.

[3] K. Storchmann, "On the depreciation of automobiles: An international comparison," *Transportation*, vol. 31, no. 4, pp. 371–408, 2004.

[4] P. Gautam, G. Pode, R. Pode, G. K. Ayetor, and B. Diouf, "Depreciation in the electric vehicle transition: Sustainability of the second-hand electric vehicle market," *Vehicles*, vol. 6, no. 4, p. 101, 2024.

[5] L. Schloter, "Empirical analysis of the depreciation of electric vehicles compared to gasoline vehicles," *Transport Policy*, vol. 126, pp. 268–279, 2022.

[6] C. Li, C. Xu, T. An, M. Yu, and X. Xin, "The global electric vehicle (ev) industry price war: Implications for managerial decision-making," *Frontiers in Industry Economics and Management*, 2026.

[7] R. F. Silva, "Avaliação do impacto de barreiras para adoção de veículos elétricos na cidade de são paulo," Dissertação de Mestrado, Universidade Nove de Julho (UNINOVE), 2024. [Online]. Available: http://bibliotecatede.uninove.br/handle/tede/3569

[8] P.-N. Tan, M. Steinbach, A. Karpatne, and V. Kumar, *Introduction to Data Mining*, 2nd ed. Pearson Education, 2019.

[9] Z. Wang and T. Oates, "Imaging time-series to improve classification and imputation," in *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI)*, 2015, pp. 3939–3945.

[10] H. Sakoe and S. Chiba, "Dynamic programming algorithm optimization for spoken word recognition," *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 26, no. 1, pp. 43–49, 1978.

[11] J. Wu, "Imaging feature-based clustering of financial time series," *PLOS ONE*, vol. 18, no. 7, p. e0288836, 2023.

[12] J. Silva, "fipex-veiculos-brasil: Histórico de preços da tabela fipe," Hugging Face Datasets, 2024.

[13] D. Arthur and S. Vassilvitskii, "k-means++: the advantages of careful seeding," in *Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*, 2007, pp. 1027–1035.

[14] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," in *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD)*, 1996, pp. 226–231.

[15] P. J. Rousseeuw, "Silhouettes: a graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.

[16] D. L. Davies and D. W. Bouldin, "A cluster separation measure," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. PAMI-1, no. 2, pp. 224–227, 1979.