Caracterização de Padrões de Depreciação Automotiva sob a Transição Energética

Gabriel Martins Brum
Departamento de Ciência da Computação e Estatística
Universidade Estadual Paulista (UNESP)
São José do Rio Preto, Brasil
g.brum@unesp.br

***Resumo*—A transição para a mobilidade elétrica introduz incertezas na precificação de seminovos decorrentes da perda de capacidade de baterias, rápida evolução técnica e guerras comerciais de preços. Este artigo investiga a desvalorização veicular no Brasil a partir de microdados da base fipeX, analisando a preponderância da matriz energética frente ao estrato econômico e a eficácia da codificação de séries temporais em matrizes bidimensionais via Gramian Angular Fields. A metodologia emprega a Taxa de Retenção de Valor ao longo de 32 meses com 4.457 trajetórias, redução dimensional por PCA e agrupamento via K-Means e DBSCAN. A representação GASF proporcionou ganho de silhueta e aceleração computacional frente ao alinhamento elástico DTW. A análise estatística confirmou que a desvalorização acelerada decorre prioritariamente da propulsão elétrica, registrando defasagem de 25 pontos percentuais frente a modelos convencionais de mesmo estrato.**

***Index Terms*—Mineração de Séries Temporais, Veículos Elétricos, Reshaping, Agrupamento, Depreciação Automotiva.**

I. Introdução

O mercado automotivo atravessa um processo de reorganização tecnológica impulsionado pela expansão de veículos elétricos e híbridos no Brasil e no cenário internacional [1]. A especulação em torno da desvalorização desses ativos constitui um entrave à aquisição no mercado de seminovos, elevando a incerteza quanto ao custo total de posse [2]. Automóveis equipados com motores a combustão interna apresentam trajetórias de depreciação consolidadas e amortecidas em função da idade do bem [3]. Em contrapartida, veículos eletrificados enfrentam fatores depreciativos particulares, tais como a perda de capacidade de armazenamento das baterias de íons de lítio e a rápida substituição por modelos de maior autonomia [4]. A avaliação empírica sobre mercados internacionais apurou depreciação média anual de 13,9% para elétricos, superando a taxa de 10,4% de modelos convencionais a gasolina [5]. A literatura concentra-se prioritariamente em economias desenvolvidas, subsistindo uma lacuna empírica sobre a dinâmica do mercado brasileiro sob a transição energética recente [6], [7].

No campo analítico, abordagens tradicionais representam séries temporais como vetores unidimensionais com distâncias Euclidianas sensíveis a ruídos locais, enquanto o algoritmo Dynamic Time Warping (DTW) introduz elevado custo computacional e distorções que atenuam choques macroeconômicos síncronos [8]. A conversão de séries temporais em matrizes bidimensionais via Gramian Angular Summation Field (GASF), Gramian Angular Difference Field (GADF) e Markov Transition Field (MTF) agrega atributos intrínsecos e aprimora partições não supervisionadas [9], [10]. Este trabalho investiga duas questões centrais de pesquisa: (i) se a inserção de veículos elétricos induz desvalorização relativa mais acelerada em comparação a veículos convencionais de mesmo estrato econômico inicial, ou se o padrão observado decorre da faixa de preço do bem, e (ii) se a codificação de séries temporais em matrizes bidimensionais projetadas via PCA produz agrupamentos com maior coesão e separabilidade intrínseca frente a métricas vetoriais clássicas. Como contribuições, o estudo caracteriza a retenção veicular ao longo de 32 meses na base fipeX, comprova estatisticamente a primazia da matriz energética por pareamento e análise de variância, e valida a eficiência da codificação GASF frente ao alinhamento elástico.

II. Materiais e Métodos

O procedimento metodológico compreendeu a preparação dos dados, o cômputo da retenção de valor, a codificação matricial bidimensional e o agrupamento com validação estatística.

A. Base de Dados FipeX e Pré-Processamento

Os dados foram obtidos do repositório público fipeX, reunindo o histórico de preços médios mensais apurados pela Fundação Instituto de Pesquisas Econômicas (FIPE) entre 2001 e 2026 [11]. A base original de 9.276.121 registros foi filtrada para isolar automóveis de passeio lançados a partir de 2019 com acompanhamento contínuo por uma janela de $T = 32$ meses (2,6 anos). Foram removidas duplicatas, utilitários pesados, modelos com defasagem cadastral superior a um ano e combustíveis com participação residual, correspondendo à exclusão de 60,2% dos registros. A evolução dos preços foi quantificada pela Taxa de Retenção de Valor (VRR), calculada pela razão $VRR_{i,t} = P_{i,t}/P_{i,0}$ entre a cotação no mês t e o preço de lançamento no mês zero, eliminando a magnitude nominal da moeda. A amostra resultante contém 4.457 trajetórias temporais completas, englobando 1.756 veículos Flex (39,4%), 1.258 a Gasolina (28,2%), 871 a Diesel (19,5%), 382 Híbridos (8,6%) e 190 Elétricos (4,3%). Os estratos econômicos foram delimitados pelos quartis de lançamento: Entrada ($P_0 \leq$ R\$ 82.998), Intermediário (R\$ $82.998 < P_0 \leq$ R\$ 325.283) e Luxo ($P_0 >$ R\$ 325.283).

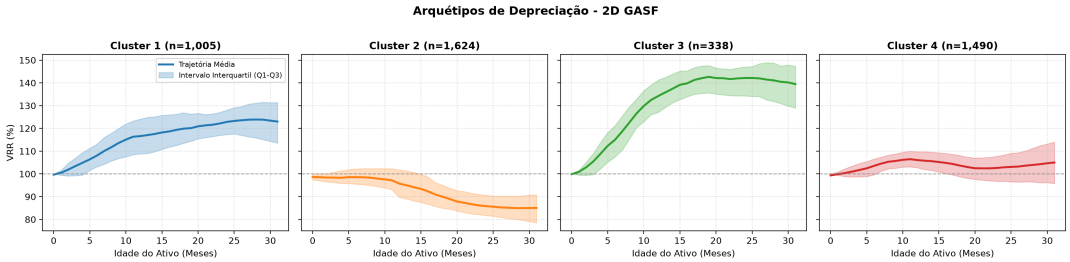


Figura 1. Trajetórias temporais médias e dispersão interquartil (Q1–Q3) dos quatro arquétipos comportamentais descobertos no espaço latente GASF com $K = 4$.

B. Codificação Bidimensional e Redução Dimensional

As trajetórias de retenção de valor foram convertidas em matrizes de dimensão 32×32 pelo método de Wang e Oates [9]. Cada série normalizada no intervalo $[-1, 1]$ foi projetada em coordenadas polares com ângulo $\phi_t = \arccos(\widetilde{VRR}_t)$ e raio $r_t = t/T$. A matriz Gramian Angular Summation Field (GASF) foi gerada pela soma cosseno $G_{(i,j)} = \cos(\phi_i + \phi_j)$, preservando correlações temporais e valores médios da série. A matriz Gramian Angular Difference Field (GADF) foi calculada pela diferença seno $D_{(i,j)} = \sin(\phi_i - \phi_j)$, capturando taxas instantâneas de variação. A matriz Markov Transition Field (MTF) foi obtida pela discretização em cinco quantis de amplitude, computando probabilidades de transição estocástica de primeira ordem entre os passos temporais. Para atenuar a dimensionalidade de 1.024 atributos por canal, a técnica de Análise de Componentes Principais (PCA) foi aplicada retendo 95% da variância acumulada, resultando em 2 componentes para o GASF e 5 para o GADF [12].

C. Modelagem de Agrupamento e Protocolo de Validação

O algoritmo K-Means foi executado com inicialização K-Means++ variando $K \in [2, 7]$ sobre o espaço 1D Euclidiano, sobre o alinhamento temporal DTW com média Barcellona (DBA) e sobre os espaços latentes gerados pelas imagens 2D via PCA [8], [13]. O algoritmo DBSCAN também foi avaliado com ε definido pelo ponto de inflexão das curvas de k-distâncias para $MinPts = 5$ [14]. A validação intrínseca das partições foi realizada pelo coeficiente de Silhueta médio e pelo índice Davies-Bouldin [15], [16]. A validação extrínseca avaliou a aderência às categorias cadastrais de combustível e estrato de preço por ARI, NMI e coeficiente V de Cramér. O efeito isolado da tecnologia de propulsão e da faixa de preço sobre a variação líquida aos 32 meses ($\Delta VRR = VRR_{32m} - VRR_{0m}$) foi quantificado por análise de variância (ANOVA) bidirecional (2×5).

III. Resultados e Discussão

A. Análise Exploratória e Pareamento de Segmentos

A análise das 4.457 trajetórias evidenciou comportamento atípico no mercado nacional entre 2019 e 2026. Em contraposição ao padrão histórico de desvalorização contínua, automóveis a combustão registraram valorização nominal motivada por restrições na cadeia global de suprimentos, atingindo retenção média superior a 115% em modelos Flex e Diesel aos 24 meses. Em sentido oposto, veículos elétricos exibiram desvalorização monotônica. Como 93,2% dos elétricos pertencem aos estratos Intermediário e de Luxo (mediana de R$ 322.000,00) e 75,5% dos modelos Flex integram o estrato de Entrada (mediana de R$ 77.000,00), o pareamento intra-estrato foi estabelecido para isolar o combustível da magnitude do investimento inicial.

B. Eficácia Comparativa das Representações

O particionamento pelo algoritmo K-Means evidenciou a superioridade da representação matricial 2D, conforme os coeficientes de Silhueta apresentados na Figura 2. Para a partição com quatro grupos ($K = 4$), a projeção GASF alcançou a maior coesão e separabilidade intrínseca ($s = 0,410$, $DB = 0,784$, tempo de 0,05 s), superando o vetor 1D Euclidiano ($s = 0,311$, $DB = 1,028$, 0,06 s) e o alinhamento elástico DTW ($s = 0,243$, $DB = 1,212$, 71,62 s). A codificação GADF alcançou separabilidade comparável ($s = 0,424$, $DB = 0,967$, 0,05 s), enquanto a técnica MTF apresentou dispersão ($s = 0,064$, $DB = 3,116$, 0,80 s) pela perda do gradiente contínuo na quantização. O processamento sobre os componentes principais do GASF atingiu velocidade 1.400 vezes superior à distância DTW.

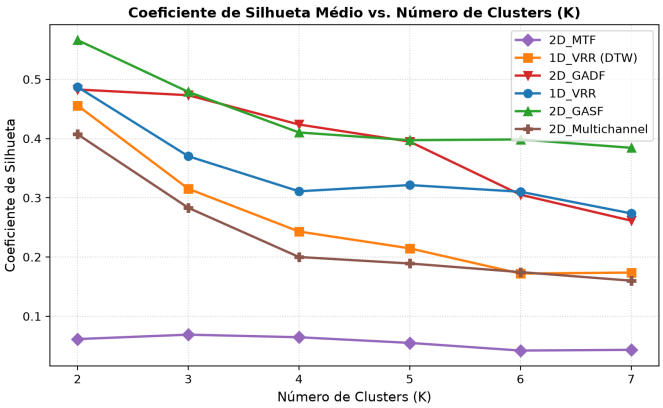


Figura 2. Coeficiente de Silhueta médio para $K \in [2, 7]$ entre as representações vetoriais 1D e os espaços latentes 2D reduzidos via PCA.

C. Arquétipos de Depreciação e Validação Extrínseca

O agrupamento no espaço latente GASF com $K = 4$ identificou quatro arquétipos comportamentais de retenção de valor, cujas características estão sintetizadas na Tabela I e cujas trajetórias temporais são exibidas na Figura 1. O arquétipo de Depreciação Acelerada (C_2) concentrou 65,8% de todos os veículos elétricos da base (125 unidades) e 48,4% dos modelos híbridos, enquanto o grupo de Super-Valorização (C_3) não continha nenhum modelo elétrico. Os testes extrínsecos registraram escores reduzidos ($ARI = 0,012$, $NMI = 0,022$ e $V = 0,140$ para combustível, bem como $ARI = 0,012$, $NMI = 0,024$ e $V = 0,159$ para faixa de preço), confirmando que a modelagem não replica divisões prévias, mas organiza os dados pela dinâmica temporal real das curvas.

Tabela I
CARACTERIZAÇÃO DOS ARQUÉTIPOS DE DEPRECIAÇÃO ($K = 4$, GASF + PCA)

Grupo	Perfil Temporal	N (%)	$\Delta\mathbf{VRR_{32m}}$	% EV	% Híb.
C_1	Valorização Moderada	1.005 (22,5%)	$+23,3\%$	6,3%	14,4%
C_2	Depreciação Acelerada	1.624 (36,4%)	$-13,6\%$	65,8%	48,4%
C_3	Super-Valorização	338 (7,6%)	$+39,6\%$	0,0%	0,5%
C_4	Estabilidade	1.490 (33,4%)	$+5,7\%$	27,9%	36,6%

A decomposição pela ANOVA bidirecional sobre o ΔVRR aos 32 meses indicou que a matriz energética responde por quase o dobro da variabilidade explicada frente ao estrato econômico ($SS = 142.704$ contra $SS = 73.614$, ambos com $p < 10^{-39}$). No estrato de Luxo, com ativos de mesmo patamar de entrada, modelos elétricos registraram perda mediana de $-23,8\%$, ao passo que veículos a gasolina obtiveram ganho de $+1,2\%$ e a diesel alcançaram $+12,1\%$. Essa diferença de 25 pontos percentuais confirma que a desvalorização acelerada decorre da tecnologia de propulsão e não do valor do veículo.

IV. CONCLUSÃO

Este trabalho investigou a dinâmica de depreciação veicular sob a transição energética no Brasil por mineração de séries temporais. Em resposta à primeira questão de pesquisa, a desvalorização acelerada observada em veículos elétricos decorre da tecnologia de propulsão e não do patamar de preço. Mais de 65% dos modelos elétricos concentram-se no grupo de desvalorização contínua, e a análise de variância comprovou o predomínio do combustível sobre a faixa econômica ($SS = 142.704$ contra $SS = 73.614$), gerando defasagem de 25 pontos percentuais frente a veículos a gasolina no mesmo estrato de luxo.

Em resposta à segunda questão de pesquisa, a codificação matricial bidimensional GASF combinada ao PCA aprimorou a separabilidade dos grupos, elevando o coeficiente de Silhueta de 0,311 para 0,410 e viabilizando o agrupamento com velocidade computacional três ordens de grandeza superior ao método DTW. Como limitação metodológica, o horizonte de 32 meses restringe a análise a safras recentes. Investigações futuras devem acompanhar a evolução dos custos de substituição de baterias e os reflexos de novas políticas industriais sobre o valor residual.

REFERÊNCIAS

[1] F. H. B. Alvarez, "Modelagem da aceitação de veículos elétricos considerando políticas de incentivo, consciência ambiental, inovação pessoal e auto-eficácia financeira: uma extensão ao utaut 2," Tese de Doutorado, Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio), 2024.

[2] L. Rush, Y. Zhou, and D. Gohlke, "Vehicle residual value analysis by powertrain type and impacts on total cost of ownership," Argonne National Laboratory, Tech. Rep. ANL/ESD-22/2 Rev. 1, 2022.

[3] K. Storchmann, "On the depreciation of automobiles: An international comparison," *Transportation*, vol. 31, no. 4, pp. 371–408, 2004.

[4] P. Gautam, G. Pode, R. Pode, G. K. Ayetor, and B. Diouf, "Depreciation in the electric vehicle transition: Sustainability of the second-hand electric vehicle market," *Vehicles*, vol. 6, no. 4, p. 101, 2024.

[5] L. Schloter, "Empirical analysis of the depreciation of electric vehicles compared to gasoline vehicles," *Transport Policy*, vol. 126, pp. 268–279, 2022.

[6] C. Li, C. Xu, T. An, M. Yu, and X. Xin, "The global electric vehicle (ev) industry price war: Implications for managerial decision-making," *Frontiers in Industry Economics and Management*, 2026.

[7] R. F. Silva, "Avaliação do impacto de barreiras para adoção de veículos elétricos na cidade de são paulo," Dissertação de Mestrado, Universidade Nove de Julho (UNINOVE), 2024.

[8] H. Sakoe and S. Chiba, "Dynamic programming algorithm optimization for spoken word recognition," *IEEE Trans. Acoust., Speech, Signal Process.*, vol. 26, no. 1, pp. 43–49, 1978.

[9] Z. Wang and T. Oates, "Imaging time-series to improve classification and imputation," in *Proc. 24th IJCAI*, 2015, pp. 3939–3945.

[10] J. Wu, "Imaging feature-based clustering of financial time series," *PLOS ONE*, vol. 18, no. 7, p. e0288836, 2023.

[11] J. Silva, "fipex-veiculos-brasil: Histórico de preços da tabela fipe," Hugging Face Datasets, 2024.

[12] P.-N. Tan, M. Steinbach, A. Karpatne, and V. Kumar, *Introduction to Data Mining*, 2nd ed. Pearson, 2019.

[13] D. Arthur and S. Vassilvitskii, "k-means++: the advantages of careful seeding," in *Proc. 18th SODA*, 2007, pp. 1027–1035.

[14] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," in *Proc. 2nd KDD*, 1996, pp. 226–231.

[15] P. J. Rousseeuw, "Silhouettes: a graphical aid to the interpretation and validation of cluster analysis," *J. Comput. Appl. Math.*, vol. 20, pp. 53–65, 1987.

[16] D. L. Davies and D. W. Bouldin, "A cluster separation measure," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. PAMI-1, no. 2, pp. 224–227, 1979.