Caracterização de Padrões de Depreciação Automotiva sob a Transição Energética: Uma Abordagem Baseada em Representação Espacial de Séries Temporais

Gabriel M. Brum

2026

Resumo

Este trabalho investiga as dinâmicas temporais de depreciação de veículos automotores a partir do conjunto de dados fipeX , com foco no impacto da inserção de veículos elétricos (EVs) no mercado brasileiro frente aos modelos convencionais a combustão interna . Metodologicamente, o estudo aborda três questões centrais: (i) a verificação de assimetrias estatísticas nas taxas de depreciação entre elétricos e a combustão de mesma faixa de valor; (ii) a análise de co-movimento e efeitos de transbordamento decorrentes de guerras de preços e marcas entrantes ; e (iii) a avaliação comparativa entre a clusterização em séries temporais 1D tradicionais e representações bidimensionais geradas via *Gramian Angular Field* (GAF) e *Markov Transition Field* (MTF). A proposta visa unir a caracterização econômica de novos ativos à exploração de representações espaciais como estratégia de transformação de atributos em tarefas de mineração de dados não supervisionadas.

1 Introdução

O mercado automotivo global e brasileiro atravessa uma transição tecnológica impulsionada pela entrada acelerada de Veículos Elétricos (EVs) [2]. Diferente dos veículos a combustão interna (ICE), cujo comportamento de depreciação histórica é consolidado e linearizado pela idade do bem, os modelos eletrificados introduzem variáveis de incerteza operacional: degradação acelerada de baterias, rápida obsolescência tecnológica, políticas tarifárias voláteis e guerras de preços [3, 5].

Compreender e segmentar essas trajetórias temporais não é apenas uma demanda mercadológica de precificação e análise de risco para seguradoras e instituições financeiras; constitui um problema clássico de *Data Mining* voltado à mineração de séries temporais (*time-series mining*) e descoberta de padrões em dados ordenados. Métodos convencionais frequentemente achatam as curvas históricas ou dependem de distâncias euclidianas 1D que falham em capturar dinâmicas não lineares, flutuações sazonais e correlações defasadas entre segmentos concorrentes [7]. Embora medidas de similaridade elásticas específicas para esse tipo de dado, como o *Dynamic Time Warping* (DTW), ofereçam maior flexibilidade ao alinhar sequências defasadas temporalmente, elas ainda operam no domínio unidimensional e frequentemente apresentam alto custo computacional em grandes volumes de dados.

A representação convencional de séries temporais como vetores unidimensionais impõe limitações analíticas severas ao processo de mineração de dados, restringindo os algoritmos de agrupamento a métricas de distância altamente suscetíveis a variações de escala. Essa restrição metodológica fundamenta a necessidade de investigar transformações de atributos mais robustas, avaliando se representações bidimensionais geradas por *Gramian Angular Fields* (GAF) ou *Markov Transition Fields* (MTF) são capazes de codificar correlações cruzadas e dependências dinâmicas que escapam às métricas clássicas, como a distância Euclidiana e o DTW [10, 9].

Sob o ponto de vista da modelagem estatística e do aprendizado de máquina, o estudo se justifica ao contrapor a eficácia de espaços latentes extraídos dessas imagens frente a métodos tradicionais de redução de dimensionalidade e seleção de atributos. A aplicação de matrizes GAF/MTF permite transpor o problema de dados tabulares temporais para o domínio de operadores de extração de padrões espaciais, abrindo caminho para testar se técnicas de aprendizado não supervisionado se beneficiam da preservação topológica dessas transformações [4]. Com isso, o trabalho estabelece um teste empírico controlado para mensurar se a complexidade adicional dessa projeção espacial se traduz, de fato, em *clusters* mais coesos e discriminantes do que os obtidos via abordagens vetoriais convencionais.

Por fim, o trabalho preenche uma lacuna relevante na análise de fenômenos de mercado ao estruturar a descoberta de padrões de desvalorização e possíveis efeitos de transbordamento decorrentes da chegada dos veículos elétricos e das montadoras chinesas [6, 1]. Ao analisar o co-movimento de preços entre matrizes energéticas concorrentes, a pesquisa vai além do agrupamento meramente exploratório e fornece um protocolo experimental rigoroso baseado em técnicas consolidadas de pré-processamento, mitigação do impacto de *outliers* e validação de modelos. Dessa forma, a investigação entrega simultaneamente uma contribuição teórica sobre representação de dados ordenados na mineração de dados e uma ferramenta descritiva aplicada para precificação e gestão de risco sobre ativos automotivos.

2 Objetivos

- **Mapear e quantificar as taxas de depreciação dos veículos elétricos:** Mensurar a velocidade e amplitude da perda de valor dos modelos eletrificados em comparação direta a veículos a combustão pareados por porte, categoria e faixa de preço de lançamento [7].
- **Avaliar o efeito de transbordamento (*spillover*) de marcas entrantes:** Analisar correlações temporais e possíveis quebras estruturais de preços em segmentos tradicionais após a introdução e guerra tarifária promovida por montadoras chinesas no mercado nacional [5, 6].
- **Implementar e validar o *reshaping* de séries temporais em imagens 2D:** Transformar as trajetórias unidimensionais de preços de cada veículo em representações matriciais utilizando algoritmos como *Gramian Angular Field* (GAF) ou *Markov Transition Field* (MTF) [10, 4].
- **Identificar e caracterizar arquétipos de desvalorização veicular:** Aplicar algoritmos de agrupamento (*clustering*) sobre representações vetoriais clássicas e sobre os espaços latentes gerados a partir das imagens, identificando perfis comportamentais típicos (alta retenção, desvalorização acelerada, valorização tardia).
- **Comparar empiricamente a eficácia das representações:** Avaliar quantitativamente, por meio de métricas de qualidade de agrupamento (como coeficiente de Silhueta e índice Davies-Bouldin), se a transformação das séries para imagem supera as abordagens vetoriais unidimensionais tradicionais, adotando a distância Euclidiana e o *Dynamic Time Warping* (DTW) como *baselines* de comparação.

3 Atividades

- **Atividade 1:** Coleta, limpeza e pré-processamento dos dados, tratamento de inconsistências/valores ausentes e estruturação temporal dos registros da base fipeX por veículo.
- **Atividade 2:** Análise exploratória e pareamento comparativo visualização das trajetórias de depreciação, cálculo de estatísticas descritivas e pareamento dos modelos elétricos com equivalentes a combustão para identificação de padrões preliminares.
- **Atividade 3:** Transformação e representação espacial (*reshaping*), realizando a codificação das séries temporais 1D em representações matriciais 2D utilizando as técnicas de GAF e MTF.
- **Atividade 4:** Modelagem de agrupamento e extração de padrões aplicação e ajuste dos algoritmos de *clustering* (K-Means e abordagens baseadas em densidade) sobre as representações geradas por imagem e sobre os dados vetoriais clássicos (empregando as medidas Euclidiana e DTW como *baselines*).
- **Atividade 5:** Avaliação experimental, interpretação e escrita final com o cálculo das métricas de validação de agrupamento, análise dos arquétipos comportamentais descobertos e consolidação dos resultados no artigo final.

4 Resultados

Nesta seção serão apresentados os resultados das etapas iniciais da pesquisa, focados na higienização, transformação e redução do escopo analítico dos dados.

4.1 Atividade 1: Pré-processamento e Limpeza de Dados

A base de dados bruta (fipeX) foi carregada contendo originalmente mais de 9,2 milhões de registros. Como etapa inicial de limpeza estrutural, instâncias inteiramente duplicadas e registros com o atributo `valor_centavos` igual a zero foram removidos. O escopo do projeto foi então restrito ao segmento de interesse, aplicando-se um filtro para manter apenas os registros com `tipo_veiculo` correspondente a carros, o que reduziu a base para aproximadamente 3,3 milhões de instâncias.

Para viabilizar a análise de séries temporais, os atributos de `ano_referencia` e `mes_referencia` foram agregados em uma única variável `data_referencia`. Além disso, realizou-se a seleção de atributos (*feature selection*) descartando colunas redundantes, como `valor_formatado` e `nome_combustivel`.

Durante o pré-processamento, observou-se que uma quantidade expressiva de registros referentes a veículos novos (Zero KM) apresentava valores ausentes na coluna `ano_modelo`, um artefato do formato textual da Tabela FIPE. Para evitar o descarte sumário desses registros e a consequente perda do preço base de lançamento — ponto de partida fundamental ($t = 0$) para a construção das séries temporais de depreciação —, aplicou-se uma técnica de imputação baseada em conhecimento de domínio [8]. O `ano_modelo` desses veículos foi inferido e preenchido com o ano correspondente extraído da sua `data_referencia`. Tal procedimento assegura o alinhamento de fase e a correta ancoragem da idade inicial do ativo em zero, eliminando o viés de seleção que ocorreria caso todos os preços de lançamento fossem excluídos do *dataset*.

4.2 Atividade 2: Análise Exploratória e Redução de Escopo

Para garantir a coesão das séries temporais e evitar vieses macroeconômicos e mercadológicos, foram aplicadas heurísticas de filtragem baseadas na exploração visual e quantitativa dos dados. A Figura 1 ilustra a distribuição logarítmica das avaliações ao longo do tempo separadas por matriz energética, enquanto a Figura 2 apresenta a densidade populacional baseada na idade calculada de cada veículo no momento de sua cotação.

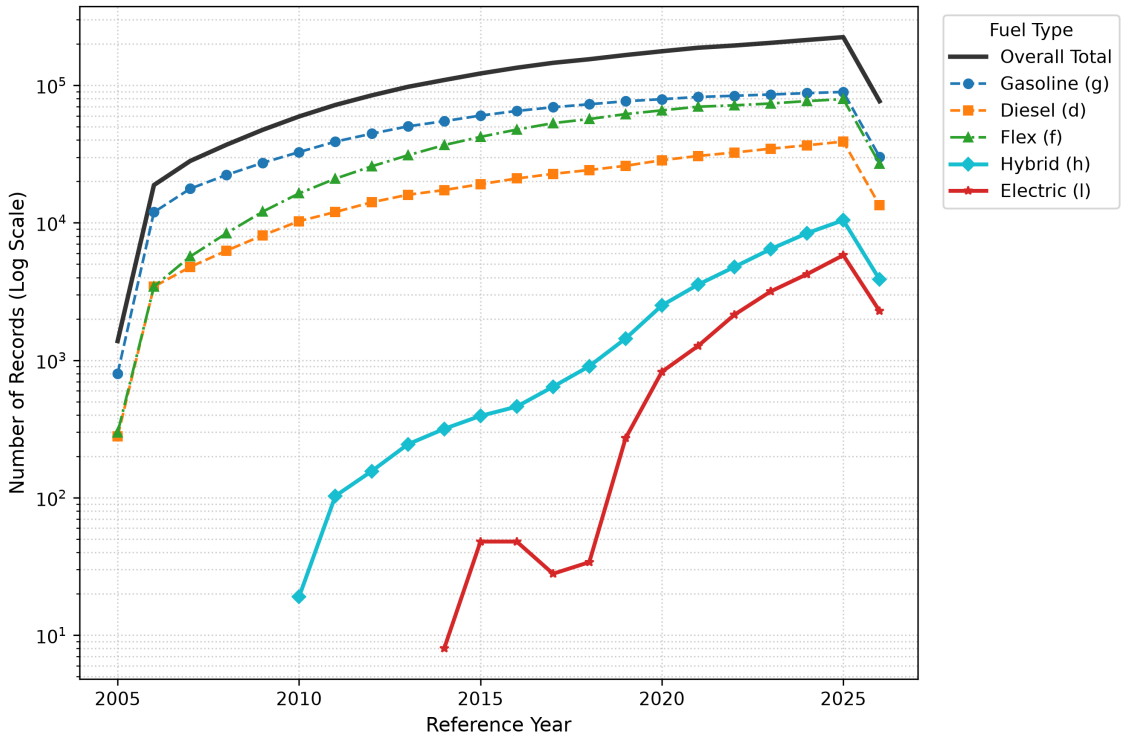


Figura 1: Distribuição temporal logarítmica da quantidade de registros por tipo de combustível (escala logarítmica).

Analisando a distribuição de marcas e combustíveis, identificou-se que veículos movidos a gás natural e álcool puro possuíam uma representatividade marginal e falta de variedade de montadoras. Por conta disso, decidiu-se remover essas categorias, visto que a diversidade da frota é um fator de controle crítico na análise comparativa de depreciação [7].

Para evitar o viés de acúmulo temporal (onde veículos antigos parecem ter um portfólio maior simplesmente por estarem há mais meses na base), a relevância das montadoras foi men-

surada contando-se os modelos de veículos estritamente únicos (`codigo_fipe` + `ano_modelo` + `sigla_combustivel`). Definiu-se o seguinte critério de corte: foram mantidas na base apenas as marcas que apresentassem um portfólio superior a 30 veículos únicos no total ou que possuíssem, no mínimo, 15 veículos únicos eletrificados (elétricos e híbridos). Esta abordagem com múltiplos limiares justifica-se pela necessidade de tratar distribuições de frequência assimétricas em tarefas de mineração de dados, garantindo que classes raras de alto interesse — neste caso, os veículos eletrificados e as montadoras entrantes — sejam adequadamente representadas [8]. O limiar de volume atua na filtragem de ruídos, enquanto a regra de exceção preserva as montadoras recentes como *outliers* legítimos, assegurando densidade sem distorcer os padrões subjacentes [8].

Para evitar que o modelo compare o comportamento econômico de carros a combustão da década de 1990 com elétricos de 2020, o escopo foi restringido a uma idade máxima de 20 anos. Os veículos cujo `ano_modelo` era inferior ao corte estipulado (lançados há mais de 20 anos) foram removidos, garantindo que a análise de *spillover* ocorra num cenário mercadológico e tecnológico equiparável. A partir das amostras filtradas, separando cada faixa etária dos veículos e dentre elas separando os tipos de combustíveis de cada veículo, foi obtido os resultados apresentados na Figura 2.

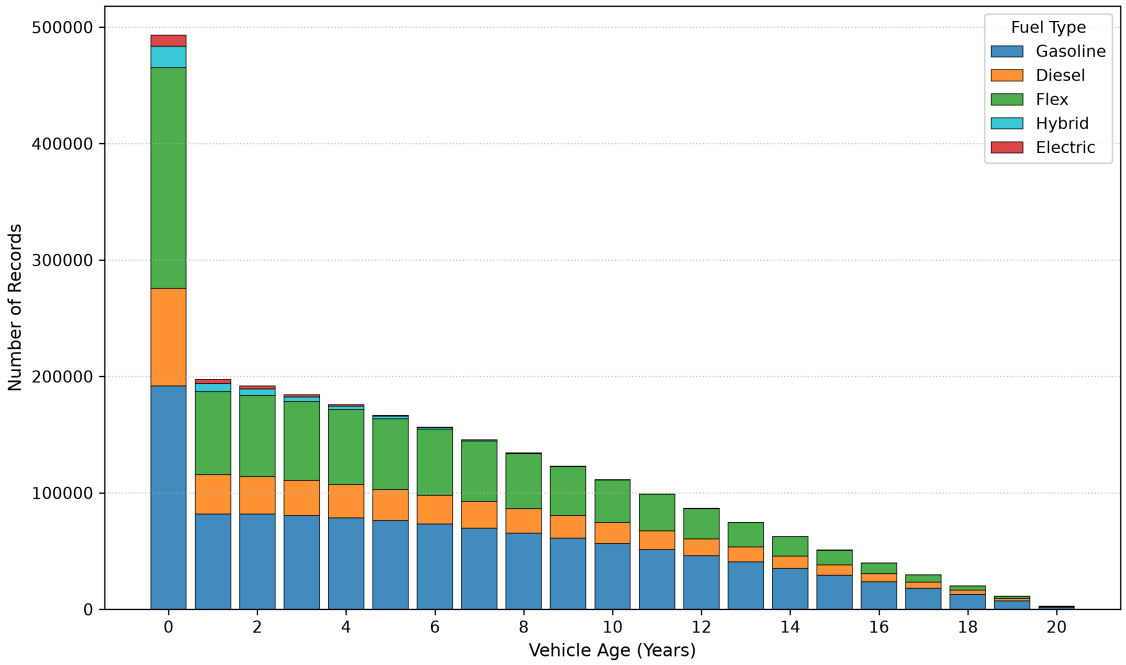


Figura 2: Gráfico de barras empilhadas que apresenta a distribuição de registros por idade do veículo em anos, estratificada por tipo de combustível.

4.2.1 Etapas Pendentes da Atividade 2: Retenção de Valor e Pareamento Comparativo

Apesar da consolidação do escopo de dados e do alinhamento temporal das coortes, a conclusão da Atividade 2 exige a execução de três etapas analíticas adicionais focadas na caracterização econômica e financeira dos ativos automotivos:

- **Cálculo da Retenção de Valor (Normalização):** Para viabilizar a comparação justa de desvalorização entre veículos de diferentes categorias e faixas de preço, os valores absolutos de cotação (em centavos) devem ser normalizados. Será estipulada a taxa de retenção percentual de cada veículo único, em que o preço de lançamento (quando a idade $t = 0$) representará 100% do valor de face. As idades subsequentes ($t = 1, t = 2, \dots$) refletirão a proporção desse valor original retido pelo mercado ao longo do tempo.
- **Visualização das Trajetórias Médias de Depreciação:** A partir dos dados normalizados, serão geradas e analisadas as curvas médias de depreciação agregadas por matriz energética. A projeção da idade do veículo contra a sua taxa de retenção média permitirá a identificação de assimetrias macroeconômicas preliminares, verificando de forma exploratória se os Veículos Elétricos (EVs) e Híbridos (HEVs) apresentam, de fato, um decaimento

mais acentuado ou instável nos primeiros anos de uso em comparação à média dos veículos a Combustão Interna (ICE).

- **Pareamento Comparativo (*Matching*):** Dado que o portfólio de veículos eletrificados concentra-se predominantemente nos segmentos *premium* e de alta tecnologia, compará-lo diretamente à média geral da frota a combustão introduziria um forte viés de categoria. Para contornar este problema e isolar a variável da matriz energética, será aplicado um método de pareamento empírico (*matching*) [7]. Pares de modelos equivalentes e competidores diretos no mercado brasileiro (por exemplo, *hatches* ou SUVs compactos com propostas comerciais semelhantes) serão pareados e suas curvas de depreciação analisadas individualmente. Este controle metodológico garante que variações na perda de valor sejam atribuídas à motorização tecnológica e não a fatores extrínsecos de segmento.

A finalização destas análises descritivas consolidará a base empírica e a estrutura relacional das séries temporais unidimensionais, fornecendo os vetores de depreciação padronizados que serão posteriormente transformados em representações espaciais (GAF e MTF) na Atividade 3.

Referências

[1] L. Abrardi. Market structure and competitive dynamics of electric vehicle in europe. Master's thesis, Politecnico di Torino, 2026.

[2] F. H. B. Alvarez. *Modelagem da Aceitação de Veículos Elétricos considerando Políticas de Incentivo, Consciência Ambiental, Inovação Pessoal e Auto-eficácia Financeira: uma Extensão ao UTAUT 2*. Tese de doutorado, Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio), 2024.

[3] P. Gautam, G. Pode, R. Pode, G. K. Ayetor, and B. Diouf. Depreciation in the electric vehicle transition: Sustainability of the second-hand electric vehicle market. *Vehicles*, 6(4):101, 2024.

[4] Jayson C. Jueco et al. Performance analysis of time series-to-image encoding across different clustering methods for labeling anomalous load data in selected visayas subgrids. In *2024 IEEE Region 10 Conference (TENCON)*. IEEE, 2024.

[5] Changjun Li, Congmei Xu, Tongtong An, Mengcheng Yu, and Xiangjian Xin. The global electric vehicle (ev) industry price war: Implications for managerial decision-making. *Frontiers in Industry Economics and Management*, 2026.

[6] Shanjun Li et al. The rise of electric vehicles in china: Growth, challenges and future prospects. In *The Great Energy Transformation in China*, page 109. ANU Press, 2025.

[7] L. Schloter. Empirical analysis of the depreciation of electric vehicles compared to gasoline vehicles. *Transport Policy*, 126:268–279, 2022.

[8] Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, and Vipin Kumar. *Introduction to Data Mining*. Pearson Education, 2nd, global edition edition, 2019.

[9] Stepan Ulyanin, Jose R. Vazquez-Canteli, and Zoltan Nagy. Feature extraction and clustering of building energy profiles encoded as images. In *Proceedings of Building Simulation 2019: 16th Conference of IBPSA*, volume 16, pages 2108–2115. IBPSA, 2019.

[10] J. Wu. Imaging feature-based clustering of financial time series. *PLOS ONE*, 18(7):e0288836, 2023.