Caracterização de Padrões de Depreciação Automotiva sob a Transição Energética: Uma Abordagem Baseada em Representação Espacial de Séries Temporais

Gabriel M. Brum

2026

Resumo

Este trabalho investiga as dinâmicas temporais de depreciação de veículos automotores a partir do conjunto de dados fipeX, com foco no impacto da inserção de veículos elétricos (EVs) no mercado brasileiro frente aos modelos convencionais a combustão interna. Metodologicamente, o estudo aborda três questões centrais: (i) a verificação de assimetrias estatísticas nas taxas de depreciação entre elétricos e a combustão de mesma faixa de valor; (ii) a análise de co-movimento e efeitos de transbordamento decorrentes de guerras de preços e marcas entrantes; e (iii) a avaliação comparativa entre a clusterização em séries temporais 1D tradicionais e representações bidimensionais geradas via *Gramian Angular Field* (GAF) e *Markov Transition Field* (MTF). A proposta visa unir a caracterização econômica de novos ativos à exploração de representações espaciais como estratégia de transformação de atributos em tarefas de mineração de dados não supervisionadas.

1 Introdução

O mercado automotivo global e brasileiro atravessa uma transição tecnológica impulsionada pela entrada acelerada de Veículos Elétricos (EVs) [2]. Diferente dos veículos a combustão interna (ICE), cujo comportamento de depreciação histórica é consolidado e linearizado pela idade do bem, os modelos eletrificados introduzem variáveis de incerteza operacional: degradação acelerada de baterias, rápida obsolescência tecnológica, políticas tarifárias voláteis e guerras de preços [3, 6].

Compreender e segmentar essas trajetórias temporais não é apenas uma demanda mercadológica de precificação e análise de risco para seguradoras e instituições financeiras; constitui um problema clássico de *Data Mining* voltado à mineração de séries temporais (*time-series mining*) e descoberta de padrões em dados ordenados. Métodos convencionais frequentemente achatam as curvas históricas ou dependem de distâncias euclidianas 1D que falham em capturar dinâmicas não lineares, flutuações sazonais e correlações defasadas entre segmentos concorrentes [9]. Embora medidas de similaridade elásticas específicas para esse tipo de dado, como o *Dynamic Time Warping* (DTW), ofereçam maior flexibilidade ao alinhar sequências defasadas temporalmente, elas ainda operam no domínio unidimensional e frequentemente apresentam alto custo computacional em grandes volumes de dados.

A representação convencional de séries temporais como vetores unidimensionais impõe limitações analíticas severas ao processo de mineração de dados, restringindo os algoritmos de agrupamento a métricas de distância altamente suscetíveis a variações de escala. Essa restrição metodológica fundamenta a necessidade de investigar transformações de atributos mais robustas, avaliando se representações bidimensionais geradas por *Gramian Angular Fields* (GAF) ou *Markov Transition Fields* (MTF) são capazes de codificar correlações cruzadas e dependências dinâmicas que escapam às métricas clássicas, como a distância Euclidiana e o DTW [12, 11].

Sob o ponto de vista da modelagem estatística e do aprendizado de máquina, o estudo se justifica ao contrapor a eficácia de espaços latentes extraídos dessas imagens frente a métodos tradicionais de redução de dimensionalidade e seleção de atributos. A aplicação de matrizes GAF/MTF permite transpor o problema de dados tabulares temporais para o domínio de operadores de extração de padrões espaciais, abrindo caminho para testar se técnicas de aprendizado não supervisionado se beneficiam da preservação topológica dessas transformações [5]. Com isso, o trabalho estabelece um teste empírico controlado para mensurar se a complexidade adicional dessa projeção espacial se traduz, de fato, em *clusters* mais coesos e discriminantes do que os obtidos via abordagens vetoriais convencionais.

Por fim, o trabalho preenche uma lacuna relevante na análise de fenômenos de mercado ao estruturar a descoberta de padrões de desvalorização e possíveis efeitos de transbordamento decorrentes da chegada dos veículos elétricos e das montadoras chinesas [7, 1]. Ao analisar o co-movimento de preços entre matrizes energéticas concorrentes, a pesquisa vai além do agrupamento meramente exploratório e fornece um protocolo experimental rigoroso baseado em técnicas consolidadas de pré-processamento, mitigação do impacto de *outliers* e validação de modelos. Dessa forma, a investigação entrega simultaneamente uma contribuição teórica sobre representação de dados ordenados na mineração de dados e uma ferramenta descritiva aplicada para precificação e gestão de risco sobre ativos automotivos.

2 Objetivos

- **Mapear e quantificar as taxas de depreciação dos veículos elétricos:** Mensurar a velocidade e amplitude da perda de valor dos modelos eletrificados em comparação direta a veículos a combustão pareados por porte, categoria e faixa de preço de lançamento [9].
- **Avaliar o efeito de transbordamento (*spillover*) de marcas entrantes:** Analisar correlações temporais e possíveis quebras estruturais de preços em segmentos tradicionais após a introdução e guerra tarifária promovida por montadoras chinesas no mercado nacional [6, 7].
- **Implementar e validar o *reshaping* de séries temporais em imagens 2D:** Transformar as trajetórias unidimensionais de preços de cada veículo em representações matriciais utilizando algoritmos como *Gramian Angular Field* (GAF) ou *Markov Transition Field* (MTF) [12, 5].
- **Identificar e caracterizar arquétipos de desvalorização veicular:** Aplicar algoritmos de agrupamento (*clustering*) sobre representações vetoriais clássicas e sobre os espaços latentes gerados a partir das imagens, identificando perfis comportamentais típicos (alta retenção, desvalorização acelerada, valorização tardia).
- **Comparar empiricamente a eficácia das representações:** Avaliar quantitativamente, por meio de métricas de qualidade de agrupamento (como coeficiente de Silhueta e índice Davies-Bouldin), se a transformação das séries para imagem supera as abordagens vetoriais unidimensionais tradicionais, adotando a distância Euclidiana e o *Dynamic Time Warping* (DTW) como *baselines* de comparação.

3 Atividades

- **Atividade 1:** Coleta, limpeza e pré-processamento dos dados, tratamento de inconsistências/valores ausentes e estruturação temporal dos registros da base fipeX por veículo.
- **Atividade 2:** Análise exploratória e pareamento comparativo visualização das trajetórias de depreciação, cálculo de estatísticas descritivas e pareamento dos modelos elétricos com equivalentes a combustão para identificação de padrões preliminares.
- **Atividade 3:** Transformação e representação espacial (*reshaping*), realizando a codificação das séries temporais 1D em representações matriciais 2D utilizando as técnicas de GAF e MTF.
- **Atividade 4:** Modelagem de agrupamento e extração de padrões aplicando algoritmos de *clustering* (K-Means e abordagens baseadas em densidade) sobre as representações geradas por imagem e sobre os dados vetoriais clássicos. Para garantir uma validação robusta da abordagem bidimensional proposta, o projeto estabelecerá uma linha de base (*baseline*) operando diretamente sobre as séries temporais unidimensionais (1D) da taxa de retenção de valor. Serão aplicadas medidas de similaridade clássicas, com ênfase na Distância Euclidiana e, principalmente, no algoritmo de *Dynamic Time Warping* (DTW) [8], que é especialista em alinhar defasagens temporais. O desempenho dos agrupamentos obtidos no espaço 1D com DTW servirá como parâmetro de controle crítico para avaliar o real ganho de informação e precisão proporcionado pelas codificações matriciais 2D (GAF e MTF).
- **Atividade 5:** Avaliação experimental, interpretação e escrita final com o cálculo das métricas de validação de agrupamento, análise dos arquétipos comportamentais descobertos e consolidação dos resultados no artigo final.

4 Atividade 1: Pré-processamento e Limpeza de Dados

A base de dados bruta (fipeX) foi carregada contendo originalmente mais de 9,2 milhões de registros. Como etapa inicial de limpeza estrutural, instâncias inteiramente duplicadas e registros com o atributo *valor_centavos* igual a zero foram removidos. O escopo do projeto foi então restrito ao segmento de interesse, aplicando-se um filtro para manter apenas os registros com *tipo_veiculo* correspondente a carros, o que reduziu a base para aproximadamente 3,3 milhões de instâncias.

Para viabilizar a análise de séries temporais, os atributos de *ano_referencia* e *mes_referencia* foram agregados em uma única variável *data_referencia*, que está formatada em *yyyy-mm-dd* e como não existia o dia exato da coleta, foi considerada o primeiro dia do mês. Além disso, realizou-se a seleção de atributos (*feature selection*) descartando as seguintes colunas redundantes e/ou desnecessárias para a análise:

- *valor_formatado* que tem redundância com *valor_centavos*;
- *nome_combustivel* que tem redundância com *sigla_combustivel*;
- *zero_km* que consegue ser inferido a partir do *ano_modelo* e da *data_referencia*;
- *tipo_veiculo* que após os filtros iniciais só possui amostras de carros.

Durante o pré-processamento, antes de remover definitivamente a coluna *zero_km*, observou-se que uma quantidade expressiva de registros referentes a veículos novos ($zero_km = true$) apresentava valores ausentes na coluna *ano_modelo*. Para evitar o descarte desses registros e a consequente perda do preço base de lançamento, aplicou-se uma técnica de imputação baseada em conhecimento de domínio [10]. O *ano_modelo* desses veículos foi inferido e preenchido com o ano correspondente extraído da sua *data_referencia*. Tal procedimento assegura o alinhamento de fase e a correta ancoragem da idade inicial do ativo em zero, eliminando o viés de seleção que ocorreria caso todos os preços de lançamento fossem excluídos do *dataset*.

5 Atividade 2: Análise Exploratória e Redução de Escopo

Para garantir a coesão das séries temporais e evitar vieses macroeconômicos e mercadológicos, foram aplicadas heurísticas de filtragem baseadas na exploração visual e quantitativa dos dados. A distribuição logarítmica das avaliações ao longo do tempo separadas por matriz energética é ilustrada na Figura 1.

Analisando a distribuição de marcas e combustíveis, identificou-se que veículos movidos a gás natural e álcool puro possuíam uma representatividade marginal e falta de variedade de montadoras. Por conta disso, decidiu-se remover essas categorias, visto que a diversidade da frota é um fator de controle crítico na análise comparativa de depreciação [9].

Para evitar o viés de acúmulo temporal (onde veículos antigos parecem ter um portfólio maior simplesmente por estarem há mais meses na base), a relevância das montadoras foi mensurada contando-se os modelos de veículos estritamente únicos ($codigo_fipe + ano_modelo + sigla_combustivel$). Definiu-se o seguinte critério de corte: foram mantidas na base apenas as marcas que apresentassem um portfólio superior a 30 veículos únicos no total ou que possuíssem, no mínimo, 15 veículos únicos eletrificados (elétricos e híbridos). Esta abordagem com múltiplos limiares justifica-se pela necessidade de tratar distribuições de frequência assimétricas em tarefas de mineração de dados, garantindo que os veículos eletrificados e as montadoras entrantes sejam adequadamente representadas. O limiar de volume atua na filtragem de ruídos, enquanto a regra de exceção preserva as montadoras recentes, assegurando densidade sem distorcer os padrões subjacentes [10].

Para evitar que o modelo compare o comportamento econômico de carros a combustão da década de 1990 com elétricos da década de 2020, o escopo foi restringido a uma janela de mercado máxima de 20 anos. Os veículos cujo *ano_lancamento* absoluto era anterior ao corte estipulado foram removidos. A partir das amostras filtradas, estratificando a idade absoluta dos veículos e a sua respectiva matriz energética, obtiveram-se os resultados apresentados na Figura 2.

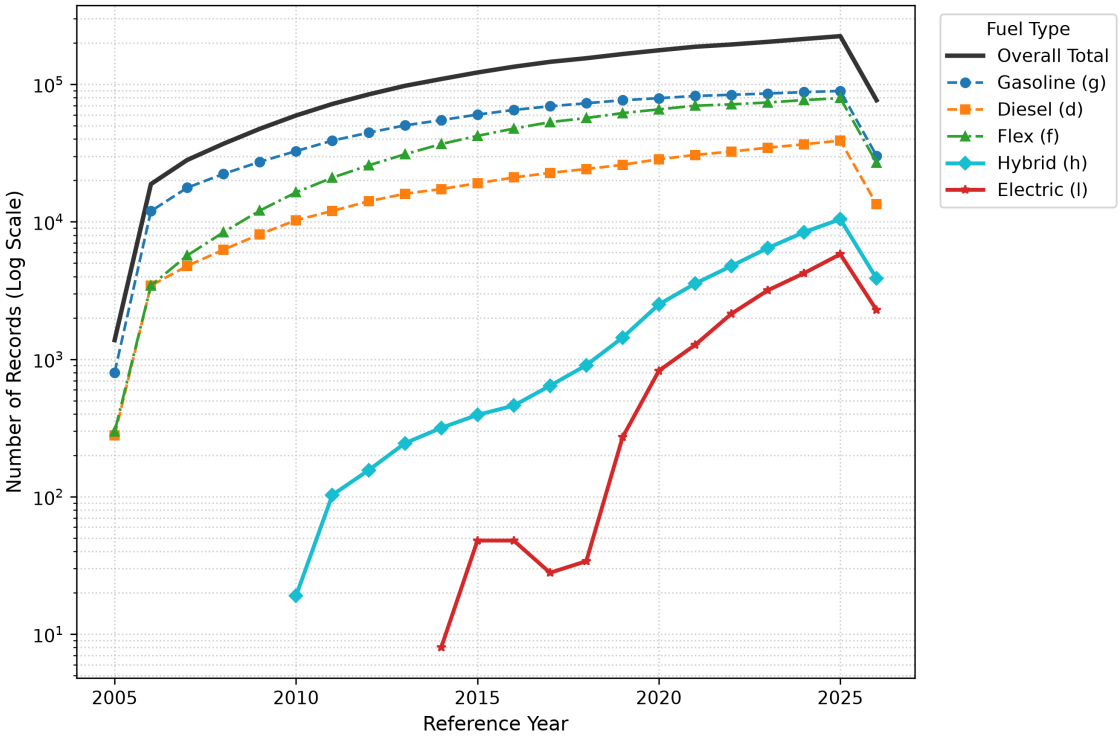


Figura 1: Distribuição temporal logarítmica da quantidade de registros por tipo de combustível (escala logarítmica).

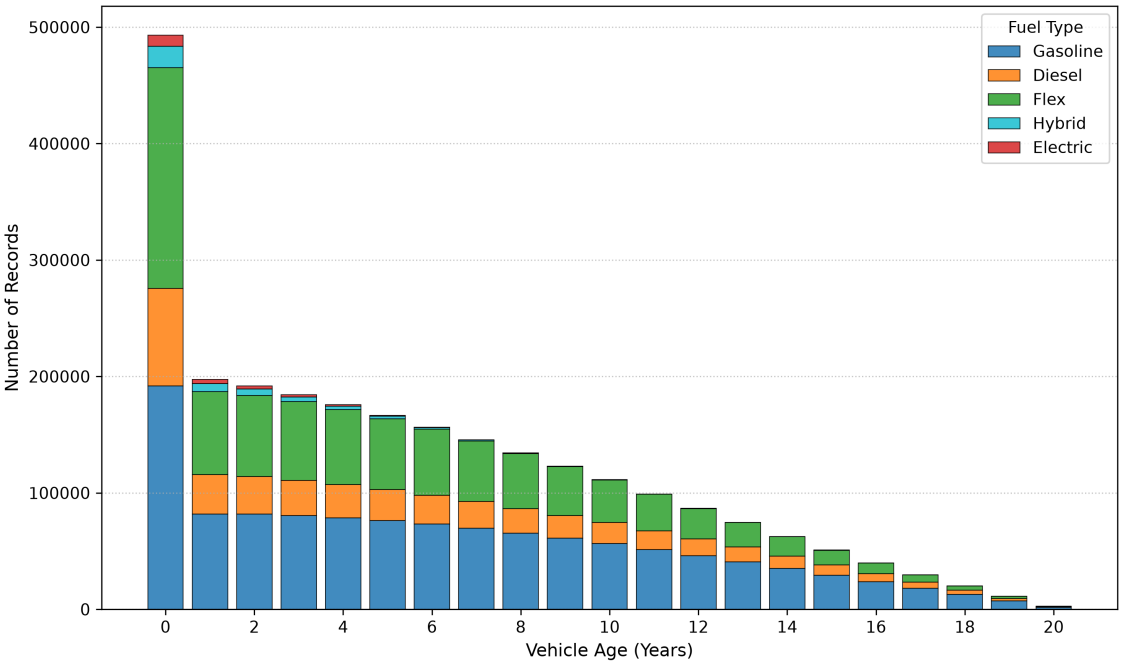


Figura 2: Gráfico de barras empilhadas que apresenta a distribuição de registros por idade do veículo em anos, estratificada por tipo de combustível.

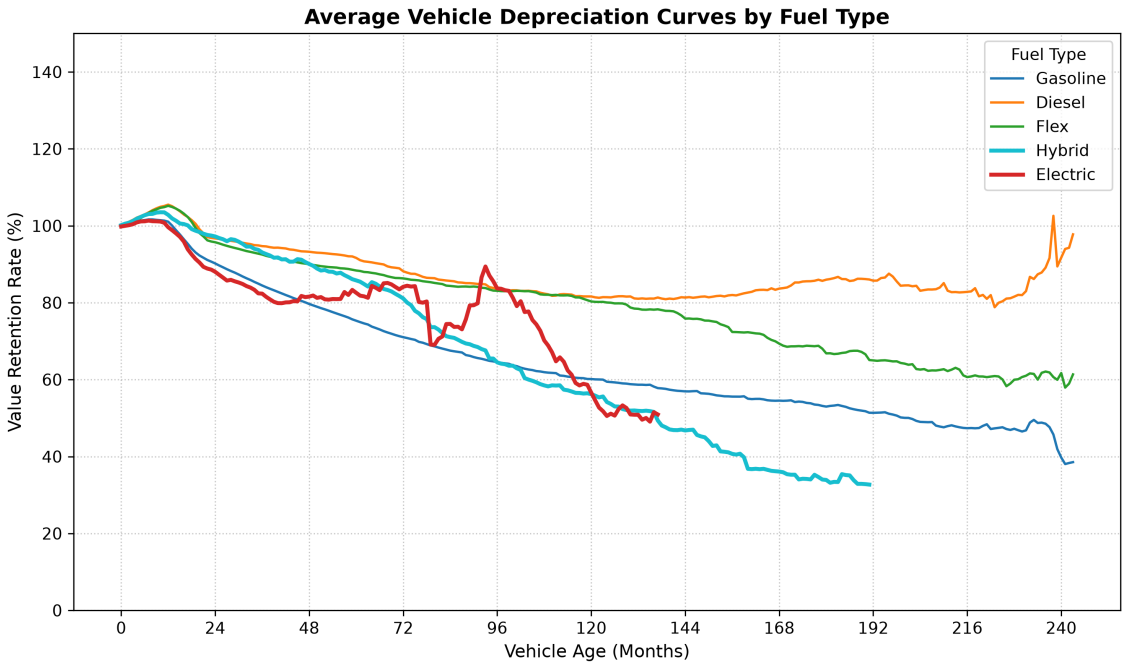


Figura 3: Curvas de depreciação médias por matriz energética, expressas em termos de Taxa de Retenção de Valor (VRR).

5.1 Análise de Depreciação

O comportamento de depreciação dos veículos pode ser analisado com base em duas métricas financeiras fundamentais: a Taxa de Retenção de Valor (do inglês, *Value Retention Rate* - VRR) e a Variação de Preço Ano a Ano (*Year-over-Year* - YoY). A Taxa de Retenção de Valor foi estabelecida isolando-se o preço absoluto de lançamento de cada veículo (momento $t = 0$, definido pela primeira data histórica de cotação do modelo na tabela) e medindo a proporção desse valor original que é retida em cada mês subsequente da vida útil do ativo. Matematicamente, a cotação mensal de cada veículo é dividida pelo seu respectivo preço de estreia, conforme expresso na Equação 1:

$$VRR_{i,t} = \left(\frac{P_{i,t}}{P_{i,0}} \right) \times 100 \tag{1}$$

Por outro lado, para capturar o comportamento macroeconômico e o impacto de eventos externos (como choques de oferta e inflação), calculou-se a variação YoY. Esta métrica foi obtida agrupando-se o preço médio de cada modelo dentro de um ano civil e determinando a sua variação percentual em relação ao preço médio do mesmo veículo no ano calendário imediatamente anterior, dada pela Equação 2:

$$YoY_{i,y} = \left(\frac{P_{i,y} - P_{i,y-1}}{P_{i,y-1}} \right) \times 100 \tag{2}$$

em que $YoY_{i,y}$ indica a variação percentual do preço do veículo i no ano civil y, $P_{i,y}$ é a média de cotação ao longo do ano de referência, e $P_{i,y-1}$ é a média de cotação no ano imediatamente anterior. A Figura 4 apresenta a variação média por matriz energética, tendo uma faixa central no gráfico que separa taxas positivas (valorização dos veículos) e taxas negativas (depreciação) em relação ao preço no fim do ano anterior. Enquanto o VRR expõe a física de desvalorização temporal do próprio produto, a métrica YoY atua como um termômetro das flutuações conjunturais do mercado automotivo como um todo, registrando inclusive anomalias temporárias de apreciação.

A fim de ter uma compreensão mais específica do comportamento de depreciação, foi criada uma visualização das faixas de valores de lançamento das amostras separadas por matriz energética, conforme apresentado na Figura 5. O gráfico boxplot evidencia que o tipo de motorização impacta diretamente na faixa de preço dos veículos, então para uma análise de depreciação por categoria de nível de preço, foi necessário analisar globalmente os veículos, independentemente de sua matriz energética, assim a Figura 6 apresenta a distribuição de todos os veículos e define três faixas de valores:

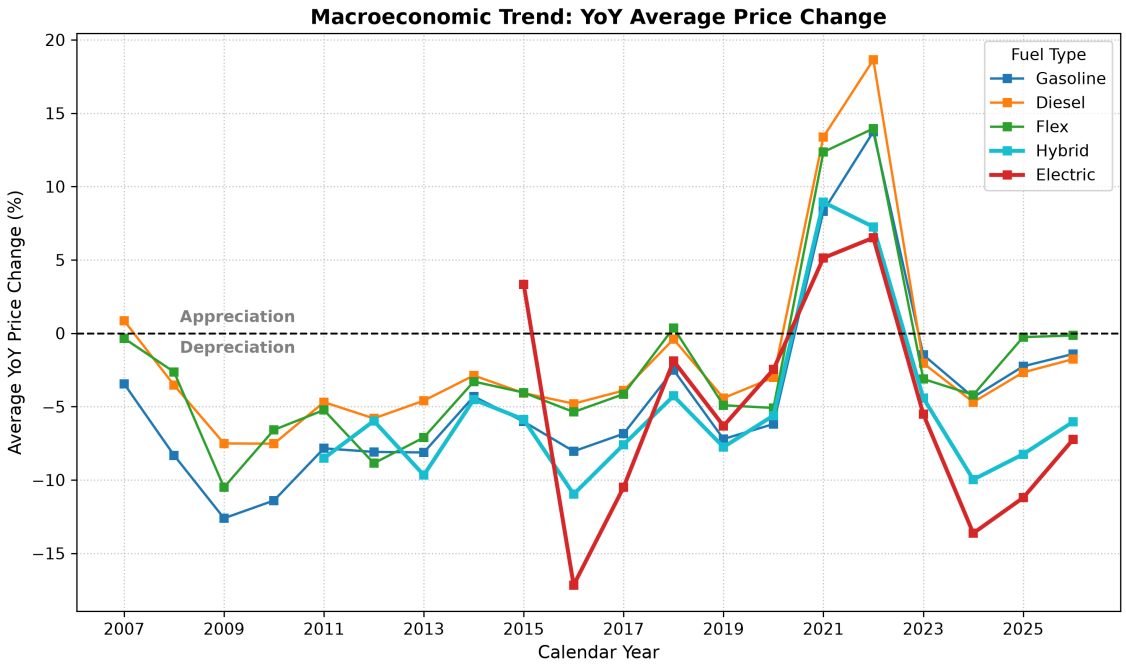


Figura 4: Curvas de depreciação médias por matriz energética, expressas em termos de Variação Ano a Ano (YoY).

- Veículos de entrada ($x \leq Q_1$), sendo que $Q_1 = \text{R\$}\,108.750$;
- Veículos intermediários ($Q_1 < x \leq Q_3$), sendo que $Q_3 = \text{R\$}\,400.110$;
- Veículos de luxo ($x > Q_3$).

Antes de analisar cada categoria especificamente, o impacto da pandemia na economia é um fator notório, principalmente no ano de 2022, onde a inflação atingiu o pico de 12,13% [4]. No período pandêmico, ocorreu um aumento no valor dos veículos para todas as categorias, então antes de analisar cada caso, é importante que fique claro ao leitor que esse período que afetou o mundo inteiro afetou diretamente a amostragem explorada neste trabalho.

5.1.1 Depreciação de Veículos de Entrada

No *dataset* explorado, os veículos de entrada movidos à Diesel mantiveram um saldo positivo, tendo sido mais valorizado do que depreciado, assim como mostra a Figura 7. Os veículos a gasolina, em média, também tiveram um saldo positivo, porém com uma menor taxa de valorização ano a ano, assim como é ilustrado na Figura 8. Os veículos híbridos e elétricos foram as únicas categorias a ja iniciarem com depreciação no período analisado, na Figura 8 temos a análise de 2019 até 2026, e os veículos elétricos tiveram uma depreciação maior do que -5% e os híbridos já iniciaram 2020 com uma depreciação maior do que -10%. Os flex tiveram um comportamento muito semelhante ao de Gasolina, e isto fica nítido na fígura 7.

5.1.2 Depreciação de Veículos Intermediários

Os veículos intermediários obtiveram uma maior desvalorização geral do que os veículos de entrada, pois os de entrada nos piores casos chegaram próximos a 80% de VRR, já os intermediários chegaram próximos a 60% de VRR, como ilustra a Figura 9. Aqui nenhuma categoria obteve um VRR acima de 100%, porém manteve-se o comportamento de veículos híbridos e elétricos sendo os que mais desvalorizaram. Ao migrar para a análise de YoY, os veículos elétricos atingiram um pico de desvalorização maior do que -15% em 2024, e os híbridos pioraram, saindo de uma depreciação próximo de -5% para uma acima de -10%, conforme a Figura 10

5.1.3 Depreciação de Veículos de Luxo

Os veículos de luxo à Gasolina foram os únicos a ter uma valoriazação ao longo dos meses, e os à Diesel tiveram uma depreciação maior do que os híbridos, o que é apresentado na Figura 11. Nesta

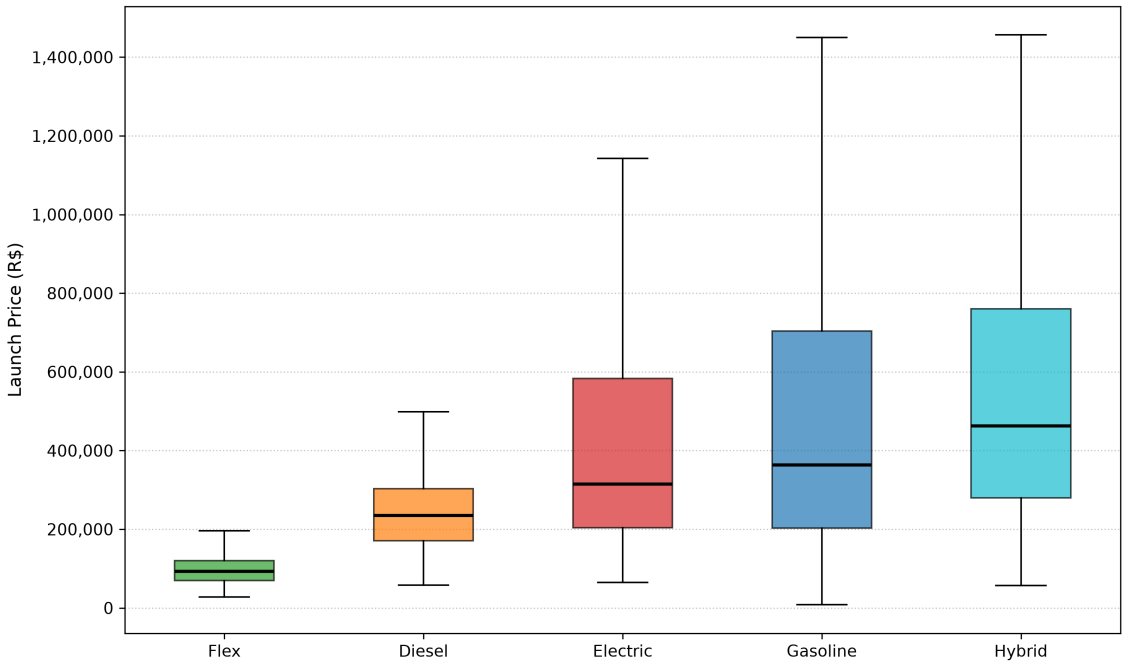


Figura 5: Distribuição de preços por matriz energética, com destaque para os quartis Q1 e Q3 que definem as faixas de preço.

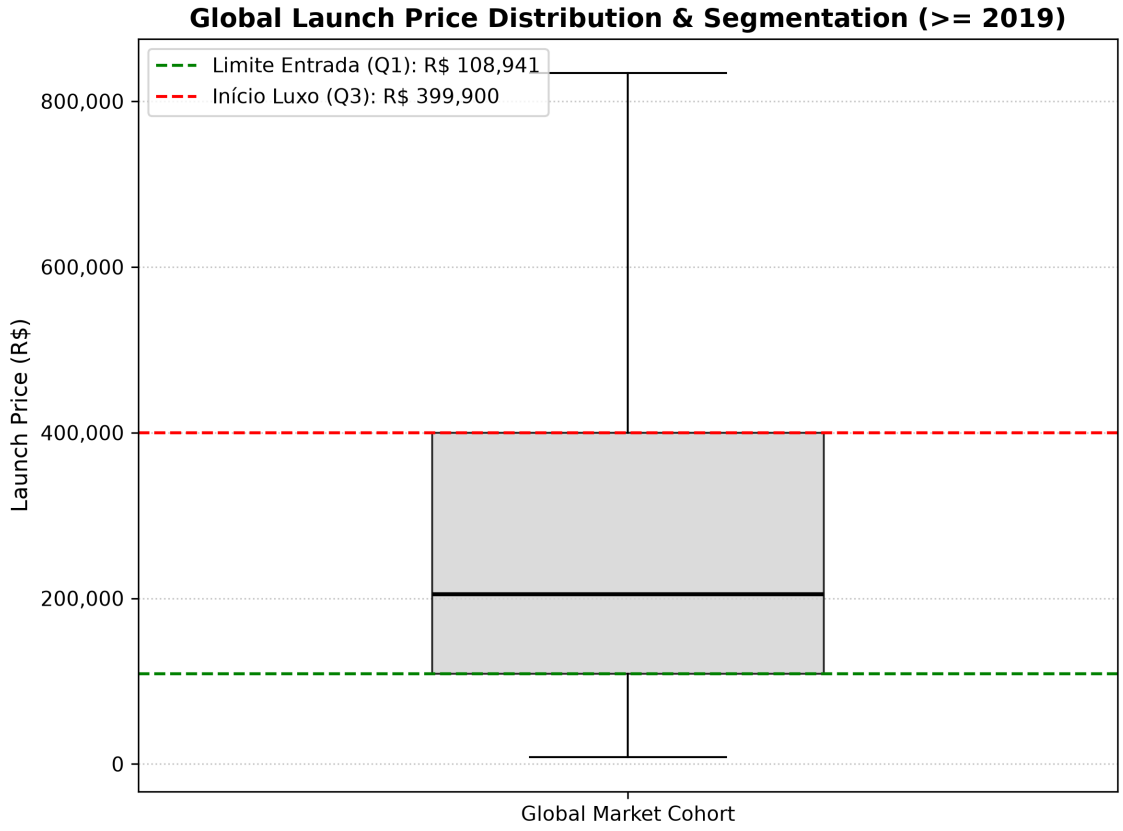


Figura 6: Distribuição geral de preços de lançamento, com destaque para os quartis Q1 e Q3 que definem as faixas de preço.

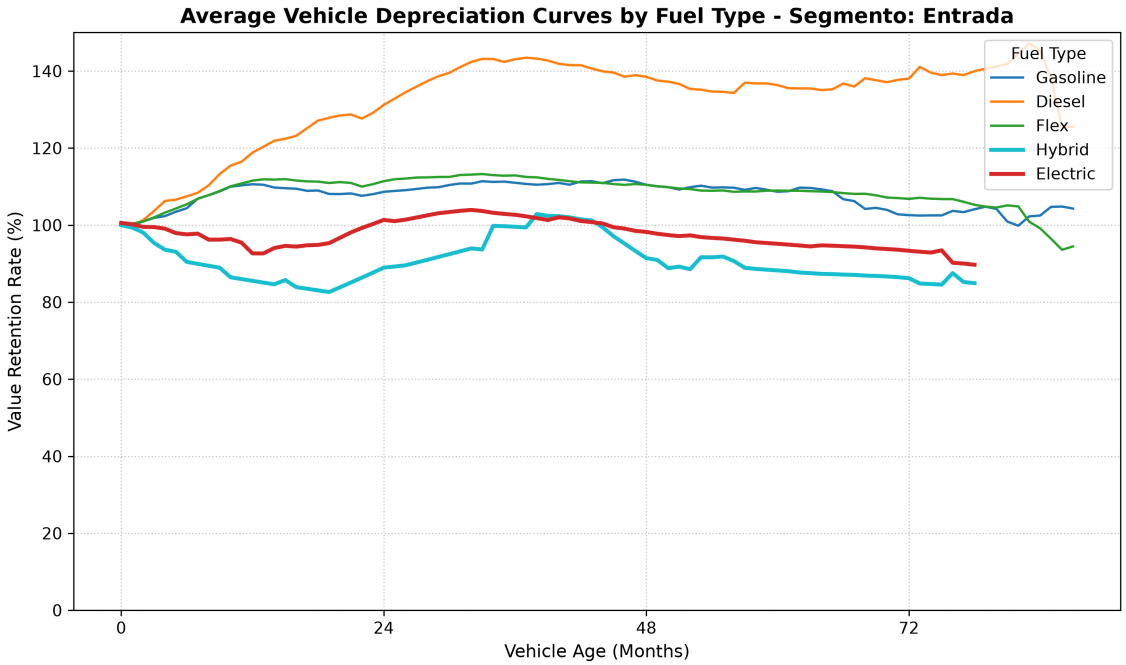


Figura 7: Curvas de depreciação médias por matriz energética para veículos de entrada, expressas em termos de Taxa de Retenção de Valor (VRR).

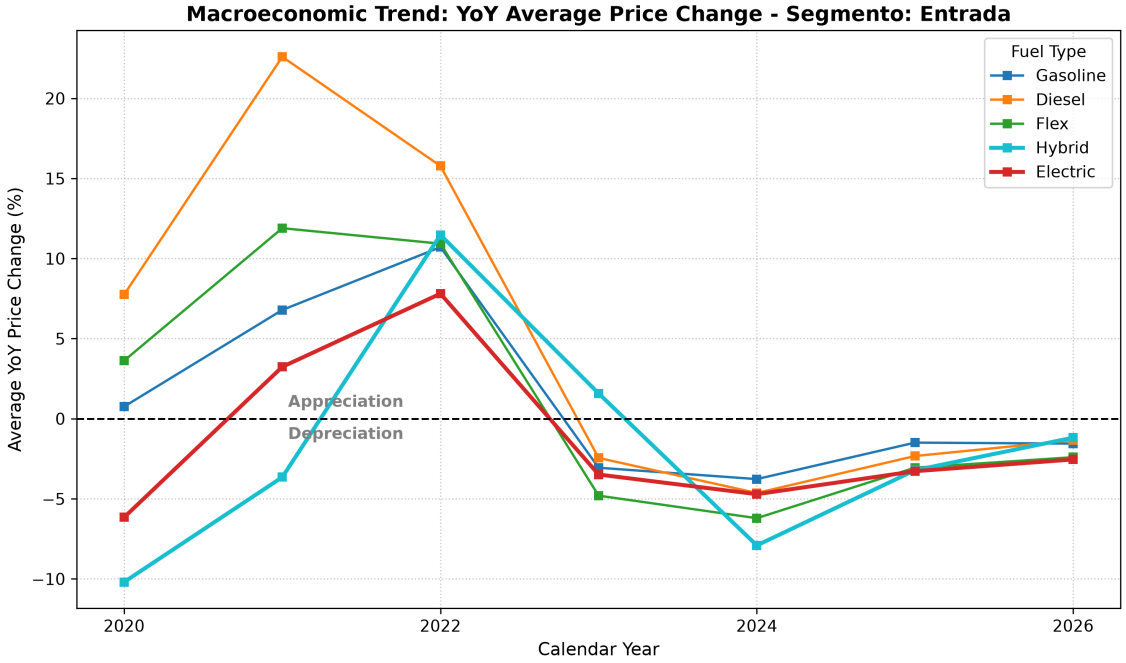


Figura 8: Taxa de por matriz energética para veículos de entrada, expressas em termos de Variação Ano a Ano (YoY).

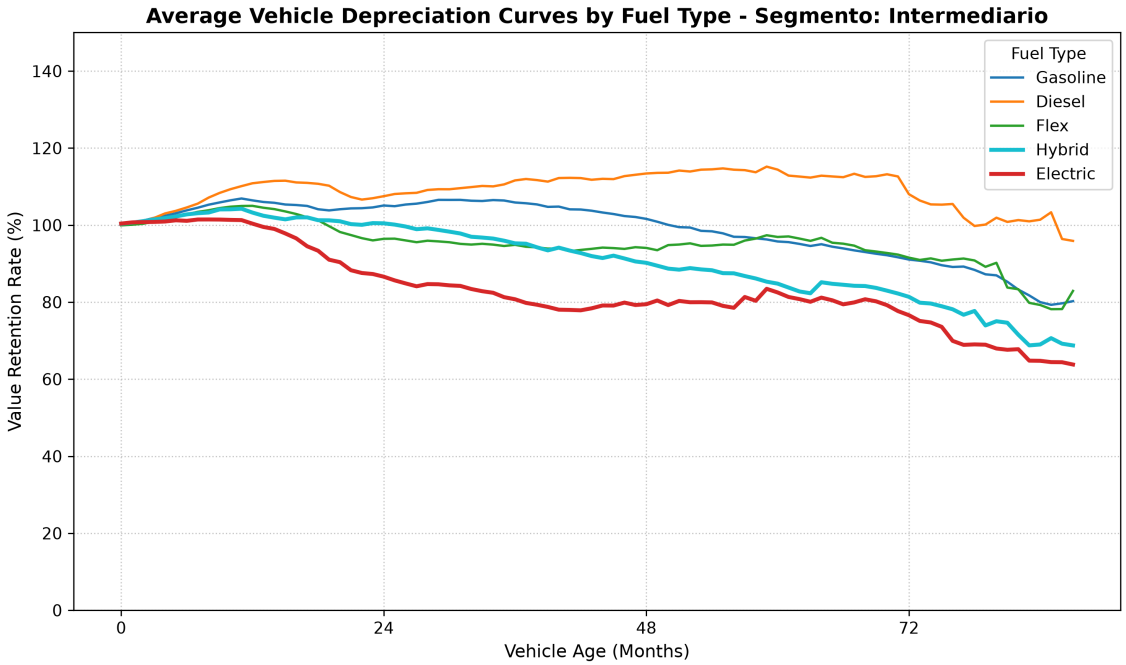


Figura 9: Curvas de depreciação médias por matriz energética para veículos de entrada, expressas em termos de Taxa de Retenção de Valor (VRR).

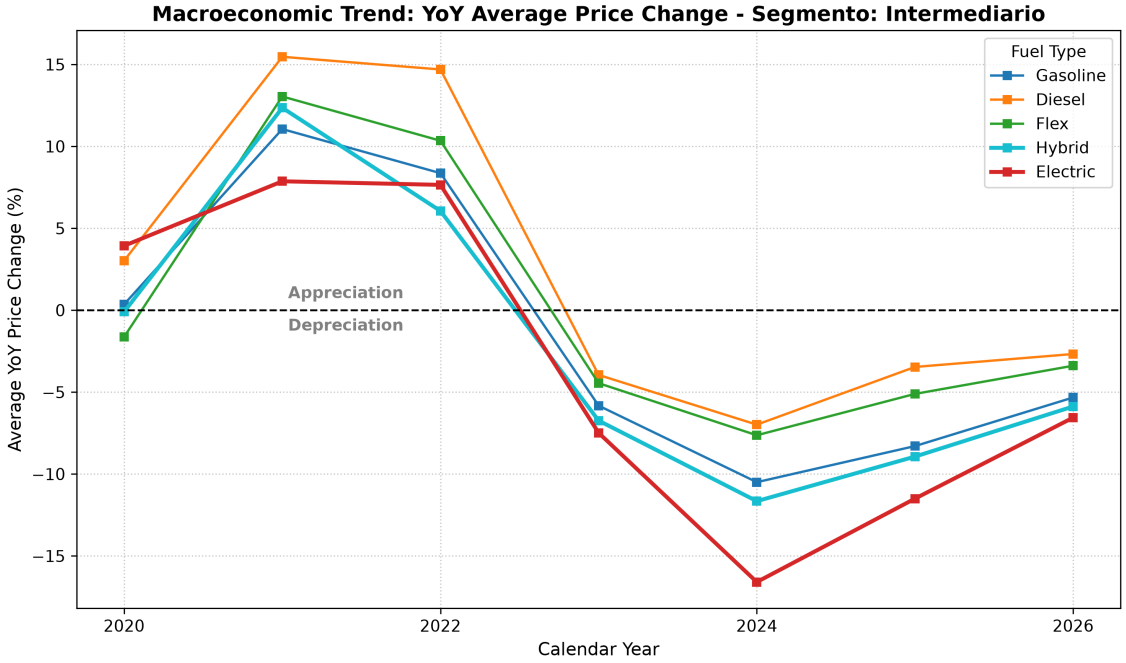


Figura 10: Taxa de por matriz energética para veículos de entrada, expressas em termos de Variação Ano a Ano (YoY).

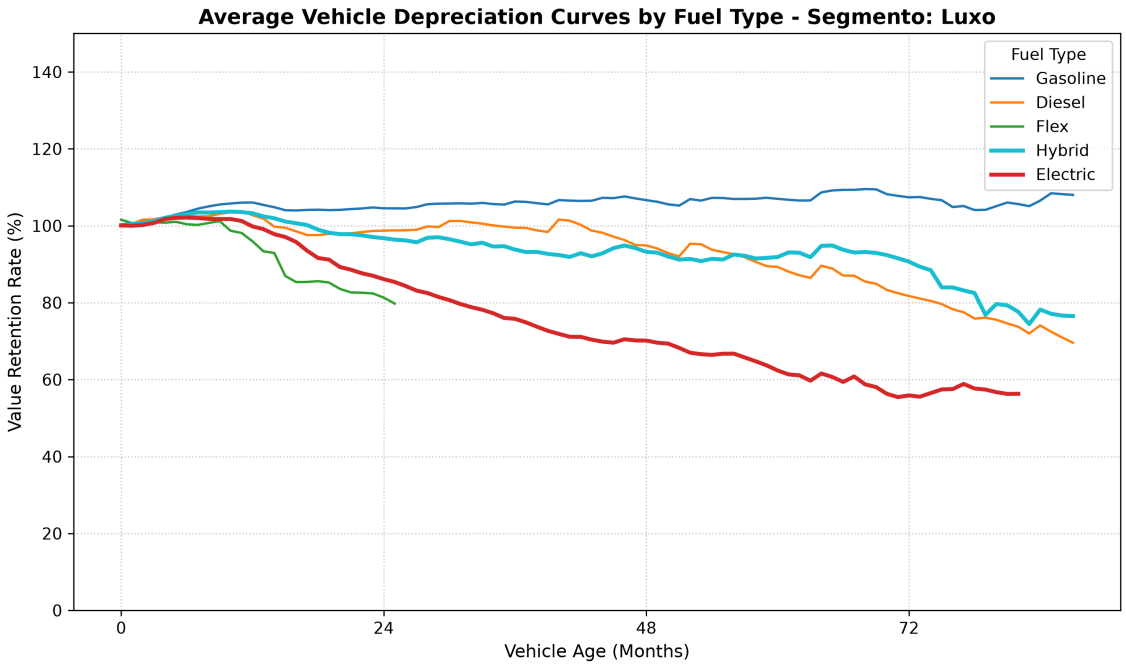


Figura 11: Curvas de depreciação médias por matriz energética para veículos de entrada, expressas em termos de Taxa de Retenção de Valor (VRR).

imagem, também nota-se a intensa depreciação dos veículos elétricos, os quais por volta de 60 meses de idade já apresentam um VRR abaixo de 60%, superando a depreciação máxima dos veículos de intermediários. Na Figura 12, observa-se que os veículos luxuosos foram o que obtiveram a menor valorização durante a pandemia, tendo todas as categorias sendo uma valorização menor do que 15%. Já no outro extremo, os veículos elétricos apesar de ter o menor VRR, tiveram uma desvalorização de YoY menos pior do que os intermediários, sem ultrapassar a porcentagem de 15% de desvalorização em 2024.

Referências

[1] L. Abrardi. Market structure and competitive dynamics of electric vehicle in europe. Master's thesis, Politecnico di Torino, 2026.

[2] F. H. B. Alvarez. *Modelagem da Aceitação de Veículos Elétricos considerando Políticas de Incentivo, Consciência Ambiental, Inovação Pessoal e Auto-eficácia Financeira: uma Extensão ao UTAUT 2*. Tese de doutorado, Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio), 2024.

[3] P. Gautam, G. Pode, R. Pode, G. K. Ayetor, and B. Diouf. Depreciation in the electric vehicle transition: Sustainability of the second-hand electric vehicle market. *Vehicles*, 6(4):101, 2024.

[4] Instituto Brasileiro de Geografia e Estatística. Índice nacional de preços ao consumidor amplo - IPCA: Abril de 2022, may 2022. Acesso em: 21 out. 2026.

[5] Jayson C. Jueco et al. Performance analysis of time series-to-image encoding across different clustering methods for labeling anomalous load data in selected visayas subgrids. In *2024 IEEE Region 10 Conference (TENCON)*. IEEE, 2024.

[6] Changjun Li, Congmei Xu, Tongtong An, Mengcheng Yu, and Xiangjian Xin. The global electric vehicle (ev) industry price war: Implications for managerial decision-making. *Frontiers in Industry Economics and Management*, 2026.

[7] Shanjun Li et al. The rise of electric vehicles in china: Growth, challenges and future prospects. In *The Great Energy Transformation in China*, page 109. ANU Press, 2025.

[8] Hiroaki Sakoe and Seibi Chiba. Dynamic programming algorithm optimization for spoken word recognition. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 26(1):43–49, 1978.

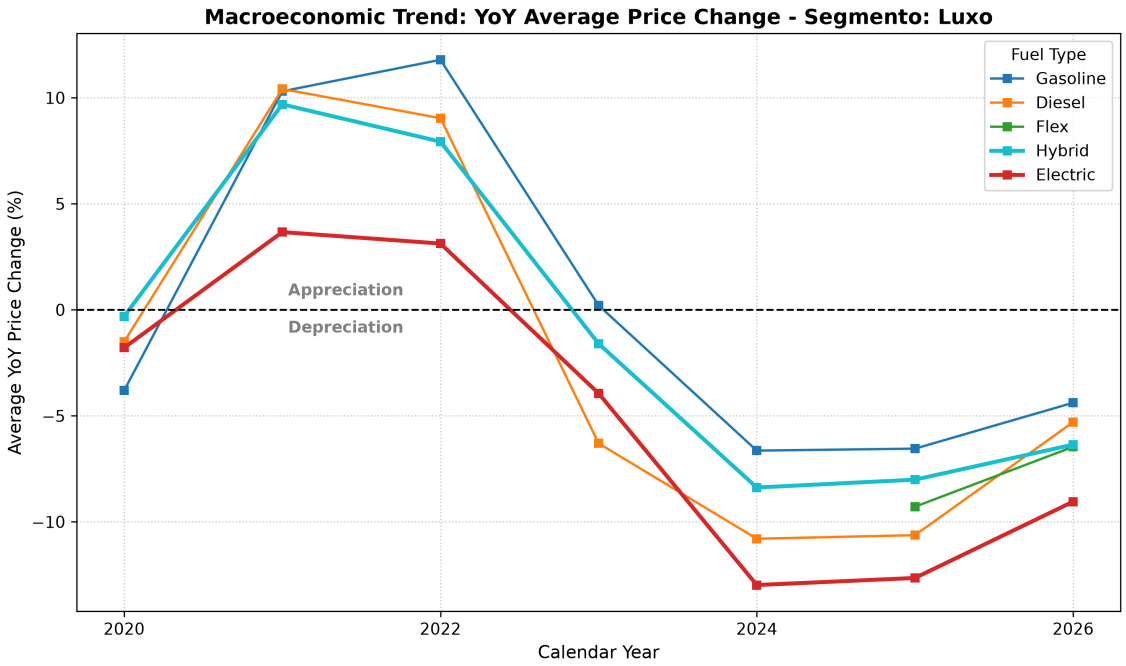


Figura 12: Taxa de por matriz energética para veículos de entrada, expressas em termos de Variação Ano a Ano (YoY).

[9] L. Schloter. Empirical analysis of the depreciation of electric vehicles compared to gasoline vehicles. *Transport Policy*, 126:268–279, 2022.

[10] Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, and Vipin Kumar. *Introduction to Data Mining*. Pearson Education, 2nd, global edition edition, 2019.

[11] Stepan Ulyanin, Jose R. Vazquez-Canteli, and Zoltan Nagy. Feature extraction and clustering of building energy profiles encoded as images. In *Proceedings of Building Simulation 2019: 16th Conference of IBPSA*, volume 16, pages 2108–2115. IBPSA, 2019.

[12] J. Wu. Imaging feature-based clustering of financial time series. *PLOS ONE*, 18(7):e0288836, 2023.