Caracterização de Padrões de Depreciação Automotiva sob a Transição Energética: Uma Abordagem Baseada em Representação Espacial de Séries Temporais

Gabriel M. Brum

2026

Resumo

Este trabalho investiga as dinâmicas temporais de depreciação de veículos automotores a partir do conjunto de dados fipeX, com foco no impacto da inserção de veículos elétricos (EVs) no mercado brasileiro frente aos modelos convencionais a combustão interna. Metodologicamente, o estudo aborda três questões centrais: (i) a verificação de assimetrias estatísticas nas taxas de depreciação entre elétricos e a combustão de mesma faixa de valor; (ii) a análise de co-movimento e efeitos de transbordamento decorrentes de guerras de preços e marcas entrantes; e (iii) a avaliação comparativa entre a clusterização em séries temporais 1D tradicionais e representações bidimensionais geradas via *Gramian Angular Field* (GAF) e *Markov Transition Field* (MTF). A proposta visa unir a caracterização econômica de novos ativos à exploração de representações espaciais como estratégia de transformação de atributos em tarefas de mineração de dados não supervisionadas.

1 Introdução

O mercado automotivo global e brasileiro atravessa uma transição tecnológica impulsionada pela entrada acelerada de Veículos Elétricos (EVs) [2]. Diferente dos veículos a combustão interna (ICE), cujo comportamento de depreciação histórica é consolidado e linearizado pela idade do bem, os modelos eletrificados introduzem variáveis de incerteza operacional: degradação acelerada de baterias, rápida obsolescência tecnológica, políticas tarifárias voláteis e guerras de preços [6, 9].

Compreender e segmentar essas trajetórias temporais não é apenas uma demanda mercadológica de precificação e análise de risco para seguradoras e instituições financeiras; constitui um problema clássico de *Data Mining* voltado à mineração de séries temporais (*time-series mining*) e descoberta de padrões em dados ordenados. Métodos convencionais frequentemente achatam as curvas históricas ou dependem de distâncias euclidianas 1D que falham em capturar dinâmicas não lineares, flutuações sazonais e correlações defasadas entre segmentos concorrentes [13]. Embora medidas de similaridade elásticas específicas para esse tipo de dado, como o *Dynamic Time Warping* (DTW), ofereçam maior flexibilidade ao alinhar sequências defasadas temporalmente, elas ainda operam no domínio unidimensional e frequentemente apresentam alto custo computacional em grandes volumes de dados.

A representação convencional de séries temporais como vetores unidimensionais impõe limitações analíticas severas ao processo de mineração de dados, restringindo os algoritmos de agrupamento a métricas de distância altamente suscetíveis a variações de escala. Essa restrição metodológica fundamenta a necessidade de investigar transformações de atributos mais robustas, avaliando se representações bidimensionais geradas por *Gramian Angular Fields* (GAF) ou *Markov Transition Fields* (MTF) são capazes de codificar correlações cruzadas e dependências dinâmicas que escapam às métricas clássicas, como a distância Euclidiana e o DTW [17, 15].

Sob o ponto de vista da modelagem estatística e do aprendizado de máquina, o estudo se justifica ao contrapor a eficácia de espaços latentes extraídos dessas imagens frente a métodos tradicionais de redução de dimensionalidade e seleção de atributos. A aplicação de matrizes GAF/MTF permite transpor o problema de dados tabulares temporais para o domínio de operadores de extração de padrões espaciais, abrindo caminho para testar se técnicas de aprendizado não supervisionado se beneficiam da preservação topológica dessas transformações [8]. Com isso, o trabalho estabelece um teste empírico controlado para mensurar se a complexidade adicional dessa projeção espacial se traduz, de fato, em *clusters* mais coesos e discriminantes do que os obtidos via abordagens vetoriais convencionais.

Por fim, o trabalho preenche uma lacuna relevante na análise de fenômenos de mercado ao estruturar a descoberta de padrões de desvalorização e possíveis efeitos de transbordamento decorrentes da chegada dos veículos elétricos e das montadoras chinesas [10, 1]. Ao analisar o co-movimento de preços entre matrizes energéticas concorrentes, a pesquisa vai além do agrupamento meramente exploratório e fornece um protocolo experimental rigoroso baseado em técnicas consolidadas de pré-processamento, mitigação do impacto de *outliers* e validação de modelos. Dessa forma, a investigação entrega simultaneamente uma contribuição teórica sobre representação de dados ordenados na mineração de dados e uma ferramenta descritiva aplicada para precificação e gestão de risco sobre ativos automotivos.

2 Objetivos

- **Mapear e quantificar as taxas de depreciação dos veículos elétricos:** Mensurar a velocidade e amplitude da perda de valor dos modelos eletrificados em comparação direta a veículos a combustão pareados por porte, categoria e faixa de preço de lançamento [13].
- **Avaliar o efeito de transbordamento (*spillover*) de marcas entrantes:** Analisar correlações temporais e possíveis quebras estruturais de preços em segmentos tradicionais após a introdução e guerra tarifária promovida por montadoras chinesas no mercado nacional [9, 10].
- **Implementar e validar o *reshaping* de séries temporais em imagens 2D:** Transformar as trajetórias unidimensionais de preços de cada veículo em representações matriciais utilizando algoritmos como *Gramian Angular Field* (GAF) ou *Markov Transition Field* (MTF) [17, 8].
- **Identificar e caracterizar arquétipos de desvalorização veicular:** Aplicar algoritmos de agrupamento (*clustering*) sobre representações vetoriais clássicas e sobre os espaços latentes gerados a partir das imagens, identificando perfis comportamentais típicos (alta retenção, desvalorização acelerada, valorização tardia).
- **Comparar empiricamente a eficácia das representações:** Avaliar quantitativamente, por meio de métricas de qualidade de agrupamento (como coeficiente de Silhueta e índice Davies-Bouldin), se a transformação das séries para imagem supera as abordagens vetoriais unidimensionais tradicionais, adotando a distância Euclidiana e o *Dynamic Time Warping* (DTW) como *baselines* de comparação.

3 Atividades

- **Atividade 1:** Coleta, limpeza e pré-processamento dos dados, tratamento de inconsistências/valores ausentes e estruturação temporal dos registros da base fipeX por veículo.
- **Atividade 2:** Análise exploratória e pareamento comparativo visualização das trajetórias de depreciação, cálculo de estatísticas descritivas e pareamento dos modelos elétricos com equivalentes a combustão para identificação de padrões preliminares.
- **Atividade 3:** Transformação e representação espacial (*reshaping*), realizando a codificação das séries temporais 1D em representações matriciais 2D utilizando as técnicas de GAF e MTF.
- **Atividade 4:** Modelagem de agrupamento e extração de padrões aplicando algoritmos de *clustering* (K-Means e abordagens baseadas em densidade) sobre as representações geradas por imagem e sobre os dados vetoriais clássicos. Para garantir uma validação robusta da abordagem bidimensional proposta, o projeto estabelecerá uma linha de base (*baseline*) operando diretamente sobre as séries temporais unidimensionais (1D) da taxa de retenção de valor. Serão aplicadas medidas de similaridade clássicas, com ênfase na Distância Euclidiana e, principalmente, no algoritmo de *Dynamic Time Warping* (DTW) [12], que é especialista em alinhar defasagens temporais. O desempenho dos agrupamentos obtidos no espaço 1D com DTW servirá como parâmetro de controle crítico para avaliar o real ganho de informação e precisão proporcionado pelas codificações matriciais 2D (GAF e MTF).
- **Atividade 5:** Avaliação experimental, interpretação e escrita final com o cálculo das métricas de validação de agrupamento, análise dos arquétipos comportamentais descobertos e consolidação dos resultados no artigo final.

4 Atividade 1: Pré-processamento e Limpeza de Dados

A base de dados bruta (fipeX) foi carregada contendo originalmente mais de 9,2 milhões de registros. Como etapa inicial de limpeza estrutural, instâncias inteiramente duplicadas e registros com o atributo *valor_centavos* igual a zero foram removidos. O escopo do projeto foi então restrito ao segmento de interesse, aplicando-se um filtro para manter apenas os registros com *tipo_veiculo* correspondente a carros, o que reduziu a base para aproximadamente 3,3 milhões de instâncias.

Para viabilizar a análise de séries temporais, os atributos de *ano_referencia* e *mes_referencia* foram agregados em uma única variável *data_referencia*, que está formatada em *yyyy-mm-dd* e como não existia o dia exato da coleta, foi considerada o primeiro dia do mês. Além disso, realizou-se a seleção de atributos (*feature selection*) descartando as seguintes colunas redundantes e/ou desnecessárias para a análise:

- *valor_formatado* que tem redundância com *valor_centavos*;
- *nome_combustivel* que tem redundância com *sigla_combustivel*;
- *zero_km* que consegue ser inferido a partir do *ano_modelo* e da *data_referencia*;
- *tipo_veiculo* que após os filtros iniciais só possui amostras de carros.

Durante o pré-processamento, antes de remover definitivamente a coluna *zero_km*, observou-se que uma quantidade expressiva de registros referentes a veículos novos ($zero_km = true$) apresentava valores ausentes na coluna *ano_modelo*. Para evitar o descarte desses registros e a consequente perda do preço base de lançamento, aplicou-se uma técnica de imputação baseada em conhecimento de domínio [14]. O *ano_modelo* desses veículos foi inferido e preenchido com o ano correspondente extraído da sua *data_referencia*. Tal procedimento assegura o alinhamento de fase e a correta ancoragem da idade inicial do ativo em zero, eliminando o viés de seleção que ocorreria caso todos os preços de lançamento fossem excluídos do *dataset*.

5 Atividade 2: Análise Exploratória e Redução de Escopo

Para garantir a coesão das séries temporais e evitar vieses macroeconômicos e mercadológicos, foram aplicadas heurísticas de filtragem baseadas na exploração visual e quantitativa dos dados. A distribuição logarítmica das avaliações ao longo do tempo separadas por matriz energética é ilustrada na Figura 1.

Analisando a distribuição de marcas e combustíveis, identificou-se que veículos movidos a gás natural e álcool puro possuíam uma representatividade marginal e falta de variedade de montadoras. Por conta disso, decidiu-se remover essas categorias, visto que a diversidade da frota é um fator de controle crítico na análise comparativa de depreciação [13].

Para evitar o viés de acúmulo temporal (onde veículos antigos parecem ter um portfólio maior simplesmente por estarem há mais meses na base), a relevância das montadoras foi mensurada contando-se os modelos de veículos estritamente únicos ($codigo_fipe + ano_modelo + sigla_combustivel$). Definiu-se o seguinte critério de corte: foram mantidas na base apenas as marcas que apresentassem um portfólio superior a 30 veículos únicos no total ou que possuíssem, no mínimo, 15 veículos únicos eletrificados (elétricos e híbridos). Esta abordagem com múltiplos limiares justifica-se pela necessidade de tratar distribuições de frequência assimétricas em tarefas de mineração de dados, garantindo que os veículos eletrificados e as montadoras entrantes sejam adequadamente representadas. O limiar de volume atua na filtragem de ruídos, enquanto a regra de exceção preserva as montadoras recentes, assegurando densidade sem distorcer os padrões subjacentes [14].

Para evitar que o modelo compare o comportamento econômico de carros a combustão da década de 1990 com elétricos da década de 2020, o escopo foi restringido a uma janela de mercado máxima de 20 anos. Os veículos cujo *ano_lancamento* absoluto era anterior ao corte estipulado foram removidos. A partir das amostras filtradas, estratificando a idade absoluta dos veículos e a sua respectiva matriz energética, obtiveram-se os resultados apresentados na Figura 2.

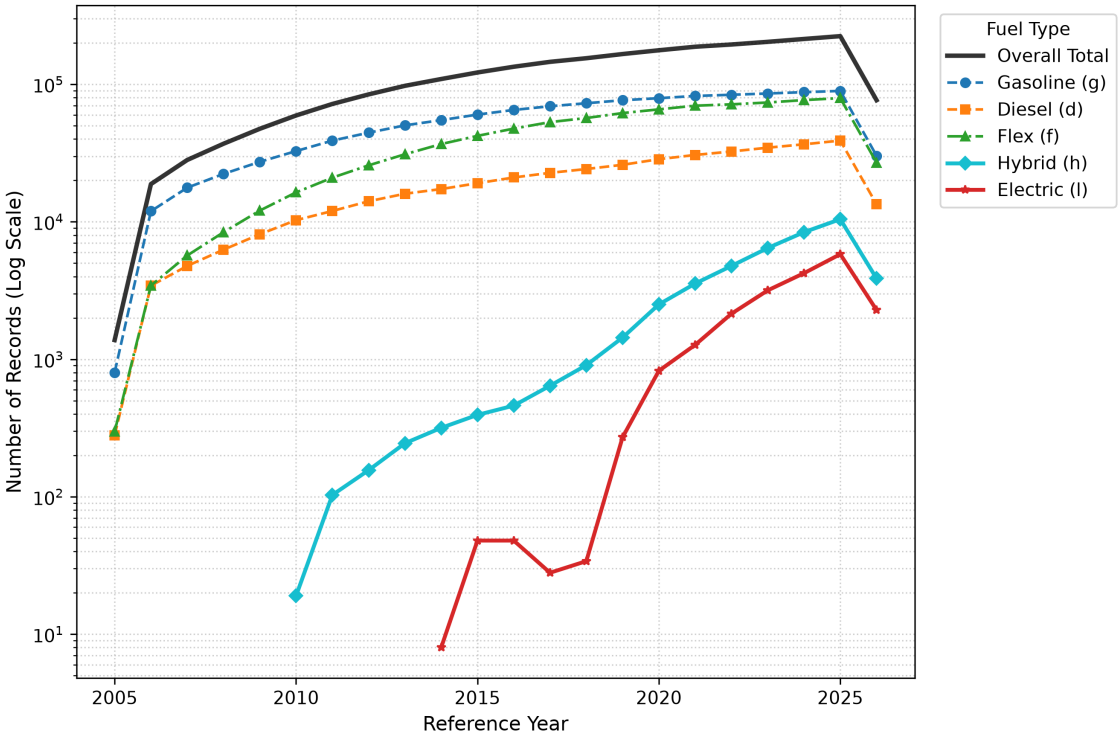


Figura 1: Distribuição temporal logarítmica da quantidade de registros por tipo de combustível (escala logarítmica).

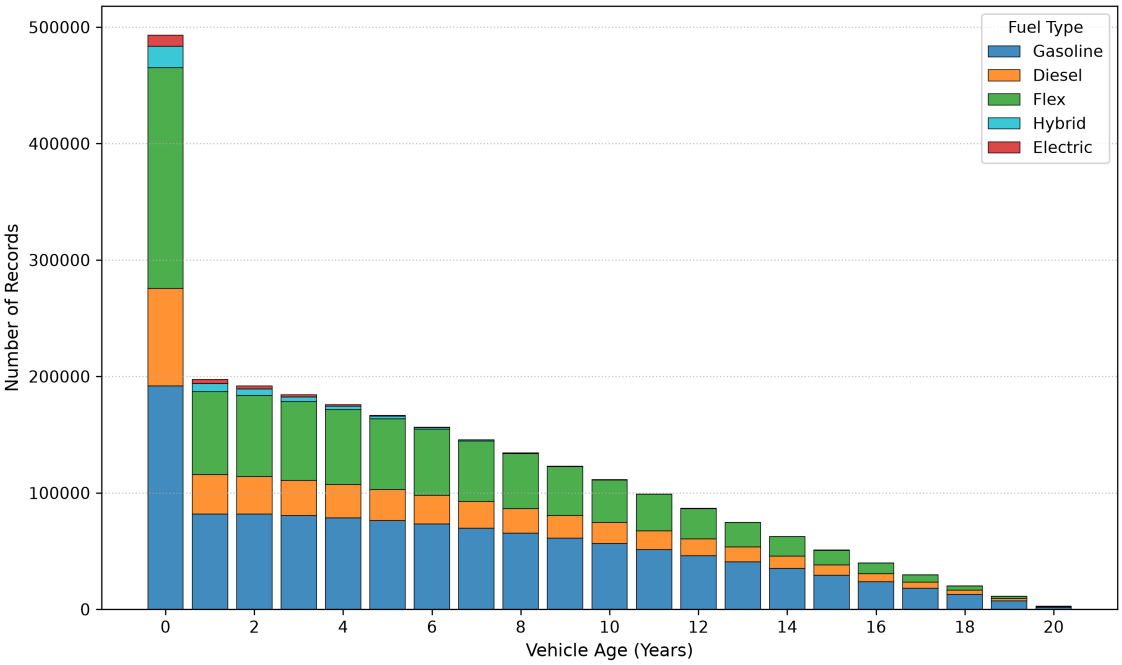


Figura 2: Gráfico de barras empilhadas que apresenta a distribuição de registros por idade do veículo em anos, estratificada por tipo de combustível.

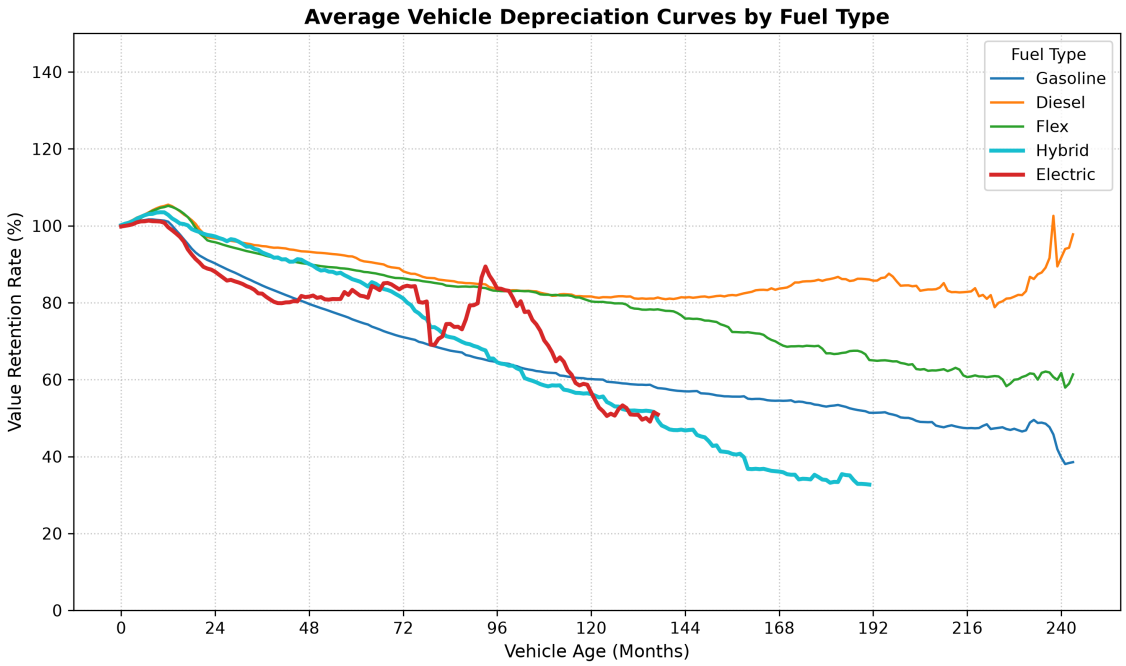


Figura 3: Curvas de depreciação médias por matriz energética, expressas em termos de Taxa de Retenção de Valor (VRR).

5.1 Análise de Depreciação

O comportamento de depreciação dos veículos pode ser analisado com base em duas métricas financeiras fundamentais: a Taxa de Retenção de Valor (do inglês, *Value Retention Rate* - VRR) e a Variação de Preço Ano a Ano (*Year-over-Year* - YoY). A Taxa de Retenção de Valor foi estabelecida isolando-se o preço absoluto de lançamento de cada veículo (momento $t = 0$, definido pela primeira data histórica de cotação do modelo na tabela) e medindo a proporção desse valor original que é retida em cada mês subsequente da vida útil do ativo. Matematicamente, a cotação mensal de cada veículo é dividida pelo seu respectivo preço de estreia, conforme expresso na Equação 1:

$$VRR_{i,t} = \left(\frac{P_{i,t}}{P_{i,0}} \right) \times 100 \tag{1}$$

Por outro lado, para capturar o comportamento macroeconômico e o impacto de eventos externos (como choques de oferta e inflação), calculou-se a variação YoY. Esta métrica foi obtida agrupando-se o preço médio de cada modelo dentro de um ano civil e determinando a sua variação percentual em relação ao preço médio do mesmo veículo no ano calendário imediatamente anterior, dada pela Equação 2:

$$YoY_{i,y} = \left(\frac{P_{i,y} - P_{i,y-1}}{P_{i,y-1}} \right) \times 100 \tag{2}$$

em que $YoY_{i,y}$ indica a variação percentual do preço do veículo i no ano civil y, $P_{i,y}$ é a média de cotação ao longo do ano de referência, e $P_{i,y-1}$ é a média de cotação no ano imediatamente anterior. A Figura 4 apresenta a variação média por matriz energética, tendo uma faixa central no gráfico que separa taxas positivas (valorização dos veículos) e taxas negativas (depreciação) em relação ao preço no fim do ano anterior. Enquanto o VRR expõe a física de desvalorização temporal do próprio produto, a métrica YoY atua como um termômetro das flutuações conjunturais do mercado automotivo como um todo, registrando inclusive anomalias temporárias de apreciação.

A fim de ter uma compreensão mais específica do comportamento de depreciação, foi criada uma visualização das faixas de valores de lançamento das amostras separadas por matriz energética, conforme apresentado na Figura 5. O gráfico boxplot evidencia que o tipo de motorização impacta diretamente na faixa de preço dos veículos, então para uma análise de depreciação por categoria de nível de preço, foi necessário analisar globalmente os veículos, independentemente de sua matriz energética, assim a Figura 6 apresenta a distribuição de todos os veículos e define três faixas de valores:

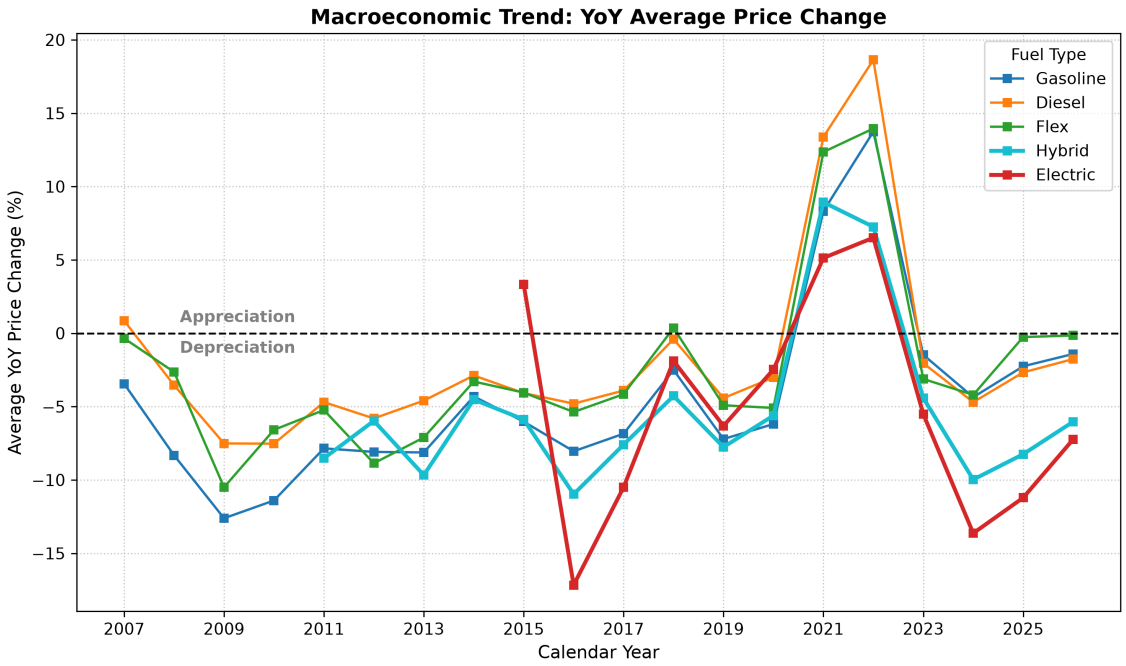


Figura 4: Curvas de depreciação médias por matriz energética, expressas em termos de Variação Ano a Ano (YoY).

- Veículos de entrada ($x \leq Q_1$), sendo que $Q_1 = \text{R\$}\,108.750$;
- Veículos intermediários ($Q_1 < x \leq Q_3$), sendo que $Q_3 = \text{R\$}\,400.110$;
- Veículos de luxo ($x > Q_3$).

Antes de analisar cada categoria especificamente, o impacto da pandemia na economia é um fator notório, principalmente no ano de 2022, onde a inflação atingiu o pico de 12,13% [7]. No período pandêmico, ocorreu um aumento no valor dos veículos para todas as categorias, então antes de analisar cada caso, é importante que fique claro ao leitor que esse período que afetou o mundo inteiro afetou diretamente a amostragem explorada neste trabalho.

5.1.1 Depreciação de Veículos de Entrada

No *dataset* explorado, os veículos de entrada movidos à Diesel mantiveram um saldo positivo, tendo sido mais valorizado do que depreciado, assim como mostra a Figura 7. Os veículos a gasolina, em média, também tiveram um saldo positivo, porém com uma menor taxa de valorização ano a ano, assim como é ilustrado na Figura 8. Os veículos híbridos e elétricos foram as únicas categorias a ja iniciarem com depreciação no período analisado, na Figura 8 temos a análise de 2019 até 2026, e os veículos elétricos tiveram uma depreciação maior do que -5% e os híbridos já iniciaram 2020 com uma depreciação maior do que -10%. Os flex tiveram um comportamento muito semelhante ao de Gasolina, e isto fica nítido na fígura 7.

5.1.2 Depreciação de Veículos Intermediários

Os veículos intermediários obtiveram uma maior desvalorização geral do que os veículos de entrada, pois os de entrada nos piores casos chegaram próximos a 80% de VRR, já os intermediários chegaram próximos a 60% de VRR, como ilustra a Figura 9. Aqui nenhuma categoria obteve um VRR acima de 100%, porém manteve-se o comportamento de veículos híbridos e elétricos sendo os que mais desvalorizaram. Ao migrar para a análise de YoY, os veículos elétricos atingiram um pico de desvalorização maior do que -15% em 2024, e os híbridos pioraram, saindo de uma depreciação próximo de -5% para uma acima de -10%, conforme a Figura 10

5.1.3 Depreciação de Veículos de Luxo

Os veículos de luxo à Gasolina foram os únicos a ter uma valoriazação ao longo dos meses, e os à Diesel tiveram uma depreciação maior do que os híbridos, o que é apresentado na Figura 11. Nesta

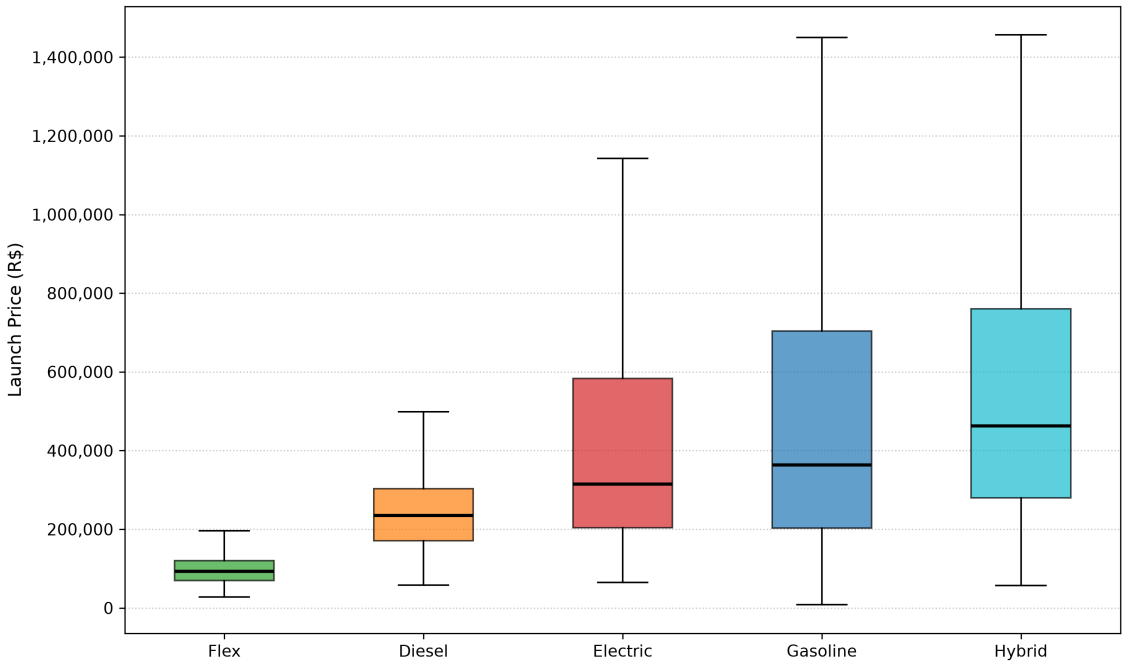


Figura 5: Distribuição de preços por matriz energética, com destaque para os quartis Q1 e Q3 que definem as faixas de preço.

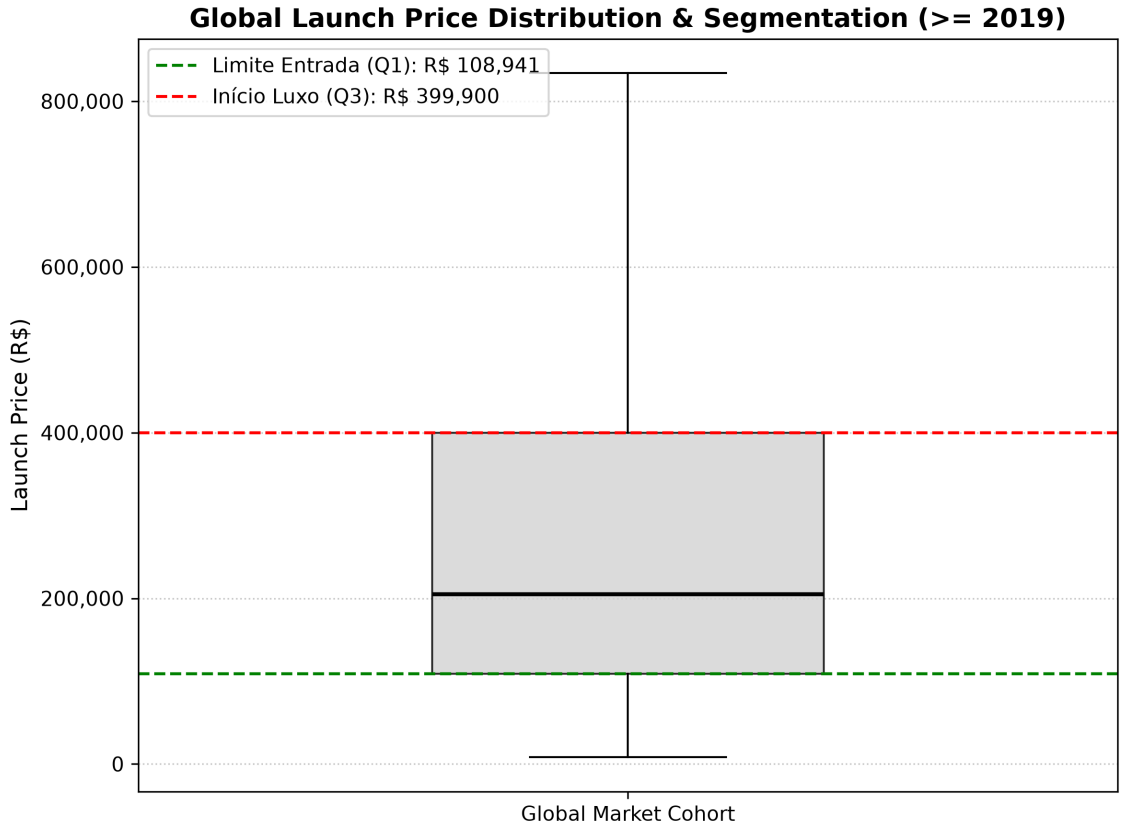


Figura 6: Distribuição geral de preços de lançamento, com destaque para os quartis Q1 e Q3 que definem as faixas de preço.

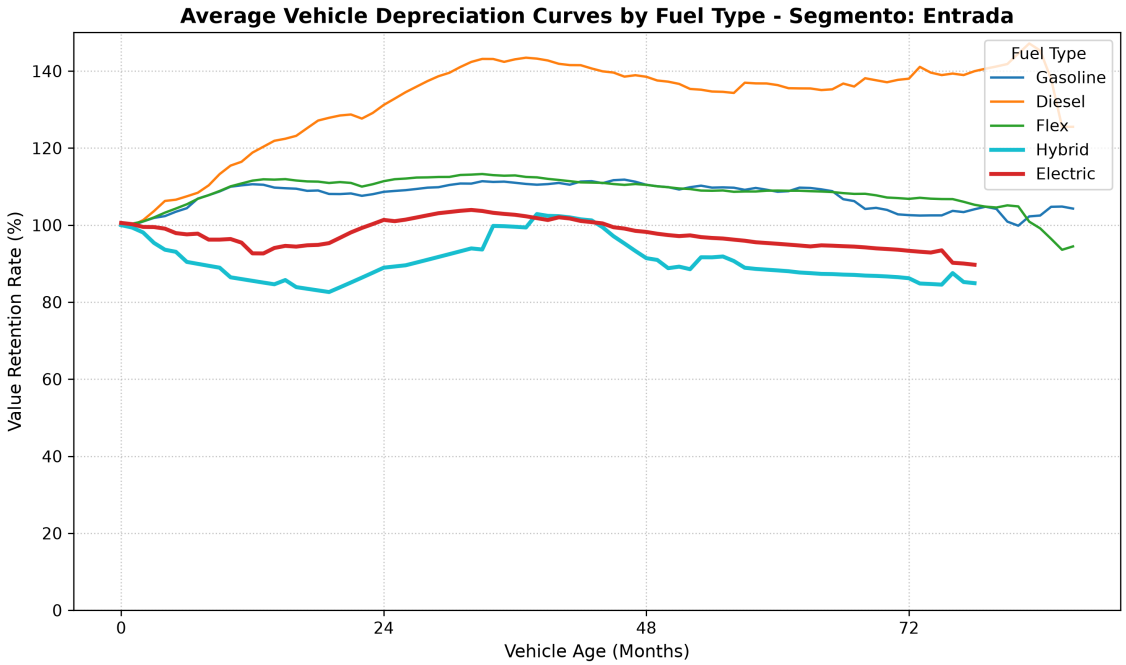


Figura 7: Curvas de depreciação médias por matriz energética para veículos de entrada, expressas em termos de Taxa de Retenção de Valor (VRR).

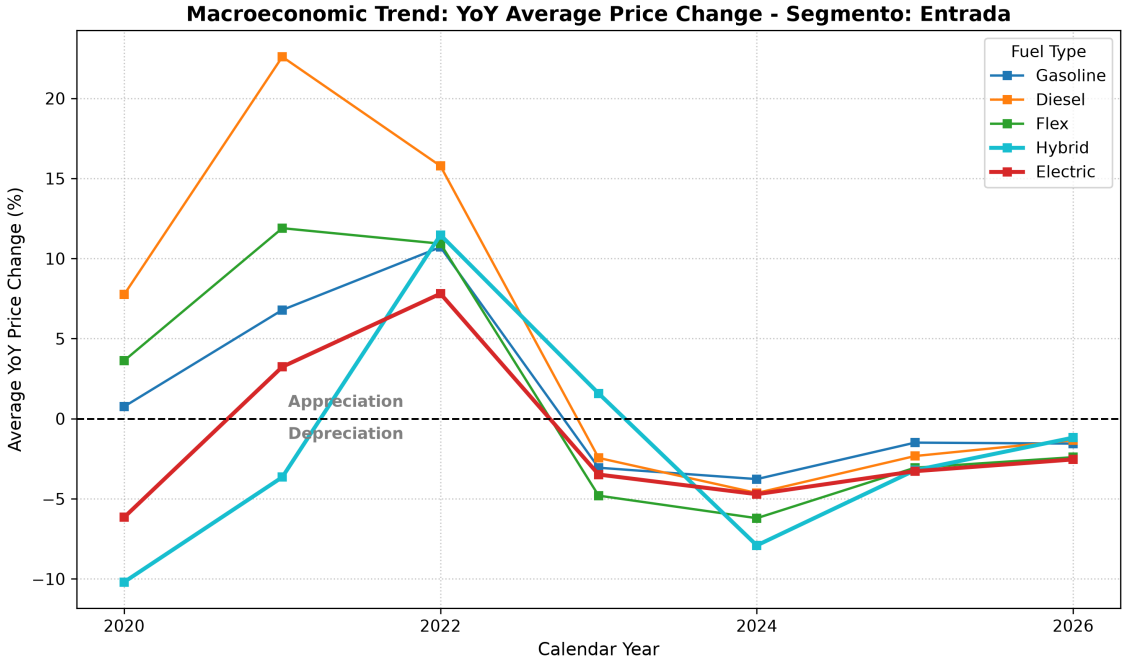


Figura 8: Taxa de por matriz energética para veículos de entrada, expressas em termos de Variação Ano a Ano (YoY).

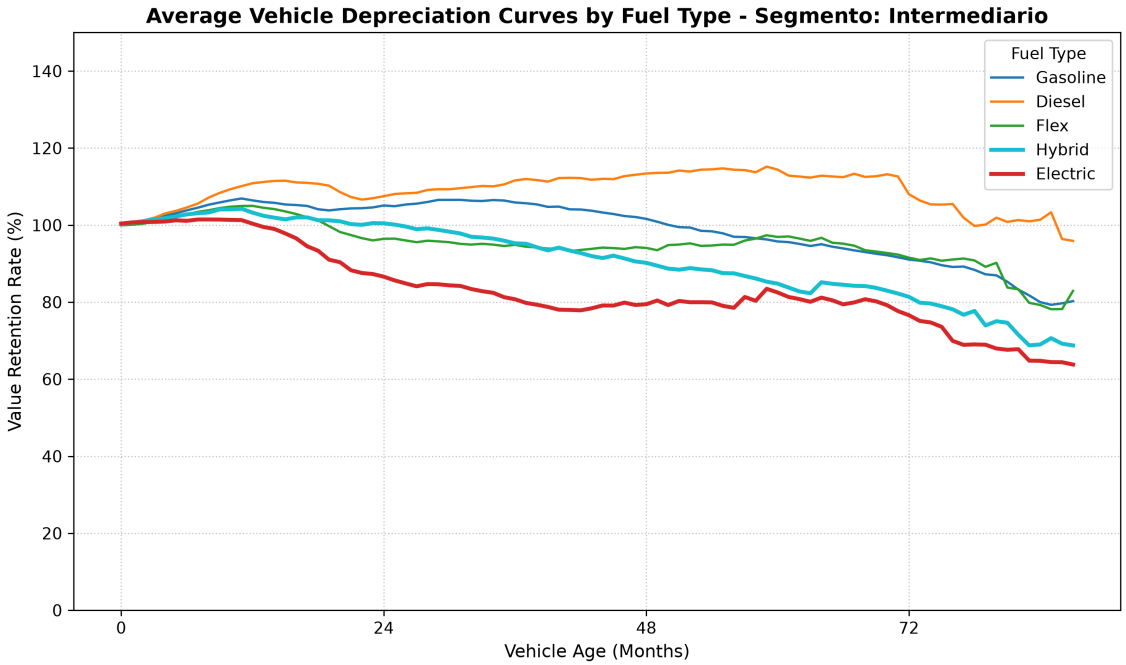


Figura 9: Curvas de depreciação médias por matriz energética para veículos de entrada, expressas em termos de Taxa de Retenção de Valor (VRR).

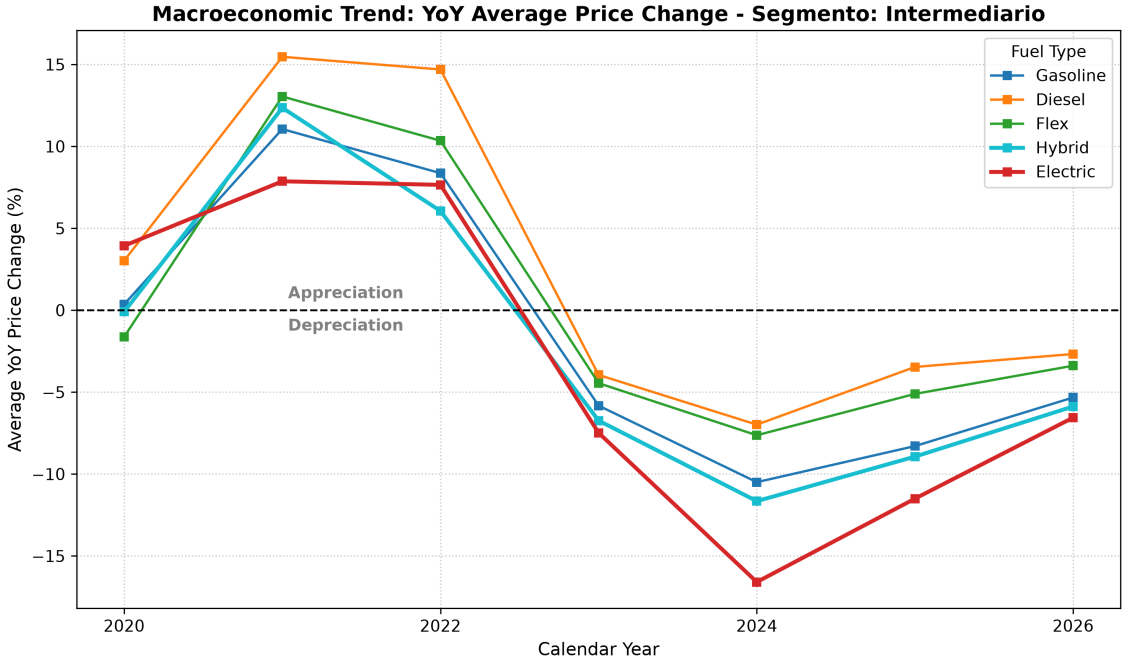


Figura 10: Taxa de por matriz energética para veículos de entrada, expressas em termos de Variação Ano a Ano (YoY).

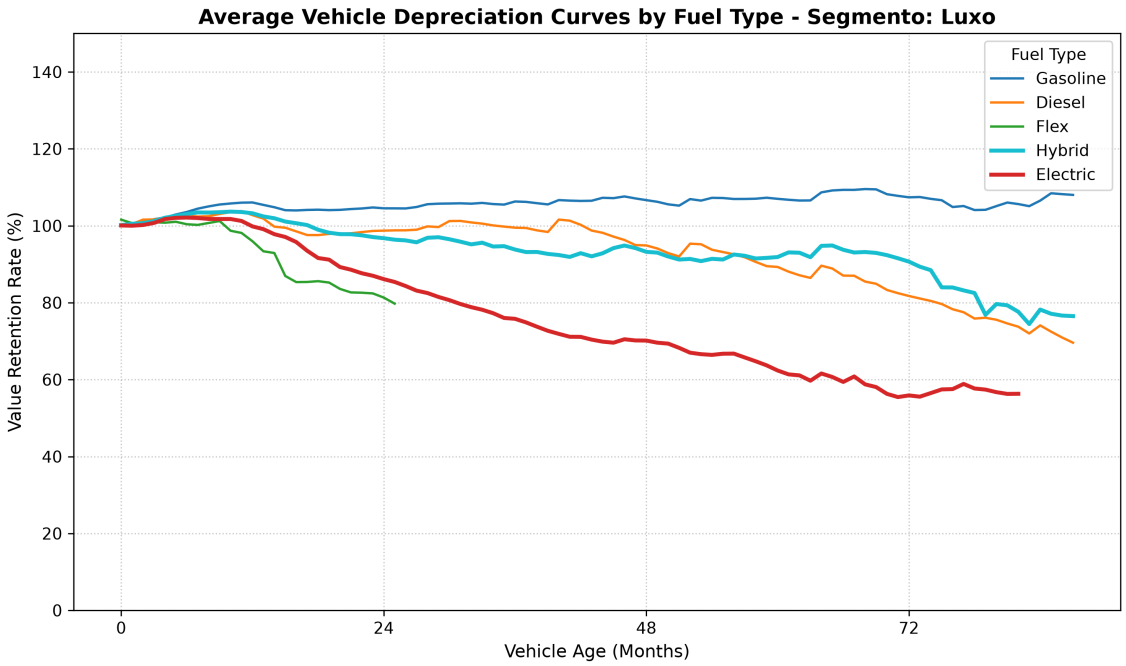


Figura 11: Curvas de depreciação médias por matriz energética para veículos de entrada, expressas em termos de Taxa de Retenção de Valor (VRR).

imagem, também nota-se a intensa depreciação dos veículos elétricos, os quais por volta de 60 meses de idade já apresentam um VRR abaixo de 60%, superando a depreciação máxima dos veículos de intermediários. Na Figura 12, observa-se que os veículos luxuosos foram o que obtiveram a menor valorização durante a pandemia, tendo todas as categorias sendo uma valorização menor do que 15%. Já no outro extremo, os veículos elétricos apesar de ter o menor VRR, tiveram uma desvalorização de YoY menos pior do que os intermediários, sem ultrapassar a porcentagem de 15% de desvalorização em 2024.

6 Atividade 3: Transformação e Representações Espaciais

As técnicas de codificação de séries temporais em representações matriciais bidimensionais, como o *Gramian Angular Field* (GAF) e o *Markov Transition Field* (MTF), são amplamente utilizadas em tarefas de mineração de dados, especialmente em problemas de classificação e agrupamento. Essas abordagens permitem capturar padrões temporais complexos que podem não ser evidentes em representações unidimensionais, então utilizamos a série de valores de retenção de valor (VRR) como base para a transformação em imagens.

6.1 Fundamentação

A ideia central de [16] é tratar uma série temporal como um sinal que pode ser reescrito em uma estrutura matricial, de modo que técnicas desenvolvidas para visão computacional passem a ser aplicáveis a dados temporais. O autor propõem três codificações: o *Gramian Angular Summation Field* (GASF), o *Gramian Angular Difference Field* (GADF) e o *Markov Transition Field* (MTF). Esse tipo de abordagem também é adotado em trabalhos posteriores para agrupamento de séries, como em [17], que compara GASF, GADF, MTF e *Recurrence Plots* (RP) e argumenta que a estrutura 2D reúne, em uma mesma representação, propriedades locais e relações de longo prazo da série.

6.1.1 Gramian Angular Field (GASF e GADF)

Dada uma série $X = \{x_1, x_2, \ldots, x_n\}$, o primeiro passo é reescalonar seus valores para o intervalo $[0, 1]$ (ou $[-1, 1]$) por meio de uma normalização *min-man*

$$\tilde{x}_i = \frac{x_i - \min(X)}{\max(X) - \min(X)}. \tag{3}$$

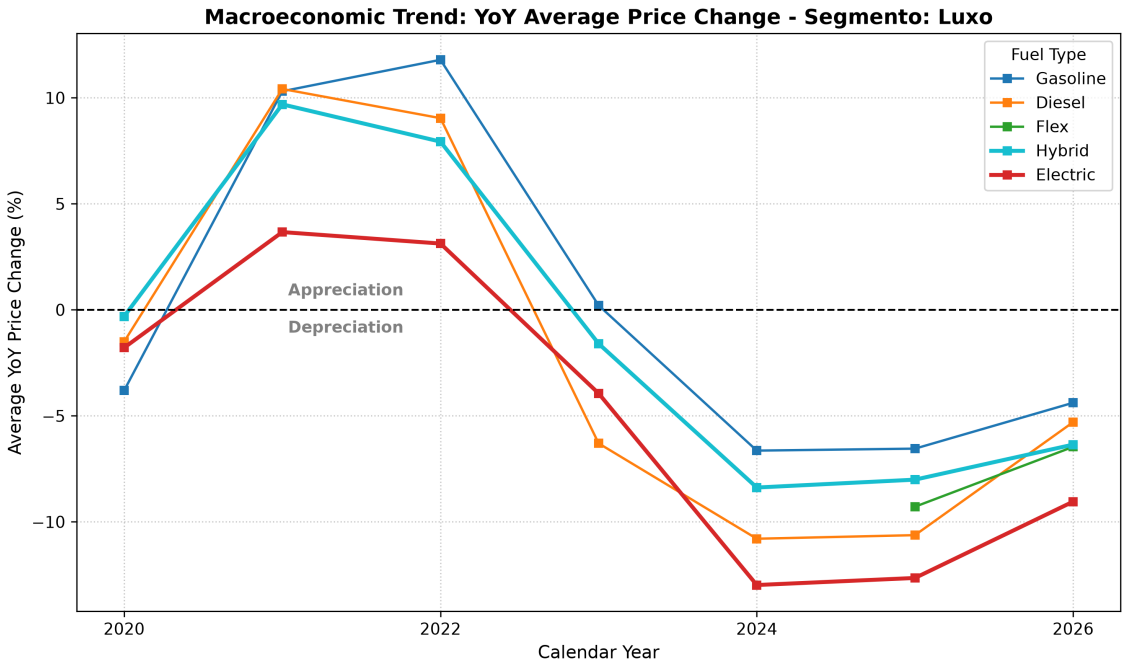


Figura 12: Taxa de por matriz energética para veículos de entrada, expressas em termos de Variação Ano a Ano (YoY).

Em seguida, a série reescalonada é levada a coordenadas polares: o valor é codificado como o ângulo e o instante de tempo como o raio,

$$\begin{cases} \phi_i = \arccos(\tilde{x}_i), & \tilde{x}_i \in \tilde{X}, \\ r_i = \dfrac{t_i}{N}, & t_i \in \mathbb{N}, \end{cases} \tag{4}$$

em que t_i é o carimbo de tempo e N é uma constante que regulariza o intervalo do sistema polar. Como a função cosseno é monotônica em $[0, \pi]$, essa transformação é bijetora, isto é, cada série possui uma única representação polar e uma única inversa. Além disso, ao contrário das coordenadas cartesianas, a representação polar preserva as relações temporais absolutas [16].

Com os ângulos ϕ_i, a correlação temporal entre os instantes i e j é obtida pela soma ou pela diferença trigonométrica dos ângulos:

$$\text{GASF} = [\cos(\phi_i + \phi_j)] = \tilde{X}' \cdot \tilde{X} - \sqrt{I - \tilde{X}^2}' \cdot \sqrt{I - \tilde{X}^2}, \tag{5}$$

$$\text{GADF} = [\sin(\phi_i - \phi_j)] = \sqrt{I - \tilde{X}^2}' \cdot \tilde{X} - \tilde{X}' \cdot \sqrt{I - \tilde{X}^2}, \tag{6}$$

onde I é o vetor linha unitário $[1, 1, \ldots, 1]$. O resultado é uma matriz $n \times n$ (uma matriz de Gram quase-definida) na qual o tempo avança do canto superior esquerdo para o inferior direito. Assim, a dependência temporal é preservada, pois a entrada (i, j) com $|i - j| = k$ representa a correlação relativa entre pontos separados por um intervalo k. A diagonal principal ($k = 0$) contém a informação original do valor, de modo que, para dados reescalonados em $[0, 1]$, é possível reconstruir a série a partir de $G_{ii} = \cos(2\phi_i)$ [16]. Como a imagem tem tamanho $n \times n$, os autores sugerem o uso de *Piecewise Aggregation Approximation* (PAA) para reduzir a resolução quando a série é longa.

6.1.2 Markov Transition Field (MTF)

Enquanto os campos angulares codificam informação estática (os valores e suas relações angulares), o MTF busca representar a dinâmica da série. A série é discretizada em Q *bins* de quantis e cada ponto x_i recebe o *bin* q_j ao qual pertence ($j \in [1, Q]$). Contando as transições entre *bins* consecutivos, à maneira de uma cadeia de Markov de primeira ordem, constrói-se a matriz de adjacência ponderada W de tamanho $Q \times Q$, que, após normalização por linha ($\sum_j w_{ij} = 1$), é a matriz de transição de Markov. Como W é insensível à distribuição de X e à dependência

temporal, o MTF a espalha ao longo do eixo do tempo:

$$M = \begin{bmatrix} w_{ij|x_1 \in q_i,\, x_1 \in q_j} & \cdots & w_{ij|x_1 \in q_i,\, x_n \in q_j} \\ \vdots & \ddots & \vdots \\ w_{ij|x_n \in q_i,\, x_1 \in q_j} & \cdots & w_{ij|x_n \in q_i,\, x_n \in q_j} \end{bmatrix}, \tag{7}$$

de forma que M_{ij} é a probabilidade de transição entre o quantil do instante t_i e o quantil do instante t_j. A diagonal principal M_{ii} corresponde à probabilidade de autotransição naquele instante [16]. Assim, o GAF e o MTF fornecem visões complementares da mesma série, e [16] propõem tratá-las como canais "ortogonais" (como as cores de uma imagem RGB), empilhando GASF, GADF e MTF em uma imagem de três canais. O MTF, porém, possui um espaço de imagens inversas muito maior que o do GAF, o que dificulta recuperar o sinal original e explica, segundo os autores, seu desempenho isolado geralmente inferior ao dos campos angulares na classificação. Por fim, [17] indicam que as quatro codificações têm custo computacional $O(n^2)$ e que a escolha do método de imageamento influencia de forma relevante o resultado de tarefas de agrupamento.

6.2 Metodologia

O fluxo do trabalho inicia com a série de entrada sendo a taxa de retenção de valor (VRR) de cada veículo, que é codificada em imagens GASF, GADF e MTF. Para cada janela de tamanho $T \in \{24, 32, 48, 64\}$ meses, são selecionados veículos lançados a partir de 2019 que possuem histórico completo para os primeiros T meses. Meses ausentes são preenchidos por interpolação linear, e séries com mais de 10% de meses ausentes são descartadas. Cada série é reescalonada globalmente em $[0, 1]$, e o MTF é calculado com $Q = 8$ *bins* de quantis por série. As saídas incluem as imagens codificadas, as séries brutas de VRR e metadados dos veículos. A Figura 13 ilustra o processo completo dessa geração.

6.2.1 Série de entrada: taxa de retenção de valor

A série a ser codificada é a *Value Retention Rate* (VRR) de cada veículo. Após a limpeza e o pré-processamento dos dados da tabela FIPE (remoção de registros duplicados e de valor zero, filtro para carros, exclusão de combustíveis gás natural e etanol, filtro de marcas relevantes e de veículos lançados há mais de 20 anos), cada coorte é identificada pela chave (`codigo_fipe`, `ano_modelo`, `sigla_combustivel`). A idade do veículo em meses (`idade_meses`) é calculada como a diferença entre o mês de referência e o mês da primeira cotação (`data_lancamento`), e a VRR é definida como

$$\mathrm{VRR}_t = \frac{\mathrm{valor}_t}{\mathrm{valor}_{t=0}}, \tag{8}$$

em que o preço de lançamento $\mathrm{valor}_{t=0}$ é ancorado na cotação do mês zero (`idade_meses` $= 0$). Dessa forma, toda série começa em 100% e descreve a evolução relativa do valor do veículo, independentemente do seu preço absoluto.

6.2.2 Janelas e seleção de veículos

Foram definidas quatro janelas, $T \in \{24, 32, 48, 64\}$ meses. Para cada janela, entram na amostra os veículos lançados a partir de 2019 que possuem histórico cobrindo os meses 0 a $T - 1$, e cada veículo é representado pelos seus primeiros T meses de VRR. Quando há mais de um registro para o mesmo veículo e mês, utiliza-se a média. Meses ausentes dentro da janela são preenchidos por interpolação linear, e séries cuja fração de meses ausentes excede 10% da janela são descartadas. A quantidade de veículos varia de acordo com a janela, já que janelas maiores exigem históricos mais longos.

6.2.3 Codificação em imagens

Cada série é codificada em três imagens $T \times T$, sem PAA e sem redimensionamento (ou seja, o tamanho da imagem é $S = T$), de modo a preservar toda a resolução temporal. As adaptações em relação ao procedimento original de [16] são as seguintes:

- **Reescalonamento global em $[0, 1]$.** Em vez do *min-max* por série da Equação 3, utiliza-se uma escala fixa e comum a todos os veículos, $\tilde{x} = \mathrm{VRR}/1{,}5$, com recorte (*clipping*) em $[0, 1]$ (o valor máximo de VRR é fixado em 150%). Com isso, o nível absoluto de depreciação (ou valorização) é preservado entre veículos diferentes, o que não ocorreria com a normalização

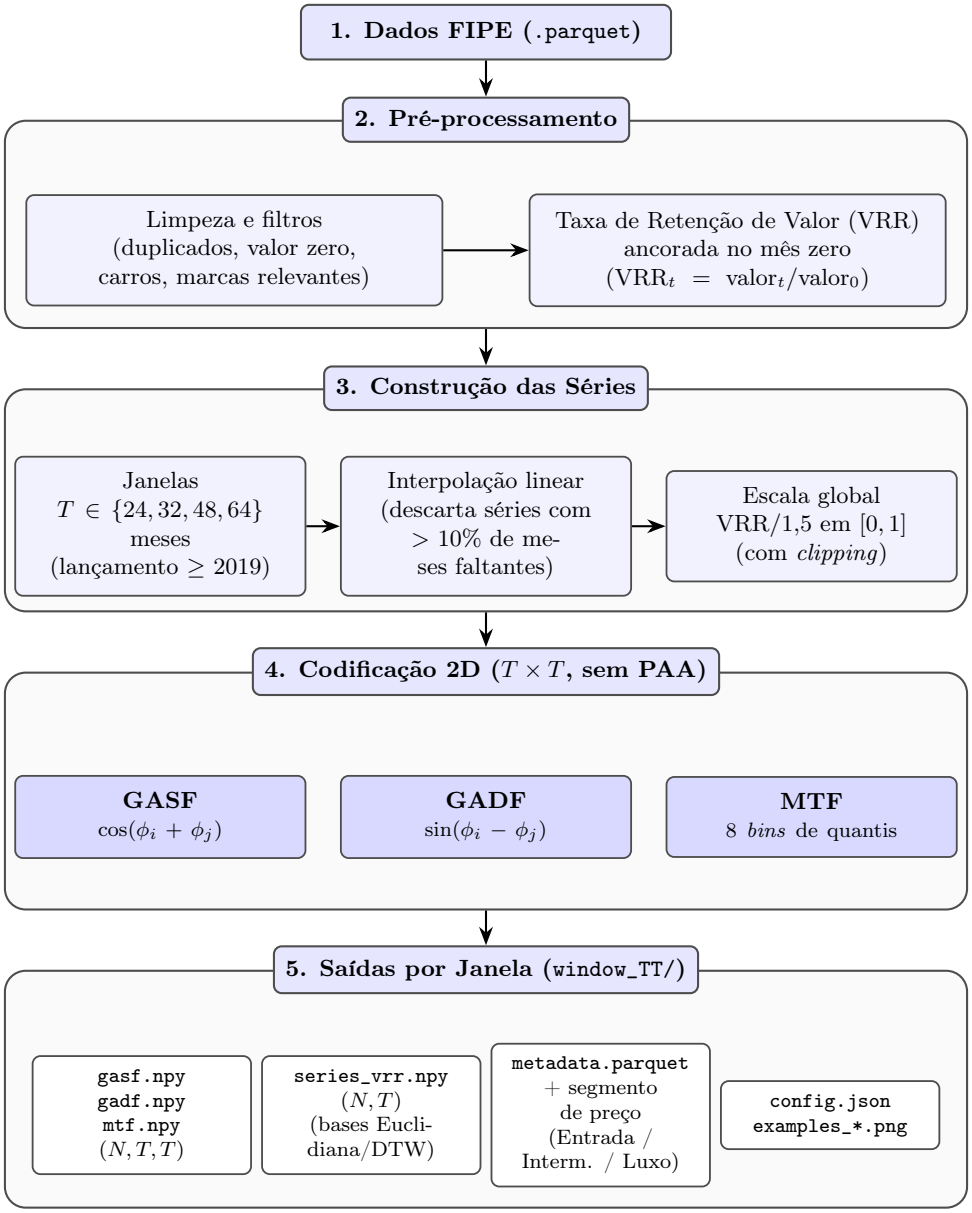


Figura 13: Fluxo da metodologia de codificação das séries de retenção de valor (VRR) em imagens GASF, GADF e MTF.

individual. A fração de valores recortados é registrada para cada janela. O intervalo $[0, 1]$ é o mesmo para o qual [16] demonstram a bijetividade do GASF.

- **GASF e GADF.** Calculados conforme as Equações 5 e 6, de forma vetorizada para todos os veículos, em precisão `float32`.
- **MTF.** Calculado com $Q = 8$ *bins* e estratégia de quantis por série, como no artigo original, de modo que cada série é discretizada pelos seus próprios quantis. A matriz W é estimada pelas transições consecutivas e normalizada por linha, e o campo é obtido por $M_{ij} = W[\text{bin}(x_i), \text{bin}(x_j)]$ (Equação 7). Como os quantis são relativos a cada série, o MTF descreve a dinâmica, mas não o nível absoluto da VRR; esse nível é preservado pelos campos angulares. A implementação também aceita *bins* uniformes sobre a escala global, o que manteria a informação de nível.

6.2.4 Segmentação por faixa de preço

Para analisar o comportamento de cada tipo de veículo, os veículos foram segmentados pelo preço de lançamento, a partir do primeiro (Q1) e do terceiro quartil (Q3) dos preços de todos os veículos únicos lançados desde 2019, independentemente do tamanho do histórico (mesmo procedimento da análise exploratória): **Entrada** (preço $\leq$ Q1), **Intermediário** (Q1 $<$ preço $\leq$ Q3) e **Luxo** (preço $>$ Q3).

6.2.5 Saídas geradas

Para cada janela T é criada uma pasta `window_TT` com os arquivos listados na Tabela 1, todos com a mesma ordem de veículos.

Tabela 1: Arquivos gerados para cada janela de T meses (N é o número de veículos da janela).

Arquivo	**Conteúdo**
`gasf.npy`, `gadf.npy`, `mtf.npy`	Imagens `float32` de dimensão (N, T, T)
`series_vrr.npy`	Séries VRR brutas (N, T), em razão, para as bases Euclidiana/DTW
`metadata.parquet`	Uma linha por veículo (modelo, marca, combustível, preço de lançamento, segmento etc.)
`config.json`	Parâmetros usados (janela, escala, *bins*, *clipping*, Q1 e Q3)
`examples_fuel.png`, `examples_segments.png`	Exemplos por combustível e por faixa de preço

6.3 Resultados

As Figuras 14 a 17 mostram, para cada janela, um veículo sorteado aleatoriamente (semente fixa) de cada faixa de preço, com a série de VRR (em %) e as respectivas imagens GASF, GADF e MTF. Como os veículos sorteados diferem entre as janelas, as figuras ilustram o comportamento das codificações e não permitem comparar um mesmo veículo entre janelas.

6.3.1 Análise das representações

Nos campos angulares, a posição temporal avança do canto superior esquerdo para o inferior direito, e a cor de cada região depende do nível da VRR nos instantes correspondentes, como descrito por [16]. Com a escala global adotada, séries que se afastam muito de 100% geram imagens com contraste forte. É o caso do Macan S na janela de 48 meses (Figura 16), cuja VRR sobe de 100% até cerca de 150% e produz um GASF com grandes regiões em vermelho, e da Strada Volcano na mesma janela, com valorização até cerca de 143%. Já séries com pouca amplitude resultam em imagens quase uniformes, como a Fiorino Endurance e o 718 Boxster 2.0 na janela de 24 meses (Figura 14), cuja VRR varia em poucos pontos percentuais. Esse efeito é esperado, pois a escala fixa mantém a informação de nível em vez de normalizar cada série para ocupar todo o intervalo. O GADF, por sua vez, exibe um padrão assimétrico em relação à diagonal (tons azulados e alaranjados em lados opostos), que reflete a diferença de ângulos entre instantes e, portanto, o

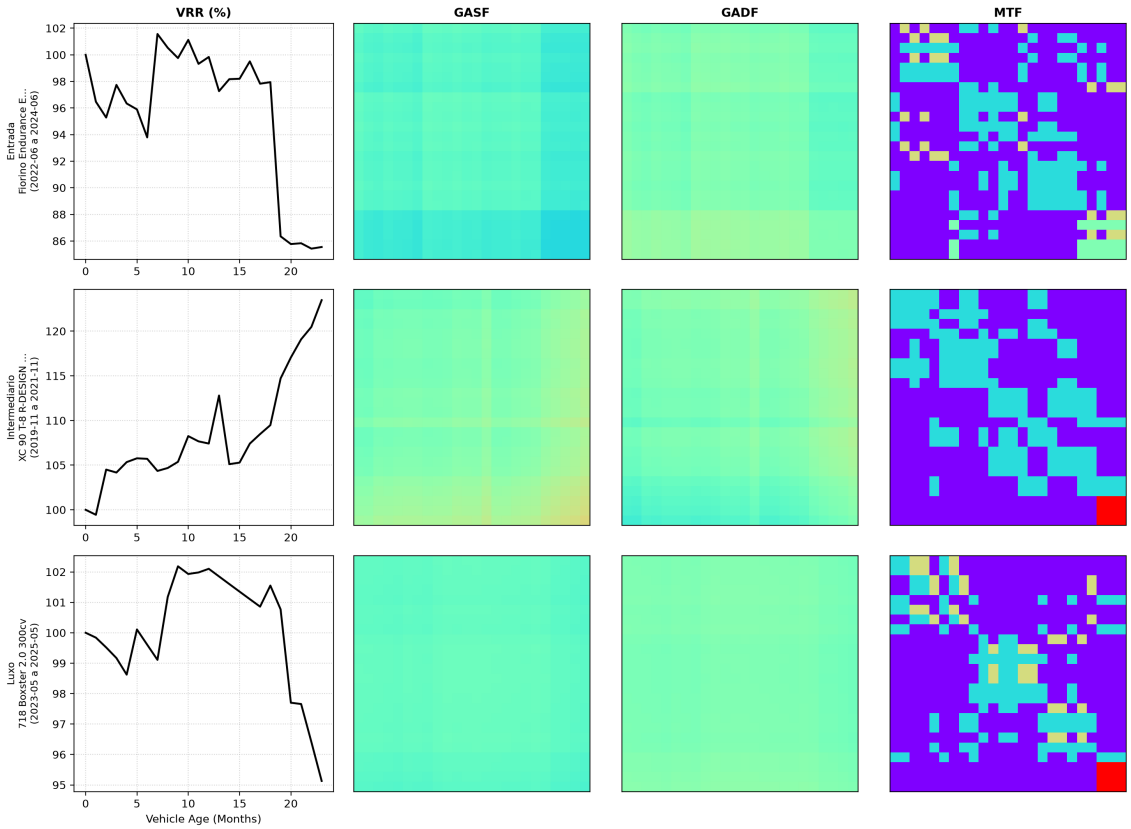


Figura 14: Exemplos por faixa de preço para a janela de 24 meses (imagens 24×24).

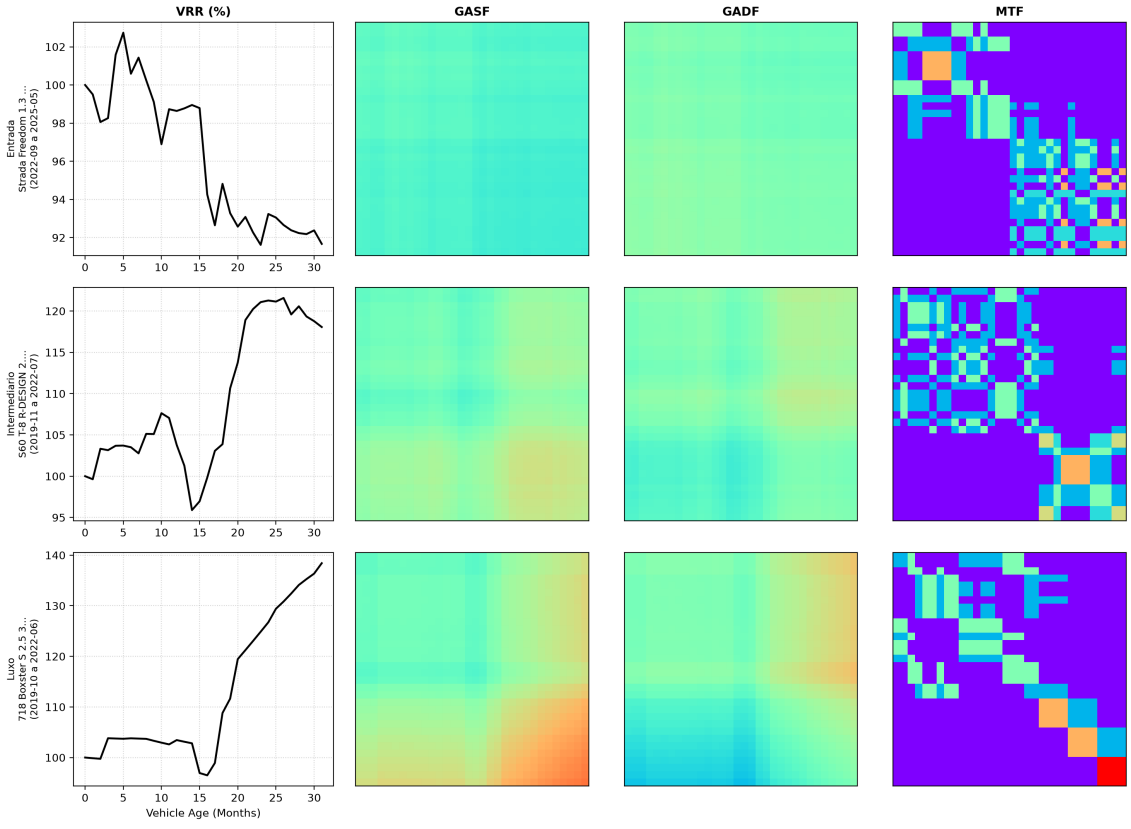


Figura 15: Exemplos por faixa de preço para a janela de 32 meses (imagens 32×32).

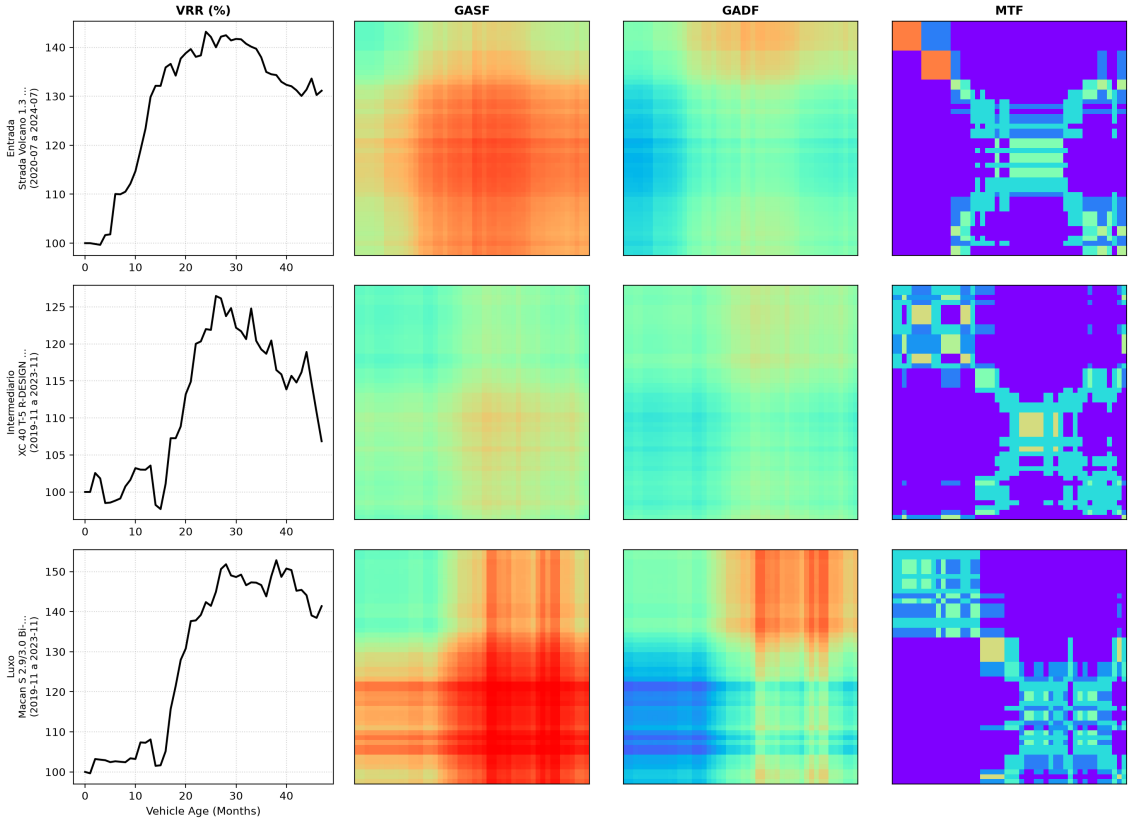


Figura 16: Exemplos por faixa de preço para a janela de 48 meses (imagens 48×48).

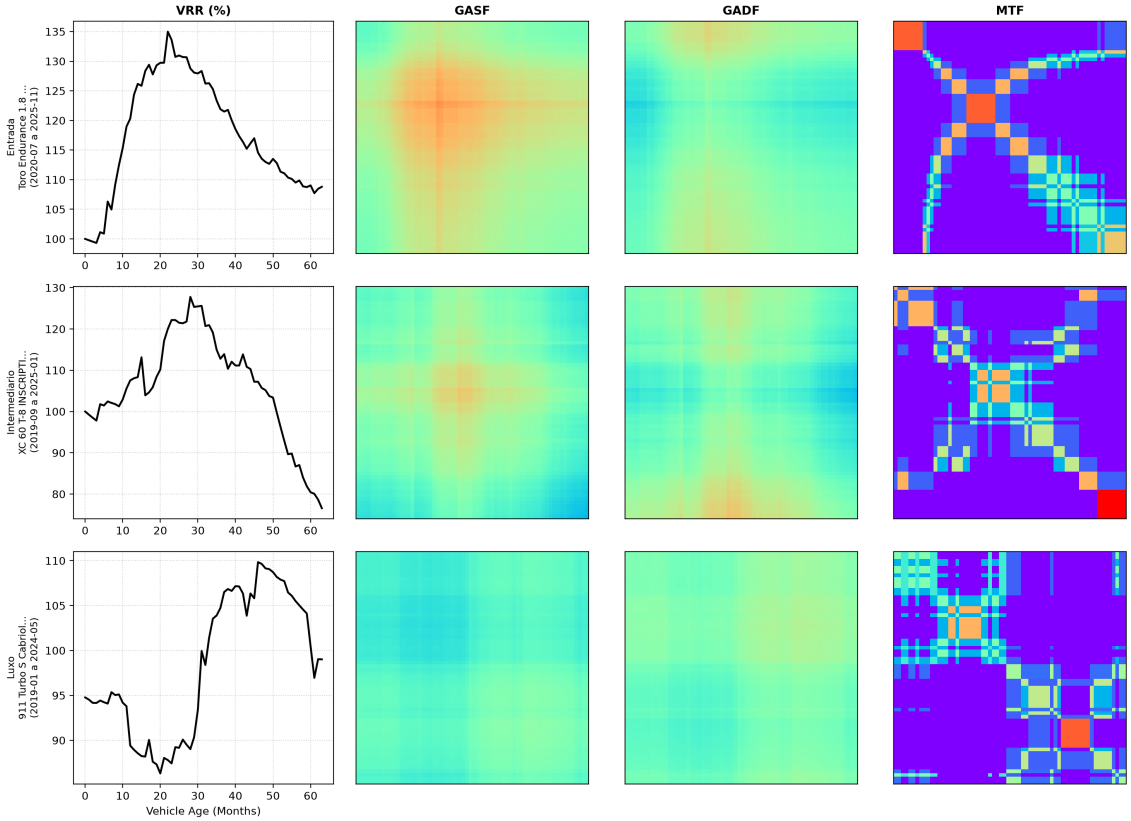


Figura 17: Exemplos por faixa de preço para a janela de 64 meses (imagens 64×64).

sentido da variação (subida ou queda) ao longo do tempo. Eventos abruptos aparecem como faixas horizontais e verticais, como a queda de cerca de 98% para 86% no mês 19 da Fiorino (Figura 14) e o salto do Macan S em torno do mês 17 (Figura 16).

O MTF apresenta uma estrutura em blocos, em que cada bloco corresponde a um par de quantis e sua probabilidade de transição. Blocos sobre a diagonal e próximos a ela indicam que a série permanece por vários meses no mesmo *bin*, o que é típico de trechos de tendência suave, ao passo que padrões em xadrez e linhas finas indicam alternância mais frequente entre *bins*, ou seja, maior oscilação. Como os quantis são calculados por série, séries com formatos de curva parecidos podem gerar MTF semelhantes mesmo com níveis de VRR diferentes. Isso é consistente com a observação de [16] de que o MTF captura a dinâmica, mas não seria suficiente, sozinho, para reconstruir o sinal. Por essa razão, os autores o tratam como canal complementar aos campos angulares.

Nos exemplos, os veículos de Entrada (Toro, Strada, Fiorino) e de Intermediário (Volvo XC40, XC60, XC90, S60) apresentam, em várias janelas, um período inicial de valorização acima do preço de lançamento seguido de queda (Toro e XC60 na janela de 64 meses, XC40 na de 48 meses), enquanto os exemplos de Luxo (Porsche) mostram comportamentos variados: o 911 Turbo S cai para cerca de 86% e se recupera até cerca de 110% na janela de 64 meses, o 718 Boxster S valoriza de forma quase monotônica até cerca de 138% na janela de 32 meses e o Macan S passa de 150% na de 48 meses. A VRR acima de 100% em veículos de 2019 a 2020 sugere que o período observado teve forte valorização do mercado de usados, o que deve ser confirmado na análise exploratória. Como cada faixa é representada por um único veículo por figura, essas observações são qualitativas e não permitem concluir diferenças sistemáticas entre as faixas, o que dependerá das etapas seguintes de classificação ou agrupamento. De qualquer forma, as imagens mostram que trajetórias distintas de depreciação geram texturas visualmente distintas nas três codificações, o que é a premissa para o uso de métodos de visão computacional sobre essas representações, de forma análoga ao que [17] exploram em séries financeiras.

À medida que a janela aumenta, as imagens ganham resolução e passam a conter trechos mais longos da trajetória, incluindo fases de valorização, pico e queda (Figuras 16 e 17). Nas janelas curtas (24 e 32 meses), as imagens são mais homogêneas e o MTF possui blocos grandes e menos estruturados (Figuras 14 e 15). Em contrapartida, janelas maiores restringem a amostra aos veículos com histórico mais longo, o que é um compromisso a ser considerado nas etapas seguintes.

7 Atividade 4: Modelagem de Agrupamento e Extração de Padrões

A presente atividade compreende a aplicação e a comparação empírica de técnicas de agrupamento (*clustering*) não supervisionado para a descoberta de padrões e arquétipos comportamentais de depreciação veicular. Para tanto, estabelece-se uma linha de base (*baseline*) operando diretamente no domínio temporal unidimensional (1D) das séries de Taxa de Retenção de Valor (VRR) sob métricas euclidianas e de *Dynamic Time Warping* (DTW), confrontando-a com os agrupamentos extraídos dos espaços latentes gerados pelas codificações matriciais bidimensionais (2D) desenvolvidas na Atividade 3 (*Gramian Angular Fields* e *Markov Transition Fields*).

7.1 Fundamentação Teórica

Conforme formalizado na literatura clássica de mineração de dados [14], a análise de agrupamento visa particionar uma coleção de objetos não rotulados em subconjuntos homogêneos (clusters), de modo que a similaridade intraclasse seja maximizada e a similaridade interclasse seja minimizada.

7.1.1 Taxonomia de Agrupamentos e Tipos de Clusters

A literatura estabelece distinções conceituais fundamentais quanto à organização e à topologia dos grupos gerados [14]:

- **Particional vs. Hierárquico:** Um agrupamento particional divide os dados em subconjuntos disjuntos e não sobrepostos, de modo que cada objeto pertença a exatamente um grupo. Em contrapartida, abordagens hierárquicas constroem uma árvore aninhada de partições (dendrograma), permitindo múltiplos níveis de granularidade.
- **Exclusivo vs. Não-Exclusivo (Fuzzy):** No particionamento estrito (exclusivo), a pertinência é binária ($x_i \in C_j$). No modelo *fuzzy*, cada ponto possui um grau de pertinência $\mu_{ij} \in [0, 1]$ em relação a cada cluster, com $\sum_j \mu_{ij} = 1$.

- **Completo vs. Parcial:** Enquanto métodos completos alocam compulsoriamente todos os pontos a algum agrupamento, métodos parciais identificam e isolam instâncias anômalas como ruído (*noise*), característica central de algoritmos baseados em densidade.

Quanto à definição da natureza dos grupos, distinguem-se quatro classes fundamentais:

1. **Well-separated (Bem separados):** Cada ponto está mais próximo de todos os pontos de seu próprio cluster do que de qualquer ponto pertencente a clusters externos.
2. **Center-based (Baseados em centro):** Cada objeto está mais próximo do centro de seu grupo do que do centro de qualquer outro grupo. O centro pode ser formalizado como um *centróide* (média ou mediana dos atributos do grupo) ou um *medóide* (objeto real pertencente à amostra que minimiza a soma das distâncias aos demais pontos do cluster).
3. **Contiguity-based (Baseados em contiguidade):** Grupos formados por vizinhanças imediatas, em que dois objetos conectam-se se a distância mútua for inferior a um limiar pré-estabelecido.
4. **Density-based (Baseados em densidade):** Regiões de alta densidade no espaço de atributos separadas por regiões contíguas de baixa densidade, viabilizando o isolamento de ruídos e o mapeamento de agrupamentos com geometrias arbitrárias e não convexas.

7.1.2 K-Means e Minimização do Erro Quadrático (SSE)

O algoritmo K-Means é o método particional baseado em centróides mais difundido na literatura. Dado um conjunto de N objetos $X = \{x_1, \ldots, x_N\}$ no espaço $\mathbb{R}^D$ e um número pré-definido K de partições, o algoritmo busca determinar os conjuntos $C = \{C_1, \ldots, C_K\}$ e seus respectivos centróides $m_k = \frac{1}{|C_k|} \sum_{x \in C_k} x$ que minimizem a Soma dos Erros Quadráticos (*Sum of Squared Errors* - SSE) [14]:

$$\text{SSE} = \sum_{k=1}^{K} \sum_{x \in C_k} \|x - m_k\|^2. \tag{9}$$

Para atenuar a suscetibilidade da convergência a mínimos locais insatisfatórios decorrentes da escolha inicial aleatória, adota-se o esquema de inicialização probabilística inteligente K-Means++ [3], no qual o primeiro centróide é sorteado uniformemente e os subsequentes são sorteados com probabilidade proporcional ao quadrado da distância mínima ao centróide mais próximo já selecionado ($D(x)^2$).

7.1.3 Agrupamento Baseado em Densidade: DBSCAN

O algoritmo DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) [5] define clusters a partir da densidade local de pontos. Dados dois hiperparâmetros fundamentais — o raio de vizinhança ε (*Eps*) e o número mínimo de vizinhos $MinPts$ — o algoritmo particiona as instâncias em três categorias conceituais [14]:

- **Ponto Núcleo (*Core Point*):** Ponto cuja vizinhança esférica de raio ε contém pelo menos $MinPts$ vizinhos, isto é, $|N_\varepsilon(x)| \geq MinPts$.
- **Ponto de Borda (*Border Point*):** Ponto que não satisfaz a condição de núcleo ($|N_\varepsilon(x)| < MinPts$), mas reside dentro da vizinhança-ε de um ponto núcleo.
- **Ponto de Ruído (*Noise Point*):** Ponto que não é nem núcleo nem borda, sendo classificado como ruído ou *outlier*.

Para evitar a escolha arbitrária de ε, segue-se a prescrição metodológica do gráfico de k-distâncias (*k-distance graph*) proposta por [5] e sintetizada por [14]: calcula-se a distância de cada ponto ao seu k-ésimo vizinho mais próximo (com $k = MinPts$) e ordenam-se essas distâncias em ordem decrescente; o ponto de inflexão (*cotovelo/knee*) da curva indica o limiar ótimo de ε, separando a densidade dos agrupamentos genuínos da cauda esparsa de ruídos.

7.1.4 Métricas de Proximidade em Séries Temporais: Euclidiana vs. DTW

A aplicação de algoritmos de agrupamento diretamente sobre trajetórias temporais 1D exige cautela quanto à medida de proximidade. Enquanto a distância euclidiana impõe um alinhamento rígido ponto a ponto ($|x_t - y_t|$), tornando o modelo vulnerável a pequenos descompassos temporais e deslocamentos de fase, o algoritmo *Dynamic Time Warping* (DTW) [12] encontra um caminho de alinhamento ótimo não linear na matriz de distâncias locais, permitindo associar padrões com acelerações ou desacelerações temporais relativas. No cálculo de centróides no espaço DTW, emprega-se o procedimento de *DTW Barycenter Averaging* (DBA) para atualização iterativa das curvas médias.

7.1.5 Espaços Latentes 2D (GAF e MTF)

Na abordagem bidimensional, cada série temporal de comprimento T gera matrizes ($T \times T$) para GASF, GADF e MTF. Como a estrutura matricial impõe uma dimensão de T^2 atributos por canal (frequentemente correlacionados e simétricos em relação à diagonal principal), emprega-se Análise de Componentes Principais (PCA) sobre o espaço vetorizado das imagens para reter 95% da variância total acumulada. Essa projeção ortogonal remove redundâncias colineares de alta frequência e preserva os eixos dominantes de dispersão estrutural das texturas visuais [17].

7.1.6 Critérios de Validação de Agrupamento

A qualidade e a coesão dos clusters gerados são avaliadas por meio de índices intrínsecos de validação não supervisionada [14]:

- **Coeficiente de Silhueta (s):** Proposto por [11], mensura o equilíbrio entre a coesão intra-cluster $a(i)$ (distância média do ponto i aos demais membros de seu grupo) e a separação inter-cluster $b(i)$ (distância média do ponto i aos pontos do grupo mais próximo):

$$s(i) = \frac{b(i) - a(i)}{\max(a(i),\, b(i))}, \quad s(i) \in [-1, +1]. \tag{10}$$

  Valores próximos a $+1$ atestam excelente compactação e isolamento, enquanto valores próximos de zero ou negativos indicam indefinição de fronteira ou sobreposição.

- **Índice Davies-Bouldin (DB):** Proposto por [4], calcula a razão média entre a dispersão interna dos pares de clusters e a distância entre seus centróides:

$$DB = \frac{1}{K} \sum_{i=1}^{K} \max_{j \neq i} \left(\frac{\bar{d}_i + \bar{d}_j}{d(m_i, m_j)} \right), \tag{11}$$

  em que valores menores denotam partições com clusters densos e bem espaçados.

7.2 Metodologia Experimental

O protocolo experimental baseou-se na janela temporal de $T = 32$ meses ($N = 3.872$ veículos lançados a partir de 2019 com histórico contínuo ou até 10% de interpolação). Essa janela captura desde o preço de lançamento até a maturação de 2,6 anos de mercado, englobando choques econômicos pós-pandemia e a introdução da frota eletrificada.

Foram avaliadas comparativamente as seguintes representações:

1. **1D VRR (Euclidiano):** Vetores brutos da Taxa de Retenção de Valor em $\mathbb{R}^{32}$.
2. **1D VRR (DTW):** Séries 1D processadas via TimeSeriesKMeans com cálculo de centróides por DBA.
3. **2D GASF (PCA 95%):** Projeção dos campos de soma angular em 2 componentes principais (responsáveis por 97,0% da variância total).
4. **2D GADF (PCA 95%):** Projeção dos campos de diferença angular em 5 componentes principais (95,2% da variância total).
5. **2D MTF (PCA 95%):** Projeção dos campos de transição de Markov em 511 componentes (95,0% da variância total).

6. **2D Multicanal (PCA 95%):** Projeção da concatenação plana dos três campos em 156 componentes principais (95,0% da variância).

Para cada representação, o algoritmo K-Means foi testado na faixa $K \in \{2, 3, 4, 5, 6, 7\}$ com 10 inicializações independentes. Adicionalmente, calibrou-se o DBSCAN ($MinPts = 5$) determinando-se ε a partir do joelho das curvas de k-distância.

7.3 Resultados e Validação de Agrupamento

A Tabela 2 reporta o desempenho comparativo das métricas de Silhueta e Davies-Bouldin ao longo dos diferentes valores de K.

Tabela 2: Métricas de validação intrínseca para diferentes números de clusters (K).

Representação	Métrica	K=2	K=3	K=4	K=5	K=6	K=7
1D VRR (Euclidiano)	Silhueta	0,479	0,386	0,303	0,316	0,307	0,294
	Davies-Bouldin	0,765	0,945	1,038	1,041	1,012	1,054
1D VRR (DTW)	Silhueta	0,459	0,345	0,258	0,194	0,164	0,169
	Davies-Bouldin	0,792	1,096	1,383	1,583	1,676	1,476
2D GASF	**Silhueta**	**0,544**	**0,481**	**0,430**	**0,384**	**0,387**	**0,378**
	Davies-Bouldin	**0,661**	**0,747**	**0,811**	**0,854**	**0,831**	**0,840**
2D GADF	Silhueta	0,457	0,451	0,413	0,396	0,319	0,318
	Davies-Bouldin	0,941	1,089	0,970	0,996	0,995	1,036
2D MTF	Silhueta	0,066	0,075	0,071	0,074	0,047	0,048
	Davies-Bouldin	3,175	3,680	3,033	3,011	3,163	3,277
2D Multicanal	Silhueta	0,397	0,293	0,225	0,210	0,186	0,167
	Davies-Bouldin	0,997	1,240	1,475	1,442	1,485	1,558

A evolução quantitativa das métricas de coesão, separação e decaimento da inércia é ilustrada nas Figuras 18, 19 e 20.

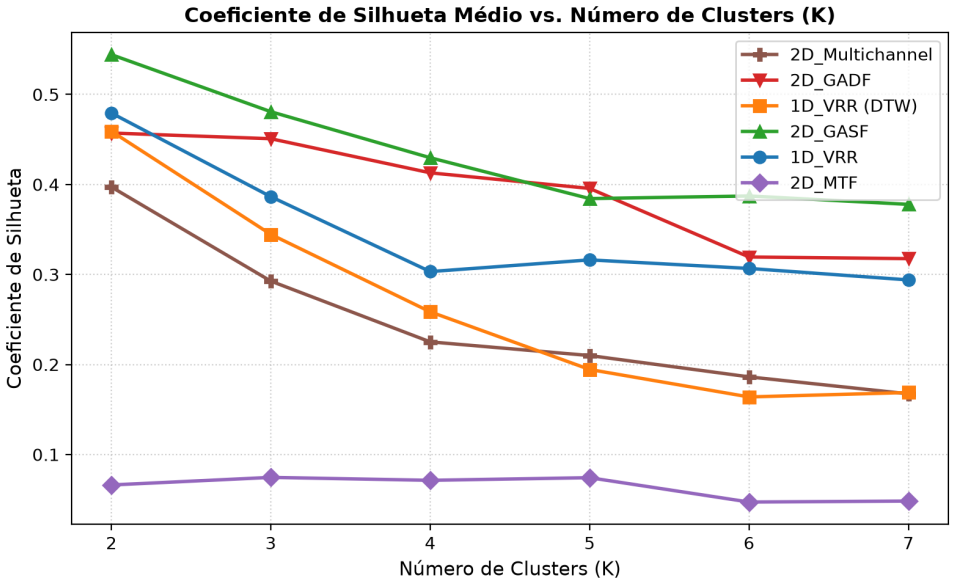


Figura 18: Coeficiente de Silhueta médio para $K \in [2, 7]$ entre representações 1D e 2D.

7.3.1 Análise Comparativa 1D vs. 2D

Os resultados experimentais revelam nuances teóricas de alto valor analítico:

- **Superioridade da Codificação GASF:** O espaço latente derivado do GASF superou consistentemente todas as demais representações em todos os valores de K. Em $K = 4$, o GASF obteve Silhueta de +0,430 contra +0,303 da abordagem 1D Euclidiana e +0,258 do

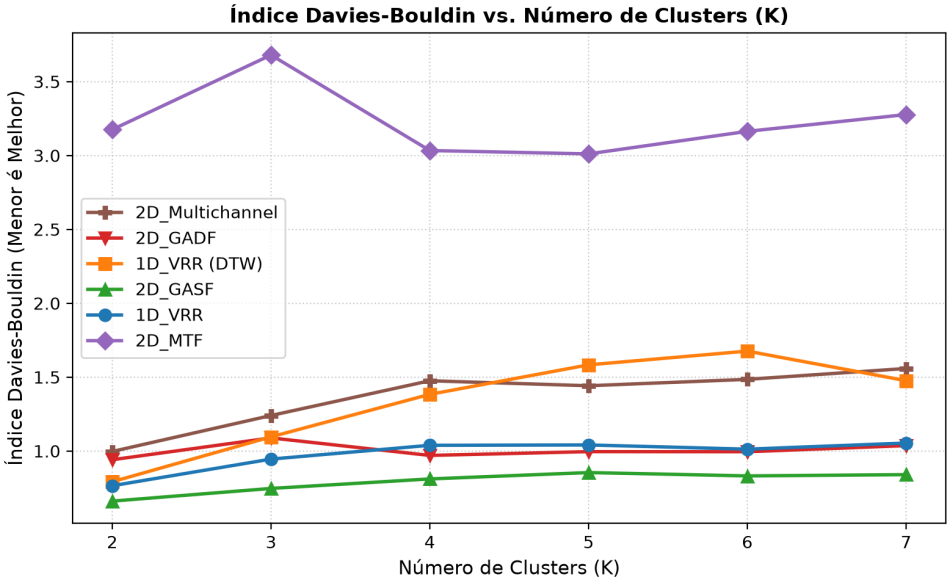


Figura 19: Índice Davies-Bouldin (menor é melhor) para $K \in [2, 7]$.

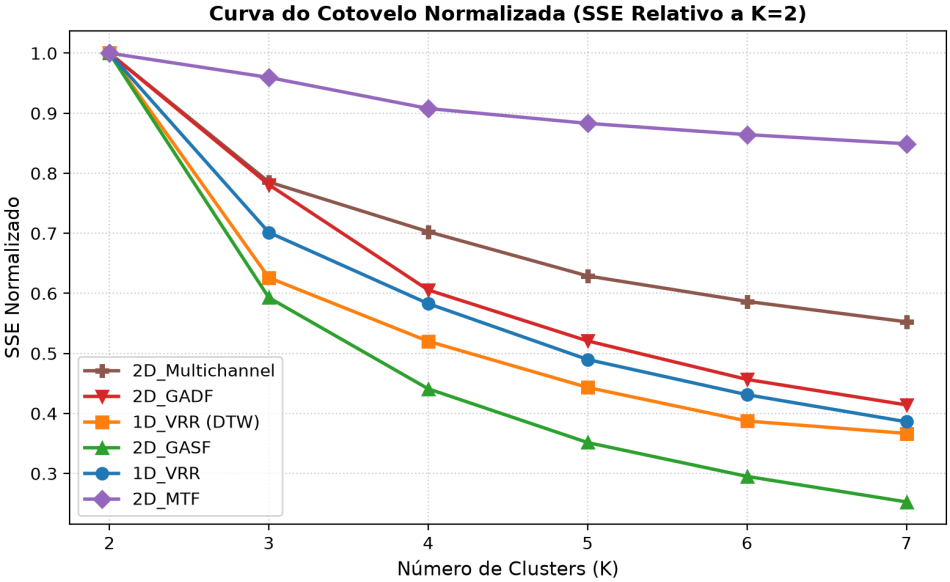


Figura 20: Curvas de decaimento do SSE normalizado em relação a $K = 2$ (Método do Cotovelo).

1D DTW. O índice Davies-Bouldin correspondente foi substancialmente inferior (0,811 no GASF frente a 1,038 e 1,383 nas abordagens 1D), comprovando que a transformação angular compacta variações redundantes e amplifica a discriminação de níveis e tendências absolutas de depreciação.

- **Limitações do DTW em Dados Homogêneos:** A métrica DTW apresentou escores de silhueta inferiores aos da distância Euclidiana. Isso ocorre porque o DTW "perdoa" defasagens de tempo ao comprimir ou distender o eixo temporal para alinhar curvas. No mercado de veículos, porém, o instante exato em que um ativo se valoriza ou desvaloriza carrega significado econômico vital (p. ex., choque de semicondutores em 2021). Ao flexibilizar o alinhamento de fase temporal, o DTW aglutina veículos com perfis temporais intrinsecamente distintos, gerando grupos com dispersão euclidiana ampliada.

- **Comportamento do MTF:** O campo de transição de Markov apresentou coeficiente de silhueta próximo de zero ($s \approx 0{,}07$) e alto Davies-Bouldin ($DB > 3{,}0$). Essa constatação é coerente com a formulação teórica de [16] e os achados empíricos de [17]: como os quantis do MTF são calculados em nível relativo individual de série, a matriz de transição preserva a dinâmica de oscilação local, mas perde completamente a magnitude absoluta do preço inicial e do VRR final.

7.3.2 Calibração e Desempenho do DBSCAN

A Figura 21 exibe os gráficos de k-distância gerados para $MinPts = 5$. O joelho pronunciado estabeleceu os parâmetros $\varepsilon = 0{,}110$ para o espaço 1D VRR e $\varepsilon = 0{,}139$ para o espaço 2D GASF.

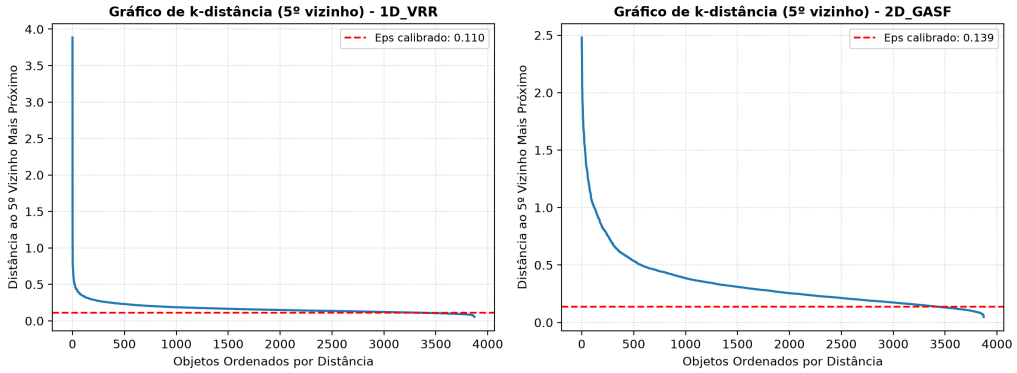


Figura 21: Curvas de k-distância ordenadas ($MinPts = 5$) e determinação do limiar ε.

O DBSCAN no espaço 1D identificou 30 agrupamentos e classificou 78,3% da base como ruído (Silhueta de $-0{,}177$). Já no espaço 2D GASF, o algoritmo particionou instâncias em regiões de alta concentração central (Silhueta dos pontos nucleares de $+0{,}387$). O elevado percentual de ruído evidencia que as trajetórias de depreciação automotiva formam um contínuo com densidade variável e dispersão periférica, justificando a superioridade prática dos métodos particionais (K-Means) para a segmentação de mercado e definição de arquétipos.

7.4 Caracterização dos Arquétipos de Depreciação ($K = 4$)

A inspeção da curva do cotovelo (Figura 20) combinada à interpretabilidade econômica indica que $K = 4$ representa o ponto de equilíbrio ótimo para derivar arquétipos comportamentais. A Tabela 3 sintetiza os quatro perfis identificados pelo modelo 2D GASF, enquanto a Figura 22 exibe as trajetórias de VRR com seus respectivos intervalos interquartis (Q1–Q3).

Tabela 3: Síntese dos quatro arquétipos comportamentais de depreciação identificados via 2D GASF ($K = 4$).

Arquétipo	Veículos	% Total	VRR 0m	VRR 12m	VRR 32m	Δ Líquido	Elétricos	% Eletrif.
Cluster 1 (Depreciação Acelerada)	1.522	39,3%	98,4%	95,3%	84,8%	−13, 6%	133	21,3%
Cluster 2 (Super-Valorização)	327	8,4%	99,9%	134,4%	140,0%	+40, 1%	0	3,1%
Cluster 3 (Valorização Moderada)	864	22,3%	99,7%	117,7%	123,9%	+24, 2%	10	7,1%
Cluster 4 (Estabilidade Paritária)	1.159	29,9%	99,2%	106,6%	107,9%	+8, 7%	52	15,0%

Os quatro arquétipos apresentam características operacionais e econômicas nítidas:

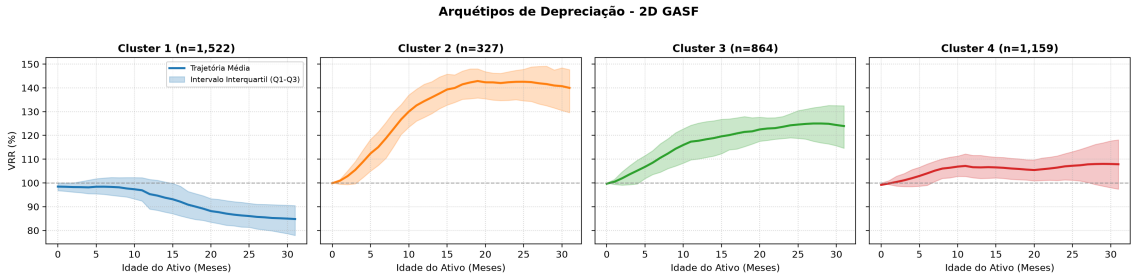


Figura 22: Trajetórias médias e dispersão interquartil (Q1–Q3) dos quatro arquétipos via 2D GASF.

1. **Cluster 1 — Depreciação Acelerada e Perda de Valor:** Reúne 1.522 veículos (39,3% da amostra). Apresenta perda contínua de cotação desde a estreia, fechando aos 32 meses com VRR médio de 84,8% (queda acumulada de −13,6%). Este agrupamento concentra a grande maioria dos veículos elétricos da base: **133 de um total de 195 elétricos (**68,2% **de toda a frota EV)** encontram-se alocados neste cluster, juntamente com 191 modelos híbridos.

2. **Cluster 2 — Super-Valorização Anômala / Utilitários:** Composto por 327 veículos (8,4%). Atinge VRR médio de 134,4% aos 12 meses e finaliza aos 32 meses em expressivos 140,0% de retenção (ganho líquido de +40,1%). De forma contundente, **não há nenhum veículo elétrico neste cluster** (0 elétricos e apenas 10 híbridos). O agrupamento é dominado em mais de 97% por veículos a combustão tradicional e veículos utilitários comerciais a diesel, refletindo a explosão de demanda e a escassez de suprimentos no período pandêmico.

3. **Cluster 3 — Valorização Moderada / Resiliência Pós-Pandemia:** Agrupa 864 modelos (22,3%) com valorização média de +24,2% (VRR final de 123,9%). Possui representação irrisória de modelos eletrificados (10 elétricos, representando apenas 1,2% do grupo).

4. **Cluster 4 — Estabilidade e Retenção Paritária:** Reúne 1.159 veículos (29,9%) com trajetória resiliente e estável, encerrando aos 32 meses em 107,9% do preço inicial (+8,7%). Exibe composição mista equilibrada, integrando 52 veículos elétricos e 122 híbridos.

A Figura 23 ilustra a estratificação dos quatro clusters segundo matriz energética e faixa de preço de lançamento. Constata-se que o Cluster 1 (Depreciação Acelerada) absorve a maior concentração percentual de veículos das categorias Intermediário e Luxo eletrificados, evidenciando que a depreciação mais severa incide preponderantemente sobre veículos novos equipados com tecnologia puramente elétrica.

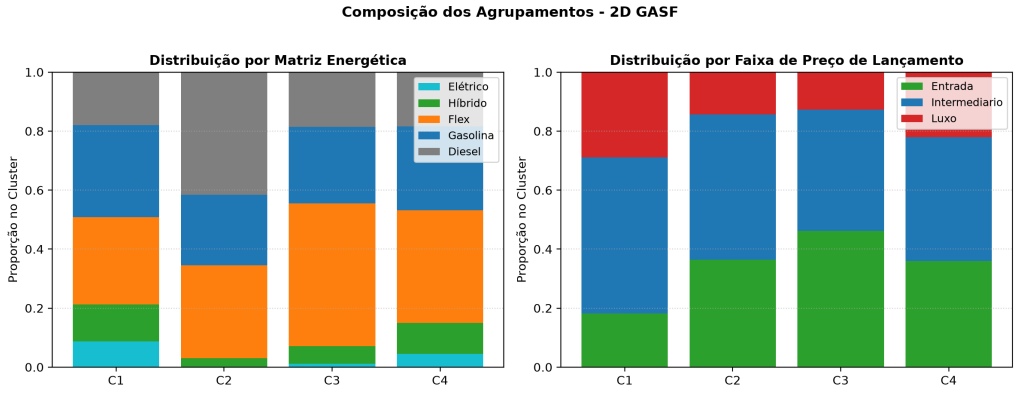


Figura 23: Composição dos arquétipos segundo tipo de combustível e faixa de preço de lançamento.

Por fim, a Figura 24 exibe o medóide representativo de cada um dos quatro arquétipos, conectando a curva temporal de VRR às matrizes correspondentes de GASF, GADF e MTF. O medóide do Cluster 1 (perfil de desvalorização acelerada) exibe contraste angular invertido em relação aos medóides dos clusters em valorização contínua (Clusters 2 e 3), validando visualmente a capacidade das representações espaciais em sintetizar a física de mercado das trajetórias temporais.

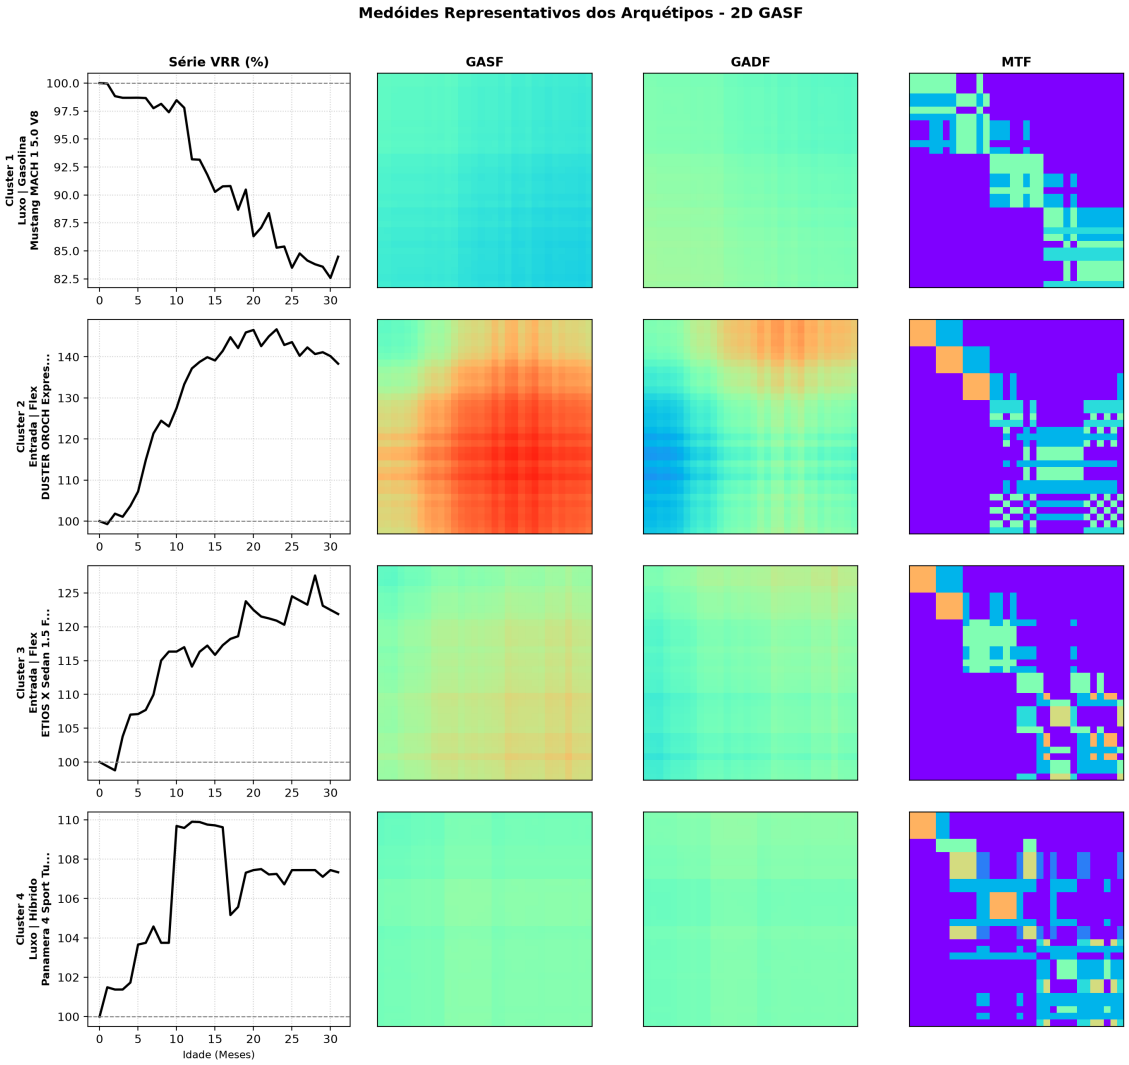


Figura 24: Medóides representativos de cada arquétipo com suas respectivas séries e imagens 2D (GASF, GADF e MTF).

Referências

[1] L. Abrardi. Market structure and competitive dynamics of electric vehicle in europe. Master's thesis, Politecnico di Torino, 2026.

[2] F. H. B. Alvarez. *Modelagem da Aceitação de Veículos Elétricos considerando Políticas de Incentivo, Consciência Ambiental, Inovação Pessoal e Auto-eficácia Financeira: uma Extensão ao UTAUT 2*. Tese de doutorado, Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio), 2024.

[3] David Arthur and Sergei Vassilvitskii. k-means++: the advantages of careful seeding. In *Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*, pages 1027–1035, 2007.

[4] David L. Davies and Donald W. Bouldin. A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-1(2):224–227, 1979.

[5] Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 226–231, 1996.

[6] P. Gautam, G. Pode, R. Pode, G. K. Ayetor, and B. Diouf. Depreciation in the electric vehicle transition: Sustainability of the second-hand electric vehicle market. *Vehicles*, 6(4):101, 2024.

[7] Instituto Brasileiro de Geografia e Estatística. Índice nacional de preços ao consumidor amplo - IPCA: Abril de 2022, may 2022. Acesso em: 21 out. 2026.

[8] Jayson C. Jueco et al. Performance analysis of time series-to-image encoding across different clustering methods for labeling anomalous load data in selected visayas subgrids. In *2024 IEEE Region 10 Conference (TENCON)*. IEEE, 2024.

[9] Changjun Li, Congmei Xu, Tongtong An, Mengcheng Yu, and Xiangjian Xin. The global electric vehicle (ev) industry price war: Implications for managerial decision-making. *Frontiers in Industry Economics and Management*, 2026.

[10] Shanjun Li et al. The rise of electric vehicles in china: Growth, challenges and future prospects. In *The Great Energy Transformation in China*, page 109. ANU Press, 2025.

[11] Peter J. Rousseeuw. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20:53–65, 1987.

[12] Hiroaki Sakoe and Seibi Chiba. Dynamic programming algorithm optimization for spoken word recognition. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 26(1):43–49, 1978.

[13] L. Schloter. Empirical analysis of the depreciation of electric vehicles compared to gasoline vehicles. *Transport Policy*, 126:268–279, 2022.

[14] Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, and Vipin Kumar. *Introduction to Data Mining*. Pearson Education, 2nd, global edition edition, 2019.

[15] Stepan Ulyanin, Jose R. Vazquez-Canteli, and Zoltan Nagy. Feature extraction and clustering of building energy profiles encoded as images. In *Proceedings of Building Simulation 2019: 16th Conference of IBPSA*, volume 16, pages 2108–2115. IBPSA, 2019.

[16] Zhiguang Wang and Tim Oates. Imaging time-series to improve classification and imputation. In *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI)*, pages 3939–3945, 2015.

[17] J. Wu. Imaging feature-based clustering of financial time series. *PLOS ONE*, 18(7):e0288836, 2023.